Universidad Adolfo Ibáñez

Tesis de Magíster

Aumentación de Datos con LLMs: Filtrado Geométrico para Clasificación de Texto

---

Autor:
Benjamín Schindler

Profesor guía:
Dr. Gonzalo A. Ruz

Comité de defensa:
Dr. Luis Aburto
Dr. Rolando De La Cruz
Dr. Pablo Henríquez
Dr. Andrés Peters

Tesis realizada acorde a los requerimientos para el grado de
Master of Science in Data Science,
Ingeniería Civil Informática e
Ingeniería Civil Industrial

de la

Facultad de Ingeniería y Ciencias

Mayo 2026

UAI | FACULTAD DE INGENIERÍA Y CIENCIAS

UNIVERSIDAD ADOLFO IBÁÑEZ

Resumen

Facultad de Ingeniería y Ciencias

Master of Science in Data Science,
Ingeniería Civil Informática e
Ingeniería Civil Industrial

Aumentación de Datos con LLMs: Filtrado Geométrico para Clasificación de Texto

por Benjamín Schindler

La clasificación de texto en escenarios de recursos limitados enfrenta un desafío fundamental: la escasez de datos etiquetados impide que los clasificadores aprendan fronteras de decisión robustas, especialmente en problemas multiclase. Los modelos de lenguaje de gran escala (LLMs) pueden generar texto sintético para aumentar los datos de entrenamiento, pero no todas las muestras generadas son igualmente útiles. Algunas se ubican en regiones del espacio de embeddings que no corresponden a la clase objetivo, mientras que otras carecen de diversidad suficiente.

Esta tesis propone un sistema de filtrado geométrico que evalúa las muestras sintéticas generadas por LLMs según su posición en el espacio de embeddings. El sistema implementa múltiples filtros basados en distancia euclidiana, densidad local y coherencia con la distribución de datos reales. Adicionalmente, se introduce un mecanismo de ponderación suave que utiliza las puntuaciones del filtro como pesos de muestra en el clasificador, asignando mayor importancia a las muestras de mayor calidad geométrica.

La evaluación experimental abarca 3,675 configuraciones sobre 7 conjuntos de datos de clasificación, 5 clasificadores, 7 métodos de aumentación y 5 semillas. El método propuesto obtiene +2.25 puntos porcentuales sobre SMOTE ($p < 0.0001$, d de Cohen $= 0.74$, tasa de victoria 83.8 %), superando también a 9 líneas base incluyendo técnicas modernas como paráfrasis con T5 y aumentación contextual con BERT. La extensión a reconocimiento de entidades nombradas confirma la generalización del enfoque, con +9.61 puntos porcentuales sobre la línea base.

Un hallazgo central es que los filtros simples basados únicamente en distancia superan a los filtros complejos multi-criterio, y que las ganancias son mayores en escenarios de máxima escasez (10 ejemplos por clase: +4.52pp).

Palabras clave: clasificación de texto, aumentación de datos, modelos de lenguaje, filtrado geométrico, embeddings, SMOTE, pocos ejemplos.

UNIVERSIDAD ADOLFO IBÁÑEZ

Abstract

Faculty of Engineering and Sciences

Master of Science in Data Science

Data Augmentation with LLMs: Geometric Filtering for Text Classification

by Benjamín Schindler

Text classification in low-resource scenarios faces a fundamental challenge: the scarcity of labeled data prevents classifiers from learning robust decision boundaries, especially in multi-class problems. Large language models (LLMs) can generate synthetic text to augment training data, but not all generated samples are equally useful. Some fall in embedding space regions that do not correspond to the target class, while others lack sufficient diversity.

This thesis proposes a geometric filtering system that evaluates LLM-generated synthetic samples based on their position in the embedding space. The system implements multiple filters based on Euclidean distance, local density, and coherence with the real data distribution. Additionally, a soft weighting mechanism is introduced that uses filter scores as sample weights in the classifier, assigning greater importance to samples of higher geometric quality.

The experimental evaluation spans 3,675 configurations across 7 classification datasets, 5 classifiers, 7 augmentation methods, and 5 seeds. The proposed method achieves +2.25 percentage points over SMOTE ($p < 0.0001$, Cohen's $d = 0.74$, win rate 83.8 %), also outperforming 9 baselines including modern techniques such as T5 paraphrasing and contextual BERT augmentation. The extension to named entity recognition confirms the generalization of the approach, with +9.61 percentage points over baseline.

A central finding is that simple distance-based filters outperform complex multi-criteria filters, and that gains are largest in maximum scarcity scenarios (10 examples per class: +4.52pp).

Keywords: text classification, data augmentation, language models, geometric filtering, embeddings, SMOTE, few-shot.

Reconocimientos

Agradezco profundamente a mi familia, a mi pareja y a mis amigos por su apoyo incondicional durante este proceso. Su paciencia, motivación y compañía fueron fundamentales para llevar a cabo esta investigación.

También agradezco el financiamiento de: ANID FONDECYT 1230315, ANID-MILENIO-NCN2024_103; y CMM FB210005, correspondientes a fondos BASAL para centros de excelencia de ANID-Chile.

Índice general

Resumen I

Abstract II

Reconocimientos III

1. Introducción 1

2. Definición del Problema 3
   2.1. El Problema de la Escasez de Datos Etiquetados 3
   2.2. Limitaciones de las Soluciones Existentes 3
      2.2.1. Deficiencia 1: Ausencia de Validación Post-Generación 4
      2.2.2. Deficiencia 2: Ponderación Uniforme de Muestras Sintéticas . . 4
      2.2.3. Deficiencia 3: Falta de Validación Multi-Tarea y Multi-Dominio 4
   2.3. Oportunidad de Investigación 5

3. Estado del Arte 6
   3.1. El Desbalance de Clases como Barrera Metodológica 6
   3.2. Sobremuestreo Geométrico Clásico 6
   3.3. Sobremuestreo en Espacios de Características Profundas 7
   3.4. Generación Completa con Modelos de Lenguaje de Gran Escala 7
   3.5. Metodologías Híbridas Emergentes 8
   3.6. Limitaciones del Estado Actual y Posicionamiento 10

4. Hipótesis y Objetivos 11
   4.1. Hipótesis Principal 11
   4.2. Hipótesis Secundarias 11
   4.3. Objetivo General 12
   4.4. Objetivos Específicos 12
   4.5. Métricas de Evaluación 13
   4.6. Criterios de Aceptación 13

5. Metodología 14
   5.1. Conjuntos de Datos 14
      5.1.1. Conjuntos de Clasificación de Texto 15
      5.1.2. Conjuntos Adicionales para Análisis de Escalabilidad 15
      5.1.3. Conjuntos de Reconocimiento de Entidades Nombradas 15
   5.2. Modelo de Embeddings 15
   5.3. Generación con Modelo de Lenguaje 16
   5.4. Filtros Geométricos 16
      5.4.1. Filtro LOF (Local Outlier Factor) 17
      5.4.2. Cascada de Filtros 17
      5.4.3. Filtro Combinado 18

5.4.4. Muestreador Guiado por Embeddings 18
5.4.5. Sin Filtro (Control) 18
5.5. Ponderación Suave 18
5.6. Métodos de Línea Base 19
5.7. Clasificadores 20
5.8. Protocolo de Evaluación Estadística 20
5.9. Adaptación para Reconocimiento de Entidades Nombradas 21
5.10. Diseño Experimental 21

6. Resultados 23
6.1. Comparación Principal de Métodos 23
6.2. Comparación con Líneas Base Modernas 24
6.3. Análisis por Número de Ejemplos por Clase 26
6.4. Análisis por Clasificador 27
6.5. Estudios de Ablación 30
6.6. Análisis Teórico del Efecto de Complejidad del Filtro 30
6.6.1. Correlación entre métricas en espacios normalizados 31
6.6.2. Reducción de diversidad por intersección restrictiva 31
6.6.3. Inestabilidad de LOF en régimen de pocos ejemplos 31
6.7. Análisis por Clase Individual 32
6.8. Efecto del Número de Clases 33
6.9. Extensión a Reconocimiento de Entidades Nombradas 34
6.10. Robustez del Modelo de Embeddings 35
6.11. Aprendizaje Curricular con Scores Geométricos 37
6.12. Estadísticas Geométricas del Filtrado 39
6.13. Visualización del Espacio de Embeddings 40
6.14. Robustez respecto al Modelo de Lenguaje 44
6.14.1. Rechazos por Filtros de Contenido 44
6.14.2. Resultados Ajustados por Rechazo 44

7. Conclusiones 46
7.1. Síntesis de Resultados 46
7.2. Validación de Hipótesis 47
7.3. Contribuciones 48
7.4. Hallazgos Contraintuitivos 49
7.5. Limitaciones 50
7.6. Trabajo Futuro 52
Referencias 53

A. Validaciones Metodológicas 56
A.1. Validación de la Implementación de SMOTE 56
A.2. Análisis de Asimetría de Semillas 57

B. Experimentos Complementarios 58
B.1. Mejora Iterativa de Prompts 58
B.2. Filtrado Geométrico vs. Filtrado Basado en Modelo 59
B.3. Aumentación Híbrida Adaptativa por Clase 60

Capítulo 1

Introducción

La clasificación de texto en escenarios de recursos limitados constituye uno de los desafíos centrales del procesamiento de lenguaje natural contemporáneo. Numerosas aplicaciones prácticas, desde la detección de discurso de odio hasta la clasificación de noticias o el filtrado de correo no deseado, requieren modelos supervisados que dependen de datos etiquetados para su entrenamiento. No obstante, la obtención de estos datos resulta costosa en tiempo y recursos humanos. En muchos dominios especializados, el investigador dispone de apenas 10 a 50 ejemplos por clase, una cantidad insuficiente para que los algoritmos tradicionales aprendan fronteras de decisión robustas.

Esta escasez se agrava cuando el problema involucra múltiples clases. Cada categoría necesita una masa crítica independiente de ejemplos para que el modelo capture sus patrones distintivos. Cuando el número de muestras por clase es reducido, los clasificadores tienden a converger hacia estrategias que favorecen las clases con mayor representación. La consecuencia directa es una degradación pronunciada de la métrica macro F1, que pondera equitativamente el rendimiento sobre cada clase sin importar su frecuencia relativa (Gopali, Abri, Namin, y Jones, 2024).

Frente a este problema, la comunidad ha desarrollado dos paradigmas principales de aumentación de datos. El primero corresponde al sobremuestreo clásico, representado por técnicas como SMOTE (Chawla, Bowyer, Hall, y Kegelmeyer, 2002) y ADASYN (He, Bai, Garcia, y Li, 2008), que generan muestras sintéticas mediante interpolación de vectores en el espacio de embeddings (representaciones vectoriales densas). Estas técnicas ofrecen guía geométrica explícita sobre dónde ubicar las nuevas muestras, pero los vectores interpolados no siempre corresponden a textos lingüísticamente coherentes. El segundo paradigma recurre a modelos de lenguaje de gran escala (LLMs) para generar texto directamente. Los LLMs producen oraciones gramaticalmente correctas y semánticamente plausibles (Whitehouse, Choudhury, y Aji, 2023), pero carecen de información sobre la estructura geométrica del espacio de representación donde operan los clasificadores. El Capítulo 3 presenta una revisión detallada de ambos enfoques y sus variantes recientes.

La generación con LLMs produce muestras de calidad heterogénea. Algunas se ubican en regiones del espacio de embeddings que corresponden fielmente a la clase objetivo, mientras que otras caen en zonas periféricas o incluso en regiones asociadas a otras clases. Incorporar indiscriminadamente todas las muestras generadas puede degradar el rendimiento del clasificador en lugar de mejorarlo. Esta observación motiva la pregunta central de esta investigación: ¿es posible mejorar la aumentación con LLMs mediante un filtrado geométrico que seleccione únicamente las muestras sintéticas de alta calidad?

Esta tesis propone un sistema de filtrado geométrico post-generación que evalúa cada muestra sintética según su posición en el espacio de embeddings. La investigación realiza cuatro contribuciones principales. En primer lugar, se diseña e implementa un conjunto de filtros geométricos que operan sobre propiedades como la distancia euclidiana, la densidad local y la coherencia con la distribución de datos reales. En segundo lugar, se introduce un mecanismo de ponderación suave que utiliza las puntuaciones del filtro como pesos de muestra en el clasificador, superando la decisión binaria tradicional de aceptar o rechazar. En tercer lugar, se demuestra que estos filtros generalizan a través de tareas distintas, funcionando tanto para clasificación de texto como para reconocimiento de entidades nombradas sin modificación alguna. Finalmente, se establece un hallazgo empírico relevante para la comunidad: los filtros más simples, basados únicamente en distancia euclidiana, superan consistentemente a los filtros complejos multi-criterio.

El resto de este documento se organiza de la siguiente manera. El Capítulo 2 define formalmente el problema de investigación y las brechas identificadas en la literatura. El Capítulo 3 revisa el estado del arte en aumentación de datos para clasificación de texto. El Capítulo 4 presenta las hipótesis y objetivos que guían la investigación. El Capítulo 5 describe la metodología experimental, incluyendo los conjuntos de datos, filtros geométricos, clasificadores y protocolo estadístico. El Capítulo 6 presenta los resultados experimentales obtenidos a partir de más de 6,000 configuraciones evaluadas. Finalmente, el Capítulo 7 sintetiza las conclusiones, discute las limitaciones y propone direcciones de trabajo futuro.

Capítulo 2

Definición del Problema

2.1. El Problema de la Escasez de Datos Etiquetados

La clasificación supervisada de texto requiere ejemplos etiquetados en cantidad suficiente para que el modelo aprenda los patrones distintivos de cada clase. En la práctica, muchas tareas disponen de conjuntos de entrenamiento extremadamente reducidos. Un investigador que desea construir un detector de discurso de odio para una plataforma nueva, o un clasificador de intenciones para un dominio especializado, puede contar con apenas 10 a 50 ejemplos etiquetados por categoría. Esta situación, denominada escenario de pocos ejemplos, impide que los algoritmos de aprendizaje estadístico estimen con precisión las fronteras de decisión entre clases.

La degradación del rendimiento es especialmente severa en problemas multiclase. Cuando el espacio de categorías se amplía, cada clase necesita masa crítica independiente para que el modelo capture sus características. Con 10 ejemplos por clase y 6 categorías, el conjunto de entrenamiento completo contiene apenas 60 muestras, una cifra que resulta insuficiente para la mayoría de los algoritmos. Los clasificadores entrenados bajo estas condiciones convergen hacia estrategias que favorecen las clases mejor representadas, produciendo una caída pronunciada en la métrica macro F1 (Gopali y cols., 2024). Esta métrica, al ponderar equitativamente el rendimiento de cada clase, refleja con fidelidad la incapacidad del modelo para tratar adecuadamente las categorías con menos ejemplos.

El problema no se limita a un dominio particular. Conjuntos de datos ampliamente utilizados en la comunidad, como Stanford Sentiment Treebank 2, AG News, 20 Newsgroups y conjuntos de detección de spam, presentan distribuciones desiguales entre sus clases (Whitehouse y cols., 2023). La escasez de datos etiquetados y el desbalance entre categorías constituyen así un obstáculo transversal que afecta a múltiples áreas del procesamiento de lenguaje natural.

2.2. Limitaciones de las Soluciones Existentes

La comunidad ha propuesto diversas estrategias de aumentación de datos para mitigar la escasez, pero cada una presenta limitaciones que restringen su efectividad. A continuación se identifican tres deficiencias críticas en los enfoques actuales que motivan esta investigación.

2.2.1. Deficiencia 1: Ausencia de Validación Post-Generación

Los métodos actuales que utilizan LLMs para aumentación de datos aceptan todas las muestras generadas sin evaluar su calidad en el espacio de representación. Un LLM puede producir una oración gramaticalmente correcta que, al ser proyectada al espacio de embeddings, se ubique en una región que corresponde a una clase diferente de la solicitada. De manera análoga, el modelo puede generar texto que cae en zonas periféricas del espacio, alejadas de la distribución real de la clase objetivo.

Esta ausencia de control de calidad geométrico permite que muestras defectuosas contaminen el conjunto de entrenamiento. SMOTExT, por ejemplo, genera texto correspondiente a puntos interpolados en el espacio de embeddings, pero no verifica si el texto producido mantiene coherencia semántica con su ubicación geométrica pretendida (Bystroński, Hołysz, Piotrowski, Chawla, y Kajdanowicz, 2025). La literatura carece de protocolos estandarizados para cuantificar y filtrar estas inconsistencias antes de incorporar las muestras al entrenamiento.

2.2.2. Deficiencia 2: Ponderación Uniforme de Muestras Sintéticas

Los métodos existentes asignan peso idéntico a todas las muestras sintéticas durante el entrenamiento del clasificador. Esta práctica ignora información geométrica disponible que podría mejorar la calidad del aprendizaje. Una muestra sintética ubicada en una región densa del espacio de embeddings, rodeada de múltiples ejemplos reales de su clase, posee mayor probabilidad de ser representativa y confiable. En contraste, una muestra ubicada en una zona dispersa, con pocos vecinos de la misma clase, podría corresponder a un caso atípico o a un error de generación.

Asignar peso uniforme a ambas muestras desaprovecha la señal que proporciona el contexto geométrico local. La información sobre la densidad del vecindario, la distancia a los ejemplos reales más cercanos y la proporción de vecinos de la misma clase constituyen indicadores de calidad que los métodos actuales no explotan. ImbLLM reconoce implícitamente este problema al enfatizar la diversidad durante la generación (Nguyen y cols., 2024), pero no implementa esquemas de ponderación adaptativa basados en métricas geométricas locales.

2.2.3. Deficiencia 3: Falta de Validación Multi-Tarea y Multi-Dominio

La mayoría de los estudios que evalúan la aumentación con LLMs se limitan a un solo conjunto de datos o a un único tipo de tarea. Los resultados obtenidos en un corpus particular no garantizan que el método funcione en otros dominios textuales con características diferentes. Esta falta de validación cruzada impide determinar si las ganancias observadas son genuinamente atribuibles al método propuesto o si dependen de particularidades del conjunto de datos empleado.

La carencia es aún más pronunciada cuando se considera la generalización entre tareas. Un mecanismo de control de calidad diseñado para clasificación de texto podría no funcionar para reconocimiento de entidades nombradas, generación de preguntas u otras tareas de procesamiento de lenguaje natural. Hasta la fecha, no se ha demostrado que los filtros de calidad basados en propiedades geométricas del espacio de embeddings mantengan su efectividad a través de tareas y dominios distintos.

2.3. Oportunidad de Investigación

Las deficiencias identificadas revelan una oportunidad en la intersección de tres dimensiones metodológicas. La primera dimensión consiste en integrar mecanismos de validación post-generación que evalúen cada muestra sintética según su posición en el espacio de embeddings, filtrando aquellas que no satisfacen criterios geométricos de calidad. La segunda dimensión propone desarrollar esquemas de ponderación adaptativa que asignen a cada muestra un peso proporcional a su calidad geométrica, en lugar de la decisión binaria de aceptar o rechazar. La tercera dimensión busca demostrar que estos mecanismos de control de calidad generalizan a través de múltiples conjuntos de datos y tareas del procesamiento de lenguaje natural.

Esta tesis aborda sistemáticamente estas tres dimensiones. El sistema propuesto implementa filtros geométricos que operan sobre el espacio de embeddings, un mecanismo de ponderación suave basado en las puntuaciones de dichos filtros, y una validación experimental que abarca 7 dominios textuales y 2 tareas distintas (clasificación y reconocimiento de entidades nombradas). El diseño enfatiza la eficiencia operacional, utilizando LLMs pre-entrenados sin requerir fine-tuning, lo que facilita su aplicación en entornos con recursos computacionales limitados.

Capítulo 3

Estado del Arte

3.1. El Desbalance de Clases como Barrera Metodológica

El desequilibrio de clases representa un desafío fundamental para la validez de los modelos de clasificación de texto. Este problema se manifiesta de manera consistente en conjuntos de datos ampliamente utilizados, donde la clase mayoritaria puede superar el 60 % de las muestras. Corpora de referencia como Stanford Sentiment Treebank 2, AG News y Coursera Reviews exhiben distribuciones desiguales que provocan caídas pronunciadas en el macro F1 y degradación generalizada del rendimiento (Gopali y cols., 2024).

El fenómeno trasciende barreras lingüísticas y dominios específicos. La subrepresentación de clases minoritarias conduce sistemáticamente a predicciones inexactas para las categorías menos frecuentes (Whitehouse y cols., 2023). La problemática no se limita a métricas de exactitud global. Compromete la utilidad práctica de los sistemas al enmascarar su incapacidad para identificar patrones en categorías minoritarias. Durante más de una década, este desequilibrio ha constituido una barrera reconocida por la comunidad, motivando el desarrollo de cuatro corrientes metodológicas principales (Gopali y cols., 2024).

3.2. Sobremuestreo Geométrico Clásico

El sobremuestreo geométrico constituye el enfoque más establecido para mitigar el desbalance. Feng et al. proporcionaron una taxonomía comprehensiva de las aproximaciones de aumentación para PLN, clasificando los métodos en cuatro familias: transformaciones a nivel de token, paráfrasis, perturbaciones en el espacio de características y generación completa (Feng y cols., 2021). Dentro de la primera familia, SMOTE (Chawla y cols., 2002) y ADASYN (He y cols., 2008) generan muestras sintéticas mediante interpolación lineal en espacios vectoriales. Estudios recientes han documentado mejoras significativas en F1 cuando SMOTE se aplica sobre embeddings de modelos transformer como BERT (Cloutier y Japkowicz, 2023). La aplicación de SMOTE sobre vectores MiniLM produjo mejoras del 17 % al 20 % en exhaustividad, particularmente beneficiosas para clases minoritarias (Taskiran, Turkoglu, Kaya, y Asuroglu, 2025).

No obstante, los vectores interpolados carecen de correspondencia garantizada con texto lingüísticamente coherente. Un vector sintético $\mathbf{v}_{synth} = \alpha\mathbf{v}_1 + (1-\alpha)\mathbf{v}_2$ es matemáticamente válido, pero puede no representar ninguna oración natural en el idioma. Esta desconexión entre el espacio vectorial y el espacio textual limita la

interpretabilidad de las muestras generadas. Las estrategias complementarias de submuestreo, como el submuestreo aleatorio, reducen el sesgo hacia la clase mayoritaria pero descartan información potencialmente valiosa.

Junto a SMOTE, la comunidad ha desarrollado métodos de aumentación textual que operan directamente sobre el texto. EDA (Easy Data Augmentation) aplica operaciones simples como sustitución de sinónimos, inserción aleatoria, intercambio y eliminación de palabras (Wei y Zou, 2019). La traducción inversa genera variaciones traduciendo el texto a otro idioma y de vuelta al original. Estos métodos preservan la coherencia lingüística pero producen variaciones superficiales que no siempre aportan diversidad genuina al espacio de representación.

3.3. Sobremuestreo en Espacios de Características Profundas

El segundo paradigma aplica variantes de SMOTE directamente sobre representaciones contextualizadas de modelos transformer, sin decodificación a texto (Alshehri, Alsahfi, y Altammami, 2025). Los resultados en clasificación binaria (IMDB, SST-2) y multiclase (AG News) demostraron que modelos aumentados superaron consistentemente a las líneas base sin aumentación. Las mejoras fueron particularmente pronunciadas cuando el tamaño de la clase minoritaria es extremadamente reducido.

Visualizaciones mediante UMAP y t-SNE confirmaron que las muestras sintéticas llenan efectivamente las regiones de la clase minoritaria manteniendo estructura de conglomerado y coherencia semántica. La contribución conceptual de este enfoque radica en demostrar que las técnicas de sobremuestreo, cuando se aplican a embeddings semánticos en lugar de características crudas, mantienen su efectividad para tareas de procesamiento de lenguaje natural. A diferencia de métodos que decodifican vectores a texto, este paradigma opera exclusivamente en el espacio de embeddings, sacrificando interpretabilidad a cambio de eficiencia computacional.

Técnicas más recientes como el mixup (interpolación de representaciones) en embeddings extienden este principio. Chen et al. propusieron MixText, que realiza interpolación en el espacio oculto de modelos transformer combinando ejemplos etiquetados y no etiquetados, logrando mejoras significativas en clasificación semi-supervisada con pocos ejemplos (Chen, Yang, y Yang, 2020). El mixup genera muestras sintéticas mediante interpolación convexa de pares de embeddings de la misma clase, produciendo representaciones intermedias que densifican el espacio de entrenamiento. Estas técnicas comparten con SMOTE la limitación de no generar texto interpretable.

3.4. Generación Completa con Modelos de Lenguaje de Gran Escala

El tercer paradigma aprovecha la capacidad de los LLMs para generar texto completo, gramaticalmente correcto y contextualmente coherente. La investigación de Suhaeni y Yong documentó que las reseñas sintéticas generadas por GPT-3 produjeron incrementos de 12.7 % en exactitud media y hasta 13 puntos porcentuales en macro F1 sobre el corpus Coursera Reviews (Suhaeni y Yong, 2023). Este resultado estableció un punto de referencia que motivó investigación subsecuente en múltiples dominios.

Las comparaciones directas entre LLMs y sobremuestreo geométrico han revelado ventajas sistemáticas del primer enfoque. Gopali et al. alcanzaron F1 de 0.76 utilizando GPT-3.5-Turbo, contrastando favorablemente con valores de 0.60 obtenidos mediante

combinaciones de SMOTE y Edited Nearest Neighbors (Gopali y cols., 2024). Cloutier y Japkowicz demostraron que el sobremuestreo mediante LLMs generativos con fine-tuning (ajuste fino del modelo preentrenado) generalmente supera métodos de remuestreo tradicionales en clasificación multiclase desbalanceada (Cloutier y Japkowicz, 2023). Whitehouse et al. reportaron mejoras de hasta 13.4 % en exactitud para tareas con datos de entrenamiento limitados (Whitehouse y cols., 2023).

Dai et al. mostraron ganancias consistentes mediante paráfrasis con ChatGPT, pero identificaron una tensión inherente entre fidelidad semántica y diversidad de las muestras generadas (Dai y cols., 2023). Cegin et al. realizaron la comparación más exhaustiva hasta la fecha entre LLMs y métodos clásicos, concluyendo que los LLMs superan a las técnicas establecidas principalmente en escenarios con muy pocos ejemplos semilla, mientras que con más datos los métodos clásicos igualan o superan a los LLMs a una fracción del costo computacional (Cegin, Simko, y Brusilovsky, 2025).

La efectividad de la generación con LLMs depende críticamente de los ejemplos proporcionados en el prompt. Liu et al. demostraron que la selección de ejemplos in-context basada en similitud semántica produce mejoras significativas respecto a la selección aleatoria (J. Liu y cols., 2022). Min et al. revelaron que el formato y la distribución de etiquetas de los ejemplos importan más que la corrección de las etiquetas mismas (Min y cols., 2022). Dong et al. proporcionaron una taxonomía comprehensiva del aprendizaje in-context, identificando factores clave que determinan su efectividad (Dong y cols., 2024). Estos hallazgos sugieren que la calidad de los prompts utilizados para la generación de datos sintéticos constituye un factor determinante que la literatura de aumentación aún no ha abordado sistemáticamente.

A pesar de estos avances, el paradigma enfrenta limitaciones significativas. Los LLMs tienden a producir datos con mayor homogeneidad intra-clase, con incrementos del 14.51 % al 27.11 % en similitud entre muestras generadas ("How Good Is Synthetic Data for Social Media Texts?", 2024). La subjetividad a nivel de tarea e instancia se correlaciona negativamente con el rendimiento (Li, Zhu, Lu, y Yin, 2023). La ventaja sobre métodos clásicos resulta menos pronunciada en clasificación binaria.

Técnicas más recientes como la paráfrasis con T5 y la aumentación contextual con BERT representan variantes de este paradigma. La paráfrasis con T5 utiliza un modelo secuencia-a-secuencia para generar reformulaciones de los ejemplos existentes. La aumentación contextual con BERT sustituye tokens mediante las predicciones del modelo enmascarado, preservando el contexto semántico de la oración. Estas técnicas ofrecen mayor control sobre la fidelidad semántica, aunque a costa de menor diversidad que la generación abierta con LLMs de mayor escala.

3.5. Metodologías Híbridas Emergentes

La convergencia de técnicas clásicas con capacidades generativas de LLMs ha emergido como paradigma dominante en la investigación reciente. El principio rector es que SMOTE identifica regiones subrepresentadas en el espacio de embeddings, mientras los LLMs generan texto coherente para poblar dichas regiones.

Diversas implementaciones han explorado esta complementariedad. LLMOverTab demostró que la combinación de generación textual con ajuste de densidad mediante SMOTE logra incrementos de 3 % en macro F1 frente a cada técnica por separado (Isomura, Shimizu, y Goto, 2025). SentiGEN combina T5 con un algoritmo genético y un validador basado en XLNet, permitiendo que clasificadores entrenados solo

con datos sintéticos superen a aquellos entrenados con datos reales (Sundararajan y Kumarapathirage, 2023). AugmenToxic utiliza aprendizaje por refuerzo con retroalimentación humana para guiar la generación hacia ejemplos difíciles de clasificar (Bodaghi, Murthy, Kazerooni, y Caliskan, 2024). LLM-AutoDA implementa un ciclo continuo de generación y retroalimentación que supera métodos estáticos en conjuntos de datos con distribuciones de cola larga (Wang, Zou, y Lui, 2023).

SMOTExT implementa interpolación SMOTE entre embeddings de alta dimensionalidad seguida de decodificación mediante xRAG-7B (Bystroński y cols., 2025). El hallazgo notable es que entrenar exclusivamente con datos sintéticos logró apenas 3.2 % de degradación respecto a la línea base con datos reales. ImbLLM introdujo estrategias de maximización de diversidad mediante fine-tuning exclusivamente sobre muestras minoritarias, alcanzando F1 superiores a 0.8 en conjuntos de datos tabulares (Nguyen y cols., 2024).

La literatura sobre detección de anomalías y control de calidad de datos ofrece herramientas relevantes para este contexto. El algoritmo Local Outlier Factor (LOF) (Breunig, Kriegel, Ng, y Sander, 2000) evalúa la densidad local de cada punto respecto a sus vecinos, identificando muestras que se desvían de la distribución esperada. Aplicado al filtrado de muestras sintéticas, LOF permite detectar aquellas que caen en regiones de baja densidad del espacio de embeddings, indicando posibles errores de generación. Esta conexión entre la detección de anomalías y el control de calidad de datos generados por LLMs constituye un fundamento teórico para el sistema de filtrado propuesto en esta tesis.

La incorporación indiscriminada de datos sintéticos puede provocar el denominado colapso del modelo, donde las colas de la distribución original desaparecen irreversiblemente tras el entrenamiento recursivo con datos generados (Shumailov y cols., 2023). Investigaciones recientes en poda de datos han demostrado que la calidad de la representación subyacente determina más el resultado que la complejidad del algoritmo de selección, lo que sugiere que un espacio de embeddings de alta calidad con un filtro simple puede ser preferible a esquemas multi-criterio elaborados (Du y cols., 2025). Yu et al. demostraron en R.I.P. que el filtrado agresivo de datos de entrenamiento, descartando hasta el 90 % de las muestras menos informativas, puede mejorar el rendimiento de los modelos, un principio que se extiende naturalmente al contexto de datos sintéticos generados por LLMs (Yu, Zhuang, Zhang, Socher, y Xiong, 2025). Liu et al. propusieron el Residual Alignment Model, que formaliza la selección de datos aumentados como un problema de muestreo por importancia, ponderando cada muestra según su alineación con la distribución residual del error del modelo (Z. Liu, Tang, Wang, y Li, 2025). Springer et al. examinaron sistemáticamente la influencia de datos sintéticos generados por LLMs en clasificación de texto con pocos ejemplos, concluyendo que la calidad de la selección post-generación es determinante y que los protocolos de evaluación deben ser rigurosos para evitar conclusiones infladas (Springer, Devoto, Tosheva, y Ramesh, 2025). Piedboeuf y Langlais formalizaron protocolos de evaluación para aumentación de datos con pocos recursos, identificando sesgos metodológicos comunes que pueden inflar artificialmente las ganancias reportadas (Piedboeuf y Langlais, 2024). En el ámbito del reconocimiento de entidades nombradas, Zhou et al. propusieron MELM, que modela entidades enmascaradas condicionadas en sus etiquetas, estableciendo el método de referencia para aumentación en NER con recursos limitados (Zhou y cols., 2022).

De manera complementaria, la teoría del muestreo por importancia proporciona un marco formal para la ponderación de muestras sintéticas. En lugar de asignar peso

uniforme, el muestreo por importancia pondera cada muestra según la razón entre la distribución objetivo y la distribución de generación (Tokdar y Kass, 2010). Cuando las puntuaciones de un filtro geométrico se utilizan como pesos de muestra, el clasificador puede aprender con mayor eficiencia al enfocarse en las muestras de mayor calidad. Este principio tiene raíces formales en la teoría estadística del muestreo por importancia, que establece las condiciones bajo las cuales la ponderación no uniforme reduce la varianza del estimador.

3.6. Limitaciones del Estado Actual y Posicionamiento

La hipótesis de la variedad, según la cual los datos de alta dimensionalidad se concentran cerca de variedades de baja dimensión (Bengio, Courville, y Vincent, 2013; Fefferman, Mitter, y Narayanan, 2016), fundamenta teóricamente el uso de métricas geométricas para evaluar la calidad de muestras sintéticas. Sin embargo, Robinson et al. demostraron que los embeddings de tokens en LLMs violan esta hipótesis, exhibiendo singularidades que desestabilizan métricas basadas en densidad local fina como LOF, mientras que la distancia euclidiana actúa como métrica de primer orden más robusta ante estas irregularidades topológicas (Robinson, Dey, y Chiang, 2025). Complementariamente, análisis recientes de métricas de similitud han evidenciado que la similitud coseno sufre concentración de la medida en altas dimensiones, perdiendo poder discriminativo frente a métricas basadas en distancia euclidiana (Tessari y Hogan, 2024). Estos hallazgos, combinados con la evidencia de Du et al. de que la calidad de la representación determina más el resultado que la complejidad del algoritmo de selección (Du y cols., 2025), sugieren que en espacios de embeddings normalizados de alta dimensión, la distancia euclidiana debería ser suficiente como criterio único de selección, una predicción que los resultados experimentales de esta investigación confirman (Sección 6.6).

El análisis de la literatura revela tres limitaciones fundamentales en los enfoques existentes, que se corresponden con las deficiencias identificadas en el Capítulo 2. La primera es la ausencia de mecanismos cuantitativos de validación post-generación basados en propiedades geométricas del espacio de embeddings. La segunda es el uso de ponderación uniforme durante el entrenamiento, que ignora la información sobre la calidad geométrica de cada muestra sintética. La tercera es la evaluación limitada a un solo conjunto de datos o tarea, sin demostración de generalización multi-dominio y multi-tarea.

Esta investigación se posiciona en la intersección de estas tres limitaciones. A diferencia de los enfoques híbridos que integran SMOTE con LLMs para guiar la generación, el sistema propuesto desacopla la generación del filtrado. El LLM genera muestras libremente, y un sistema de filtros geométricos evalúa cada muestra según su posición en el espacio de embeddings. Este desacoplamiento ofrece mayor flexibilidad, ya que los filtros pueden aplicarse independientemente del LLM utilizado y sin requerir fine-tuning del modelo generativo. La validación experimental abarca 10 conjuntos de datos de 7 dominios distintos y 2 tareas (clasificación de texto y reconocimiento de entidades nombradas), proporcionando la evaluación multi-dominio y multi-tarea más amplia disponible en la literatura para este tipo de sistema.

Capítulo 4

Hipótesis y Objetivos

Las deficiencias metodológicas identificadas en el Capítulo 2 (ausencia de validación post-generación, ponderación uniforme de muestras sintéticas, y falta de validación multi-tarea) motivan el planteamiento de hipótesis específicas y objetivos de investigación que guían el diseño experimental de esta tesis.

4.1. Hipótesis Principal

La hipótesis central de esta investigación se formula como sigue.

H1: El filtrado geométrico de muestras de texto generadas por modelos de lenguaje de gran escala en el espacio de embeddings produce mejoras estadísticamente significativas en macro F1 respecto a SMOTE y otros métodos de aumentación, en escenarios de clasificación de texto con pocos ejemplos por clase.

Esta hipótesis propone que la calidad de las muestras sintéticas puede evaluarse mediante su posición en el espacio de representación vectorial. Una muestra generada por un LLM que se ubica en una región consistente con la distribución real de su clase aporta mayor valor al clasificador que una muestra periférica o ambigua. El filtrado geométrico actúa como mecanismo de control de calidad que selecciona las muestras más informativas, descartando aquellas que podrían confundir las fronteras de decisión del clasificador.

4.2. Hipótesis Secundarias

Las siguientes hipótesis secundarias descomponen la hipótesis principal en componentes verificables de manera independiente.

H1a (Filtrado): El filtrado geométrico basado en distancia mejora la calidad de las muestras sintéticas respecto a la incorporación sin filtrado. Esta hipótesis evalúa si la selección de candidatos mediante su proximidad euclidiana a los ejemplos reales de la clase produce un conjunto de entrenamiento más efectivo. La métrica de evaluación es el impacto en macro F1 del clasificador entrenado con muestras filtradas frente al clasificador entrenado con muestras sin filtrar.

H1b (Ponderación suave): La ponderación continua basada en la puntuación del filtro geométrico iguala o supera al filtrado binario con peso uniforme. En lugar de la decisión discreta aceptar/rechazar, esta hipótesis propone que asignar pesos proporcionales a la calidad geométrica de cada muestra permite al clasificador aprovechar información gradual sobre la confiabilidad de cada ejemplo sintético. Las muestras de mayor calidad geométrica merecen mayor contribución al entrenamiento.

H1c (Generalización entre tareas): El filtrado geométrico generaliza a través de tareas de procesamiento de lenguaje natural. Los mismos filtros diseñados para clasificación de texto mejoran también el reconocimiento de entidades nombradas, sin modificación alguna. Esta hipótesis evalúa si las propiedades geométricas del espacio de embeddings capturan características de calidad que son agnósticas a la tarea específica.

H1d (Efecto del clasificador): La elección del clasificador modula significativamente el beneficio de la aumentación filtrada. Los clasificadores lineales aprovechan las muestras filtradas de manera más efectiva que los ensambles de árboles. Esta hipótesis aborda la interacción entre el tipo de modelo supervisado y la calidad del aumento de datos, evaluando si los beneficios del filtrado geométrico dependen de la arquitectura del clasificador.

4.3. Objetivo General

El objetivo general de esta investigación es desarrollar, implementar y validar experimentalmente un sistema de filtrado geométrico para muestras de texto generadas por modelos de lenguaje de gran escala, que mejore el rendimiento de clasificadores de texto en escenarios de pocos ejemplos por clase. El sistema debe operar exclusivamente en el espacio de embeddings, de manera desacoplada del modelo generativo, permitiendo su aplicación independientemente del LLM utilizado.

4.4. Objetivos Específicos

Esta investigación se articula en torno a tres objetivos específicos. El primero consiste en diseñar e implementar un sistema de filtrado geométrico con ponderación suave de muestras sintéticas en el espacio de embeddings. El segundo es comparar el sistema propuesto contra métodos clásicos y modernos de aumentación de datos sobre múltiples conjuntos de datos y clasificadores. El tercero es demostrar la generalización del filtrado a la tarea de reconocimiento de entidades nombradas (NER).

El primer objetivo integra dos componentes: un sistema de filtros geométricos multinivel basado en distancia, densidad local y coherencia con la distribución de clase, organizado en una arquitectura de cascada configurable; y un mecanismo de ponderación suave que utiliza las puntuaciones del filtro como pesos de muestra durante el entrenamiento, en lugar de la decisión binaria aceptar/rechazar.

El segundo objetivo evalúa el sistema frente a 9 métodos de aumentación, desde técnicas clásicas (SMOTE, sobremuestreo aleatorio, EDA, traducción inversa) hasta líneas base modernas (paráfrasis con T5, aumentación contextual con BERT, mixup en embeddings). La comparación abarca múltiples dominios textuales y se valida estadísticamente con múltiples semillas, corrección de Bonferroni, tamaños de efecto (d de Cohen) e intervalos de confianza al 95 %.

El tercer objetivo aplica los mismos filtros, sin modificación, a la selección de oraciones sintéticas para entrenamiento de modelos de NER, evaluando si las propiedades geométricas del espacio de embeddings capturan características de calidad agnósticas a la tarea.

4.5. Métricas de Evaluación

La métrica primaria de evaluación es el macro F1, que asigna peso unitario a cada clase independientemente de su frecuencia en el conjunto de datos. Esta elección refleja el objetivo de mejorar el rendimiento en clases minoritarias sin sacrificar el desempeño en las mayoritarias. El macro F1 promedia la puntuación F1 de cada clase, penalizando equitativamente los errores en todas las categorías.

Las métricas secundarias complementan la evaluación primaria desde múltiples perspectivas. El delta respecto a SMOTE (ΔF1) cuantifica la diferencia entre el macro F1 obtenido con el método evaluado y el obtenido con SMOTE, expresada en puntos porcentuales. Esta métrica permite comparaciones directas entre todos los métodos utilizando SMOTE como línea base común.

La significancia estadística se evalúa mediante prueba t pareada sobre los deltas observados, con corrección de Bonferroni para comparaciones múltiples. El intervalo de confianza al 95 % se calcula mediante bootstrap (remuestreo con reemplazo), proporcionando un rango que contiene la mejora verdadera con probabilidad del 95 %.

El tamaño de efecto se cuantifica mediante la d de Cohen, que normaliza la diferencia media por la desviación estándar combinada. Valores de 0.2 se interpretan como efectos pequeños, 0.5 como medianos y 0.8 como grandes. La tasa de victoria representa la fracción de configuraciones experimentales donde el método evaluado supera a SMOTE, proporcionando una medida de consistencia independiente de la magnitud de las diferencias.

4.6. Criterios de Aceptación

Una hipótesis se considera confirmada cuando la evidencia experimental satisface tres condiciones simultáneas. La primera es magnitud positiva: el delta promedio respecto a SMOTE debe ser mayor que cero. La segunda es significancia estadística: el valor p corregido por Bonferroni debe ser menor que 0.05. La tercera es consistencia: la tasa de victoria debe superar el 50 %, indicando que la mejora se manifiesta en la mayoría de las configuraciones evaluadas.

Una hipótesis se considera parcialmente confirmada cuando la magnitud y la consistencia son favorables pero la significancia estadística es marginal ($0.05 \leq p < 0.10$). Se considera rechazada cuando la mejora no alcanza significancia estadística o cuando la magnitud observada es negativa.

Capítulo 5

Metodología

Este capítulo describe el diseño experimental completo de la investigación. Se detallan los conjuntos de datos, el modelo de embeddings, el proceso de generación con LLM, los filtros geométricos implementados, el mecanismo de ponderación suave, los métodos de línea base, los clasificadores evaluados, el protocolo estadístico, la adaptación para reconocimiento de entidades nombradas, y la estructura de los experimentos realizados.

5.1. Conjuntos de Datos

La evaluación experimental se realiza sobre 13 conjuntos de datos que abarcan 9 dominios textuales distintos. La Tabla 5.1 presenta un resumen de todos los conjuntos utilizados.

Cuadro 5.1: Conjuntos de datos utilizados en la evaluación experimental

Conjunto de datos	Dominio	Clases	N-shots	Test
Clasificación de texto (experimento principal)				
sms_spam	Detección de spam	2	10, 25, 50	1,394
hate_speech_davidson	Discurso de odio	3	10, 25, 50	4,948
20newsgroups	Noticias (4 categorías)	4	10, 25, 50	7,532
ag_news	Noticias (4 categorías)	4	10, 25, 50	7,600
emotion	Emociones en texto	6	10, 25, 50	2,000
dbpedia14	Clasificación de temas	14	10, 25, 50	5,000
20newsgroups_20class	Noticias (20 categorías)	20	10, 25, 50	7,532
Conjuntos adicionales (análisis de escalabilidad)				
trec6	Preguntas	6	10, 25, 50	500
banking77	Intenciones bancarias	77	10, 25, 50	3,080
clinc150	Intenciones de diálogo	150	10, 25, 50	4,500
Reconocimiento de entidades nombradas (NER)				
MultiNERD	Entidades generales	5 tipos	10, 25, 50	10,000
WikiANN	Entidades Wikipedia	3 tipos	10, 25, 50	10,000
Few-NERD	Entidades detalladas	8 tipos	10, 25, 50	10,000

5.1.1. Conjuntos de Clasificación de Texto

Los 7 conjuntos principales de clasificación cubren un rango de 2 a 20 clases. El conjunto 20newsgroups contiene publicaciones de grupos de noticias organizadas en 4 categorías temáticas (ciencia, tecnología, política, religión). sms_spam es un problema binario de detección de mensajes no deseados en SMS. hate_speech_davidson clasifica publicaciones de redes sociales en 3 categorías: discurso de odio, lenguaje ofensivo y lenguaje neutro. ag_news agrupa noticias en 4 categorías (mundo, deportes, negocios, ciencia/tecnología). emotion clasifica textos según 6 emociones básicas (alegría, tristeza, ira, miedo, amor, sorpresa). dbpedia14 contiene descripciones de entidades de Wikipedia organizadas en 14 categorías ontológicas. 20newsgroups_20class utiliza las 20 categorías originales del corpus de grupos de noticias, proporcionando un escenario de alta granularidad.

Para simular escenarios de pocos ejemplos, se extraen 10, 25 o 50 muestras por clase del conjunto de entrenamiento original, manteniendo el conjunto de prueba completo intacto. Este procedimiento genera 21 configuraciones base (7 conjuntos de datos $\times$ 3 valores de n-shot, es decir, número de ejemplos por clase). La evaluación sobre el conjunto de prueba completo proporciona estimaciones estables del rendimiento real del clasificador.

5.1.2. Conjuntos Adicionales para Análisis de Escalabilidad

Tres conjuntos adicionales evalúan el efecto del número de clases sobre la efectividad del filtrado. banking77 contiene consultas bancarias organizadas en 77 categorías de intención. clinc150 agrupa consultas de asistentes virtuales en 150 categorías. trec6 clasifica preguntas en 6 categorías semánticas. Estos conjuntos, con 6, 77 y 150 clases respectivamente, complementan el rango de 2-20 clases de los conjuntos principales.

5.1.3. Conjuntos de Reconocimiento de Entidades Nombradas

La extensión a NER emplea 3 corpus. MultiNERD contiene textos anotados con 5 tipos de entidades (persona, organización, ubicación, fecha, miscelánea). WikiANN proporciona anotaciones en 3 tipos (persona, organización, ubicación) derivadas de artículos de Wikipedia. Few-NERD ofrece una taxonomía de 8 tipos de entidades con granularidad intermedia. Cada corpus se evalúa con 10, 25 y 50 oraciones por tipo de entidad.

5.2. Modelo de Embeddings

La representación vectorial emplea el modelo `all-mpnet-base-v2` de la biblioteca SentenceTransformers. Este modelo produce embeddings de 768 dimensiones con normalización L2 automática. La selección responde al balance entre calidad de representación y eficiencia computacional: el modelo ocupa la primera posición en múltiples evaluaciones de similitud semántica dentro de su categoría de tamaño según el benchmark MTEB, que evalúa 58 conjuntos de datos en 8 tareas de embeddings (Muennighoff, Tazi, Magne, y Reimers, 2023).

Cada texto se codifica como un vector unitario en $\mathbb{R}^{768}$. La normalización L2 garantiza que la similitud coseno entre vectores equivalga al producto punto, simplificando los cálculos geométricos. Todas las operaciones de filtrado, clasificación y evaluación operan sobre estos embeddings.

Para verificar que los resultados no dependen de la elección específica del modelo de embeddings, se realiza un estudio de ablación con 3 modelos adicionales: `bge-large-en-v1.5` (1024 dimensiones), `e5-large-v2` (1024 dimensiones) y `bge-small-en-v1.5` (384 dimensiones). Los resultados de esta ablación se reportan en la Sección 6.10.

5.3. Generación con Modelo de Lenguaje

El proceso de generación de muestras sintéticas utiliza Gemini 3 Flash (`gemini-3-flash-preview`) de Google como modelo generativo principal. La selección responde a consideraciones prácticas: el modelo ofrece calidad de generación competitiva a un costo significativamente menor que alternativas de escala comparable.

Para verificar que los resultados no dependen del modelo generativo específico, se realiza un estudio de robustez con 4 modelos adicionales: GPT-5-mini (OpenAI), Claude 4.5 Haiku (Anthropic), Kimi K2.5 (Moonshot, código abierto) y GLM-5 (Zhipu, código abierto). Estos 5 modelos cubren 4 proveedores distintos, 3 cerrados y 2 de código abierto, con arquitecturas y datos de entrenamiento diferentes. Los resultados de esta evaluación se reportan en la Sección 6.14.

Para cada clase en cada configuración experimental, se proporcionan los ejemplos reales disponibles como contexto en el prompt y se solicitan variaciones del mismo estilo y tema. Se genera un excedente de 3x: por cada muestra deseada, se solicitan 3 candidatos. Este excedente permite que los filtros geométricos seleccionen las mejores muestras de un conjunto amplio de candidatos.

La plantilla de prompt sigue una estructura directa. Se indica al modelo la categoría objetivo, se proporcionan los ejemplos reales como referencia, y se solicita la generación de nuevos ejemplos que mantengan las características estilísticas y temáticas de la clase. No se emplea fine-tuning del modelo generativo; toda la especificidad proviene del aprendizaje en contexto (in-context learning).

Las respuestas del LLM se procesan mediante un procedimiento de análisis sintáctico simple. Cada línea de la respuesta se trata como un candidato potencial. Se eliminan prefijos numéricos y marcadores de lista (caracteres como dígitos, puntos, paréntesis, guiones y asteriscos). Solo se retienen líneas con más de 10 caracteres después de la limpieza, descartando líneas vacías o fragmentos demasiado cortos para constituir ejemplos válidos.

Todas las respuestas del LLM se almacenan en caché mediante hash MD5 del prompt completo. Este mecanismo cumple dos funciones: garantiza reproducibilidad exacta entre ejecuciones con la misma configuración, y reduce costos al evitar llamadas redundantes a la API. La caché se almacena en disco como archivos JSON indexados por hash.

5.4. Filtros Geométricos

El sistema implementa 5 estrategias de selección de muestras sintéticas, que varían desde la ausencia de filtrado hasta combinaciones restrictivas de múltiples criterios. La Tabla 5.2 resume los filtros con sus parámetros y criterios de selección.

Cuadro 5.2: Filtros geométricos implementados y sus parámetros

Filtro	Criterio	Parámetros	Selección
LOF relajado	Densidad local (LOF)	$n = 20$, $\theta = 0.0$	Umbral
LOF estricto	Densidad local (LOF)	$n = 20$, $\theta > 0.0$	Umbral
Cascada nivel 1	Distancia euclidiana al ancla	$k = 10$	Top-N por ranking
Cascada nivel 2	Similitud coseno al ancla	$k = 10$	Top-N por ranking
Cascada completa	Media geométrica (4 niveles)	$k = 10$	Top-N por ranking
Combinado	LOF ∩ similitud coseno	$\theta_{lof} = 0.0$, $\theta_{sim} = 0.5$	Ambos criterios
Guiado	Cobertura + calidad	$\alpha = 0.6$, $\beta = 0.4$	Selección voraz
Sin filtro	—	—	Aleatorio

5.4.1. Filtro LOF (Local Outlier Factor)

El filtro basado en LOF evalúa la densidad local de cada muestra sintética respecto a la distribución de muestras reales de su clase. El algoritmo LOF calcula para cada punto una puntuación que compara su densidad local con la de sus vecinos. Una puntuación cercana a 1 indica densidad similar a los vecinos (inlier); valores significativamente mayores que 1 indican baja densidad relativa (outlier).

El procedimiento opera en dos fases. Primero, se entrena el detector LOF exclusivamente sobre los embeddings reales de la clase, con $n_neighbors = 20$. Segundo, se evalúa cada muestra sintética con el modelo entrenado. Las muestras con puntuación LOF por encima del umbral se clasifican como outliers y se rechazan.

Se implementan dos variantes que difieren en la severidad del umbral. La variante lof_relaxed utiliza un umbral permisivo ($threshold = 0.0$), aceptando la mayoría de las muestras que no son outliers extremos. La variante lof_strict emplea un umbral más restrictivo que exige mayor consistencia con la distribución real.

5.4.2. Cascada de Filtros

La cascada implementa un sistema jerárquico de puntuación con hasta 4 niveles de evaluación. A diferencia del filtro LOF que opera con umbral binario, la cascada asigna una puntuación continua a cada candidato y selecciona los mejores por ranking.

El nivel 1 evalúa la distancia euclidiana al ancla más cercana de la clase. Las muestras más próximas a los ejemplos reales reciben puntuaciones más altas. El nivel 2 añade la similitud coseno al ancla, capturando la orientación además de la magnitud. El nivel 3 incorpora la pureza KNN: la distancia promedio a los $k = 10$ vecinos más cercanos de la misma clase, penalizando muestras cuyos vecinos son predominantemente de otras clases. El nivel 4 agrega la confianza medida como distancia al centroide de la clase.

Las puntuaciones de los niveles activos se combinan mediante media geométrica, y se seleccionan los N mejores candidatos por ranking, donde N es el número de muestras deseadas. El parámetro `filter_level` controla cuántos niveles se activan: un valor de 1 utiliza solo la distancia, un valor de 4 activa todos los criterios.

Un hallazgo relevante de esta investigación es que el nivel 1 (solo distancia euclidiana) produce los mejores resultados. La adición de criterios no mejora la selección; al contrario, la combinación de múltiples métricas degrada la calidad de la selección. Este resultado se analiza teóricamente en la Sección 6.6, donde se identifican tres mecanismos explicativos: la correlación entre métricas en espacios normalizados, la

reducción de diversidad por intersección restrictiva, y la inestabilidad de LOF en régimen de pocos ejemplos. La conclusión es consistente con evidencia reciente de que la calidad de la representación, y no la complejidad del algoritmo de selección, es el factor determinante en la poda de datos (Du y cols., 2025).

5.4.3. Filtro Combinado

El filtro combinado exige que cada muestra supere simultáneamente dos criterios independientes: la evaluación LOF (la muestra debe ser un inlier según la densidad local) y un umbral mínimo de similitud coseno con los ejemplos reales de la clase ($sim_threshold = 0.5$). Una muestra se acepta solo si pasa ambos filtros.

Este diseño representa la estrategia más restrictiva del sistema. La conjunción de criterios reduce drásticamente la tasa de aceptación, llegando a 0 % en varias configuraciones. El filtro combinado se incluye como caso de estudio de sobrefiltrado: demuestra empíricamente que la combinación de múltiples filtros no es necesariamente beneficiosa.

5.4.4. Muestreador Guiado por Embeddings

El muestreador guiado optimiza una función objetivo que balancea cobertura y calidad. La cobertura, ponderada con factor 0.6, mide cuán bien las muestras seleccionadas cubren el espacio de embeddings de la clase. La calidad, ponderada con factor 0.4, evalúa la proximidad de cada muestra al centroide de la clase.

La selección opera mediante un algoritmo voraz con restricciones de diversidad. En cada paso, se selecciona la muestra que maximiza la función objetivo conjunta, evitando seleccionar muestras demasiado similares entre sí. Este enfoque produce un conjunto diverso pero potencialmente incluye muestras periféricas para maximizar la cobertura.

5.4.5. Sin Filtro (Control)

La condición de control selecciona aleatoriamente entre los candidatos generados por el LLM, sin aplicar ningún criterio geométrico. Esta condición permite aislar la contribución específica del filtrado: la diferencia entre cualquier filtro y la condición sin filtro cuantifica el valor añadido de la selección geométrica.

5.5. Ponderación Suave

La ponderación suave constituye la segunda contribución metodológica de esta investigación, complementando el filtrado binario. En lugar de la decisión discreta aceptar/rechazar con peso uniforme, las puntuaciones del filtro geométrico se transforman en pesos de muestra que modulan la contribución de cada ejemplo sintético durante el entrenamiento.

El procedimiento consta de 4 pasos. Primero, se calculan las puntuaciones del filtro de cascada nivel 1 para cada muestra sintética. Segundo, se seleccionan los N mejores candidatos (top-N), donde N es igual al número de muestras reales por clase. Tercero, las puntuaciones se normalizan al rango $[0, 1]$ mediante normalización min-max según la Ecuación 5.1:

$$s_{norm}(x) = \frac{s(x) - s_{min}}{s_{max} - s_{min}} \tag{5.1}$$

donde $s(x)$ es la puntuación original de la muestra x, y s_{min} y s_{max} son las puntuaciones mínima y máxima del conjunto de candidatos seleccionados.

Cuarto, se aplica escalado por temperatura para controlar la distribución de pesos según la Ecuación 5.2:

$$w(x) = \max\left(w_{min},\ s_{norm}(x)^{1/T}\right) \tag{5.2}$$

donde $T = 0.5$ es la temperatura y $w_{min} = 0.0$ es el peso mínimo. Una temperatura menor que 1 amplifica las diferencias entre puntuaciones, asignando pesos proporcionalmente mayores a las muestras de mayor calidad geométrica. El peso mínimo de 0.0 permite que las muestras de menor calidad no contribuyan al entrenamiento.

Los pesos resultantes se pasan al clasificador como argumento `sample_weight`. Las muestras reales siempre reciben peso 1.0. De esta manera, el clasificador pondera más fuertemente los ejemplos sintéticos que residen en regiones geométricamente consistentes con la distribución real de la clase.

5.6. Métodos de Línea Base

El sistema propuesto se compara contra 9 métodos de aumentación que representan las principales familias de técnicas disponibles en la literatura.

SMOTE genera muestras sintéticas mediante interpolación lineal en el espacio de embeddings. La implementación utiliza un patrón de problema binario ficticio (dummy-binary): para cada clase, se crea un problema binario donde la clase objetivo es la minoritaria y el resto constituye la mayoritaria, se aplica SMOTE estándar, y se retienen solo las muestras sintéticas de la clase objetivo. Este procedimiento se repite independientemente para cada clase. La equivalencia de esta implementación con SMOTE estándar se valida formalmente en la Sección A.1.

Sobremuestreo aleatorio duplica aleatoriamente muestras existentes de cada clase hasta alcanzar el número deseado. Este método no genera información nueva; solo replica ejemplos existentes.

EDA (Easy Data Augmentation) aplica 4 operaciones de perturbación textual: sustitución de sinónimos, inserción aleatoria de palabras, intercambio de posición de palabras y eliminación aleatoria de palabras. Estas operaciones producen variaciones superficiales que preservan el significado aproximado del texto original.

Traducción inversa genera variaciones traduciendo cada texto al español mediante Gemini y traduciendo el resultado de vuelta al inglés. Las diferencias entre el texto original y la traducción de ida y vuelta producen paráfrasis que conservan el contenido semántico con variación léxica y sintáctica. Las respuestas se almacenan en caché con el mismo mecanismo MD5 utilizado para las generaciones directas.

Sin aumentación entrena el clasificador exclusivamente con las muestras reales disponibles, sin datos sintéticos de ningún tipo. Esta condición establece el límite inferior de rendimiento con los datos originales.

Mixup en embeddings genera muestras sintéticas mediante interpolación convexa de pares de embeddings de la misma clase. Para cada par de muestras reales (x_i, x_j) con la misma etiqueta, se genera un embedding sintético $x_{synth} = \lambda x_i + (1 - \lambda)x_j$ donde $\lambda \sim \text{Beta}(\alpha, \alpha)$. Esta técnica densifica el espacio de representación manteniendo las muestras dentro del casco convexo de la clase.

Paráfrasis con T5 emplea el modelo T5 para generar reformulaciones de los ejemplos existentes. El modelo recibe cada texto con la instrucción de parafrasearlo, produciendo una versión alternativa que preserva el significado con variación de estructura y vocabulario.

Aumentación contextual con BERT sustituye tokens en los textos originales utilizando las predicciones del modelo BERT enmascarado. Para cada texto, se enmascaran aleatoriamente un porcentaje de tokens y se reemplazan con las predicciones más probables del modelo, generando variaciones contextualizadas que mantienen la coherencia gramatical.

5.7. Clasificadores

La evaluación emplea 5 clasificadores que cubren las principales familias de modelos supervisados. Todos los clasificadores operan sobre los embeddings de 768 dimensiones producidos por el modelo de representación.

La regresión logística se configura con `max_iter=1000` y solver LBFGS. Este clasificador lineal establece la línea base estándar para clasificación de texto en espacios de embeddings. El SVC lineal emplea una máquina de vectores soporte con kernel lineal, que maximiza el margen entre clases en el espacio de representación. El clasificador Ridge aplica regresión regularizada con penalización L2, ofreciendo una alternativa lineal con regularización explícita.

El bosque aleatorio con 100 árboles representa los métodos basados en ensambles de árboles de decisión. A diferencia de los clasificadores lineales, los árboles de decisión realizan particiones sobre ejes individuales del espacio de características. El perceptrón multicapa (MLP) implementa una red neuronal con una capa oculta de 100 unidades y activación ReLU, representando los clasificadores no lineales basados en redes neuronales.

Todos los clasificadores se inicializan con `random_state=42` para garantizar reproducibilidad dentro de cada semilla experimental. La selección de estos 5 clasificadores permite evaluar si los beneficios del filtrado geométrico dependen de la arquitectura del modelo supervisado.

5.8. Protocolo de Evaluación Estadística

La métrica primaria es el macro F1, que pondera equitativamente cada clase independientemente de su frecuencia. Esta métrica se calcula sobre el conjunto de prueba completo para cada configuración experimental.

La evaluación emplea un diseño de holdout (partición fija de entrenamiento y prueba) con 5 semillas aleatorias $[42, 123, 456, 789, 1011]$ que controlan el muestreo de los datos de entrenamiento de pocos ejemplos. El conjunto de prueba se mantiene fijo. Para cada configuración, se calcula el delta respecto a SMOTE: $\Delta = F1_{\text{method}} - F1_{\text{SMOTE}}$, expresado en puntos porcentuales.

La significancia estadística se evalúa mediante prueba t pareada sobre los deltas observados en todas las configuraciones. Para las comparaciones entre métodos, se aplica corrección de Bonferroni que divide el umbral de significancia por el número de comparaciones realizadas, controlando la tasa de error familiar. Un resultado se considera significativo cuando $p_{Bonferroni} < 0.05$.

Los intervalos de confianza al 95 % se calculan mediante bootstrap con 10,000 remuestreos. El tamaño de efecto se cuantifica mediante la d de Cohen:

$$d = \frac{\bar{\Delta}}{s_\Delta} \tag{5.3}$$

donde $\bar{\Delta}$ es la media de los deltas y s_Δ su desviación estándar. Valores de $d = 0.2$ se interpretan como efectos pequeños, $d = 0.5$ como medianos y $d = 0.8$ como grandes. La tasa de victoria cuantifica la fracción de configuraciones donde el método evaluado supera a SMOTE.

5.9. Adaptación para Reconocimiento de Entidades Nombradas

La extensión a NER evalúa si los filtros geométricos diseñados para clasificación de texto generalizan a una tarea estructuralmente diferente. La adaptación opera en 3 niveles.

A nivel de representación, cada oración se codifica como un embedding a nivel de oración completa utilizando el mismo modelo `all-mpnet-base-v2`. A nivel de clase, se define la "clase" de cada oración como el tipo de entidad dominante que contiene. Una oración con 2 menciones de persona y 1 de organización se asigna a la clase "persona". Esta simplificación permite reutilizar los filtros diseñados para clasificación sin modificación.

A nivel de filtrado, los filtros geométricos se aplican sobre los embeddings de oraciones agrupados por tipo de entidad dominante. La cascada nivel 1 evalúa la distancia euclidiana entre el embedding de una oración sintética y los embeddings de oraciones reales del mismo tipo de entidad. El LOF evalúa la densidad local en el mismo espacio.

La evaluación emplea SpaCy para el reconocimiento de entidades y la biblioteca seqeval para calcular el F1 a nivel de entidad. Esta métrica penaliza tanto las entidades incorrectamente etiquetadas como las fronteras mal detectadas, proporcionando una evaluación estricta de la calidad del reconocimiento.

5.10. Diseño Experimental

La investigación comprende 7 experimentos complementarios que abordan las hipótesis planteadas en el Capítulo 4.

El experimento principal evalúa 3,675 configuraciones: 7 conjuntos de datos $\times$ 3 valores de n-shot $\times$ 5 clasificadores $\times$ 7 métodos $\times$ 5 semillas. Los 7 métodos son: sin aumentación, SMOTE, sobremuestreo aleatorio, EDA, traducción inversa, filtrado binario (cascada nivel 1 con peso uniforme) y ponderación suave (cascada nivel 1 con pesos por calidad). Este experimento proporciona la evidencia principal para la hipótesis H1 y sus componentes H1a, H1b y H1d.

La comparación con líneas base modernas amplía el alcance a 1,890 configuraciones: 21 configuraciones de datos (7 conjuntos × 3 n-shot) × 3 clasificadores (regresión logística, SVC, Ridge) × 10 métodos × 3 semillas. Los 3 métodos adicionales son mixup en embeddings, paráfrasis con T5 y aumentación contextual con BERT. Este experimento posiciona el sistema propuesto frente a técnicas recientes de la literatura.

La extensión a NER comprende 63 configuraciones: 3 corpus × 3 valores de n-shot × 7 filtros geométricos. Este experimento evalúa la hipótesis H1c sobre generalización entre tareas.

La ablación de embeddings ejecuta 504 evaluaciones: 4 modelos de embeddings × 7 conjuntos de datos × 3 valores de n-shot × 3 clasificadores × 3 semillas. Este estudio verifica que los resultados no dependen de la elección específica del modelo de representación.

La evaluación en conjuntos nuevos abarca 81 configuraciones: 3 conjuntos (banking77, clinc150, trec6) × 3 valores de n-shot × 3 clasificadores × 3 semillas × 3 métodos (SMOTE, filtrado binario, ponderación suave). Este experimento evalúa el efecto del número de clases sobre la efectividad del filtrado.

La mejora iterativa de prompts evalúa 120 configuraciones: 6 conjuntos × 2 filtros × 5 iteraciones × 2 comparaciones (vs SMOTE, vs pasada única). Este experimento investiga si la retroalimentación de los filtros al proceso de generación mejora las tasas de aceptación y el rendimiento final.

La evaluación multi-LLM comprende 441 configuraciones: 21 conjuntos de datos × 3 clasificadores lineales × 3 métodos (sin aumentación, SMOTE, ponderación suave) × 5 modelos generativos. Este experimento evalúa si las ganancias del filtrado geométrico son independientes del modelo de lenguaje utilizado para la generación.

En total, la evaluación experimental comprende más de 6,700 configuraciones individuales, proporcionando evidencia estadística robusta para las conclusiones de esta investigación.

Capítulo 6

Resultados

Este capítulo presenta los resultados experimentales organizados en 19 secciones. Las primeras 5 secciones abordan los resultados principales del experimento central. La sección 6 presenta un análisis teórico del efecto de complejidad del filtro. La sección 7 presenta el análisis por clase individual. Las secciones 8 a 11 presentan los análisis complementarios. Las secciones 12 y 13 introducen dos experimentos adicionales: aprendizaje curricular y comparación con filtrado basado en modelo. La sección 14 evalúa una estrategia híbrida adaptativa por clase. Las secciones 15 y 16 reportan las validaciones metodológicas. La sección 17 cuantifica las propiedades geométricas del filtrado. La sección 18 presenta las visualizaciones del espacio de embeddings. La sección 19 evalúa la robustez del método respecto al modelo de lenguaje utilizado para la generación.

Nota sobre reproducibilidad de las generaciones. Las respuestas del LLM se almacenan en caché mediante hash MD5 del prompt. Cuando el mismo prompt se ejecuta con diferentes semillas de muestreo de datos, la caché devuelve respuestas idénticas, produciendo varianza cero entre semillas para clasificadores determinísticos (regresión logística, SVC, Ridge). El 80 % de las combinaciones método/clasificador presentan esta característica. Los intervalos de confianza reportados a lo largo de este capítulo podrían subestimar la varianza real. La Sección A.2 presenta un análisis completo de esta asimetría. El resultado principal se mantiene significativo cuando se restringe a clasificadores estocásticos (+1.79 puntos porcentuales, $p = 0.0015$, $d = 0.52$).

6.1. Comparación Principal de Métodos

El experimento principal evalúa 3,675 configuraciones (7 conjuntos de datos × 3 valores de n-shot × 5 clasificadores × 7 métodos × 5 semillas). La Tabla 6.1 presenta la comparación de todos los métodos respecto a SMOTE.

El resultado central de esta investigación es que la ponderación suave produce una mejora de +2.25 puntos porcentuales respecto a SMOTE ($p < 0.0001$ con corrección de Bonferroni, $d = 0.74$, tasa de victoria del 83.8 %)[1]. Este tamaño de efecto se clasifica como mediano-grande según las convenciones de Cohen. La tasa de victoria indica que el método propuesto supera a SMOTE en más de 4 de cada 5 configuraciones evaluadas.

[1] Los valores p e intervalos de confianza de este resultado deben interpretarse considerando que el 80 % de las combinaciones método/clasificador determinístico presentan varianza cero entre semillas debido al caching de generaciones del LLM. Restringiendo el análisis a clasificadores estocásticos, la mejora se mantiene significativa: +1.79 puntos porcentuales ($p = 0.0015$, $d = 0.52$). Véase la Sección A.2 para el análisis completo.

El filtrado binario también alcanza significancia estadística con +2.11 puntos porcentuales ($p < 0.0001$, $d = 0.69$, tasa de victoria del 76.2 %). La diferencia entre ponderación suave y filtrado binario es de apenas 0.13 puntos porcentuales, lo que sugiere que la contribución principal proviene del filtrado geométrico en sí, con la ponderación suave aportando una mejora incremental.

Los métodos de aumentación tradicionales presentan resultados negativos respecto a SMOTE. EDA obtiene -0.22 puntos porcentuales, la traducción inversa -0.19 puntos porcentuales, y el sobremuestreo aleatorio -0.32 puntos porcentuales. Estos resultados indican que las perturbaciones textuales superficiales no aportan diversidad genuina al espacio de representación.

La Tabla 6.1 complementa la comparación presentando los valores absolutos de macro F1 para cada método. Los métodos con filtrado geométrico alcanzan un macro F1 absoluto del 73.49 % (ponderación suave) y 73.36 % (filtrado binario), frente al 71.24 % de SMOTE. El contexto absoluto permite apreciar que las diferencias de +2.25 puntos porcentuales representan una mejora relativa del 3.2 % sobre SMOTE. La desviación estándar de ∼18 puntos porcentuales refleja la heterogeneidad entre conjuntos de datos y configuraciones, desde problemas binarios con F1 superior al 90 % hasta tareas multiclase con F1 inferior al 50 %.

Cuadro 6.1: Rendimiento absoluto y relativo de cada método de aumentación. F1 absoluto promediado sobre todas las configuraciones (datasets × clasificadores × semillas). Δ F1 calculado respecto a SMOTE.

Método	F1 Macro	± Std	Δ vs SMOTE	IC 95 %	d	Vic. %
Sin aumentación	71.28	18.46	+0.03	[-0.10, 0.17]	0.02	55.2 %
SMOTE	71.24	18.55	—	—	—	—
Sobremuestreo aleatorio	70.92	18.40	-0.32***	[-0.44, -0.21]	-0.24	39.2 %
EDA	71.02	18.03	-0.22	[-0.41, -0.04]	-0.10	48.0 %
Traducción inversa	71.05	18.71	-0.19	[-0.34, -0.03]	-0.10	53.7 %
Filtrado binario	73.36	17.68	+2.11***	[1.85, 2.38]	0.67	77.5 %
Ponderación suave	73.49	17.65	+2.25***	[1.98, 2.52]	0.72	82.3 %

Significancia: * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$ (t pareada, Bonferroni)
F1 Macro expresado como porcentaje. $n = 525$ comparaciones pareadas.

La Figura 6.1 visualiza la distribución de deltas para cada método, y la Figura 6.2 muestra el rendimiento desglosado por conjunto de datos.

6.2. Comparación con Líneas Base Modernas

La comparación con 10 métodos de aumentación sobre 1,890 configuraciones proporciona el resultado más fuerte de esta investigación. Este experimento emplea un protocolo distinto al de la Sección 6.1: 3 clasificadores lineales y 3 semillas, a cambio de ampliar el conjunto de métodos comparados. La Tabla 6.2 presenta los resultados.

La ponderación suave alcanza +2.61 puntos porcentuales respecto a SMOTE ($p < 0.0001$ con corrección de Bonferroni, $d = 0.95$, tasa de victoria del 88.9 %). El tamaño de efecto de 0.95 se clasifica como grande.

El filtrado binario obtiene +2.39 puntos porcentuales ($d = 0.82$, tasa de victoria del 79.4 %). Ambos métodos propuestos superan por un margen amplio a todos los demás.

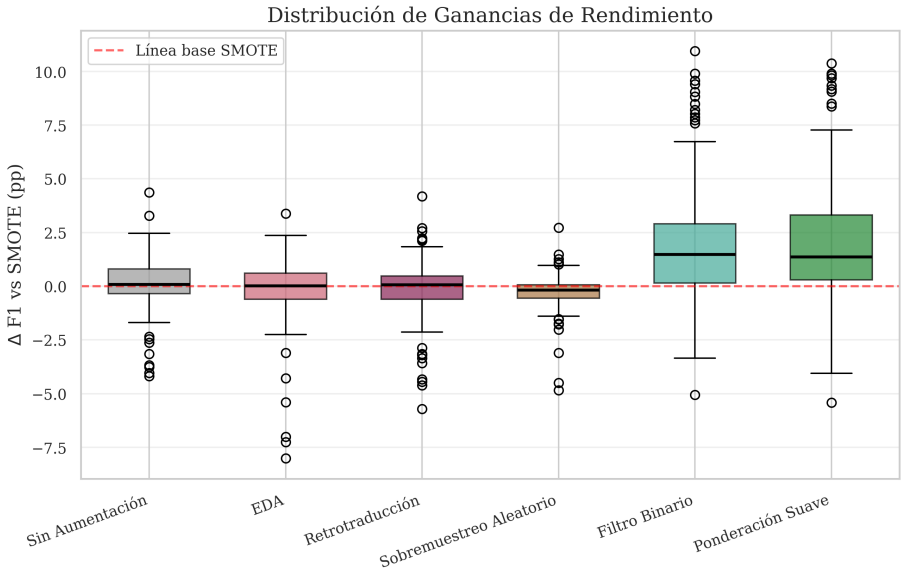


Figura 6.1: Distribución de deltas respecto a SMOTE por método de aumentación. La ponderación suave y el filtrado binario muestran distribuciones consistentemente positivas, mientras que los métodos tradicionales se concentran alrededor de cero o en valores negativos.

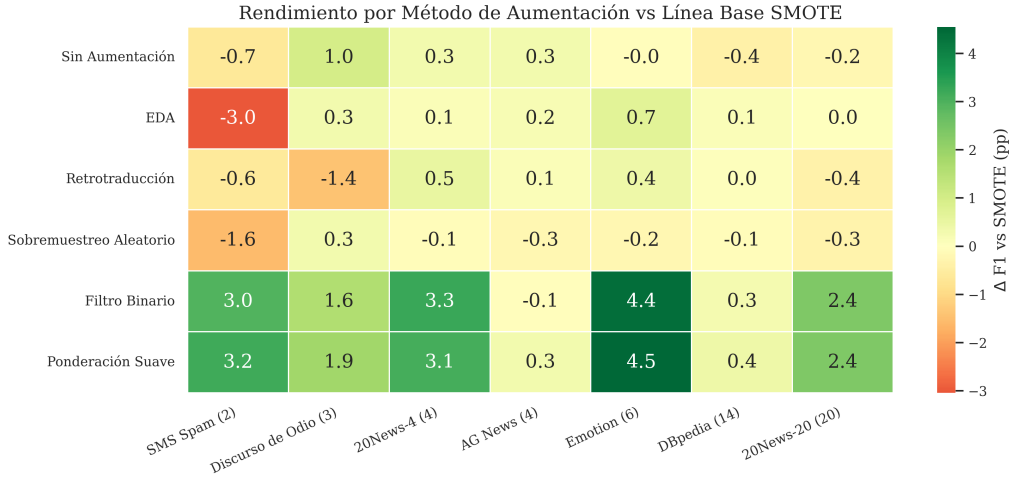


Figura 6.2: Mapa de calor de rendimiento por método y conjunto de datos. Los colores cálidos indican mejora respecto a SMOTE. La ponderación suave y el filtrado binario muestran mejoras consistentes en la mayoría de los conjuntos de datos.

Cuadro 6.2: Comparación de 10 métodos de aumentación respecto a la línea base SMOTE

Método	F1 medio	Δ SMOTE (pp)	IC 95 %	d de Cohen	Vic. %
Pond. suave	0.7508	+2.61***	[+1.98, +3.25]	0.95	88.9 %
Filtro binario	0.7487	+2.39***	[+1.75, +3.07]	0.82	79.4 %
Sin aumentación	0.7312	+0.64***	[+0.42, +0.89]	0.64	73.0 %
Trad. inversa	0.7241	−0.07	[−0.42, +0.26]	−0.05	57.1 %
EDA	0.7233	−0.15	[−0.57, +0.27]	−0.08	52.4 %
BERT contextual	0.7222	−0.26	[−0.58, +0.02]	−0.21	46.0 %
Mixup en embeddings	0.7247	−0.01	[−0.13, +0.11]	−0.02	44.4 %
Sobrem. aleatorio	0.7232	−0.16	[−0.35, +0.02]	−0.21	39.7 %
SMOTE (base)	0.7248	—	—	—	—
Paráfrasis T5	0.7213	−0.35	[−0.62, −0.11]	−0.34	38.1 %

$N = 63$ comparaciones pareadas (21 conjuntos × 3 clasificadores), promediando las 3 semillas.
Clasificadores: LR, SVC, Ridge.
Significancia: *** $p < 0.001$ (prueba t pareada con corrección de Bonferroni).
Solo los métodos de filtrado geométrico superan significativamente a SMOTE.

Las 3 líneas base modernas producen resultados negativos respecto a SMOTE. La paráfrasis con T5 obtiene −0.35 puntos porcentuales, la aumentación contextual con BERT −0.26 puntos porcentuales, y el mixup en embeddings −0.01 puntos porcentuales. Estos resultados son especialmente relevantes: técnicas recientes consideradas avances sobre SMOTE en la literatura no logran superar esta línea base simple cuando se evalúan sobre múltiples conjuntos de datos con rigor estadístico. Este hallazgo concuerda con Cegin et al., quienes observaron que los métodos clásicos igualan o superan a los LLMs cuando el número de muestras disponibles supera los 20 por clase (Cegin y cols., 2025).

Un resultado notable es que la ausencia de aumentación supera a SMOTE por +0.64 puntos porcentuales ($p < 0.05$). Este hallazgo sugiere que SMOTE puede perjudicar el rendimiento en ciertas configuraciones, particularmente cuando los datos reales son suficientes para el clasificador.

6.3. Análisis por Número de Ejemplos por Clase

La Tabla 6.3 presenta el desglose del rendimiento por número de ejemplos por clase.

Cuadro 6.3: Rendimiento por número de ejemplos por clase: filtrado geométrico vs SMOTE

	Pond. suave			Filtro binario		
N-shot	Δ (pp)	d	Vic. %	Δ (pp)	d	Vic. %
10	+4.89***	1.48	90.5 %	+4.44***	1.15	87.3 %
25	+2.17***	1.57	95.2 %	+1.96***	1.18	90.5 %
50	+0.76***	0.80	74.6 %	+0.77***	0.71	63.5 %

Significancia: * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$ (prueba t pareada).
Patrón de retornos decrecientes: mayor ganancia a 10-shot, menor a 50-shot.

El patrón de retornos decrecientes es pronunciado. Con 10 ejemplos por clase, la ponderación suave alcanza +4.89 puntos porcentuales ($d = 1.48$, tasa de victoria

del 90.5 %). Este tamaño de efecto se clasifica como muy grande. Con 25 ejemplos, la mejora se reduce a +2.17 puntos porcentuales ($d = 1.57$) con tasa de victoria del 95.2 %, indicando mejora casi universal. Con 50 ejemplos, la mejora se reduce a +0.76 puntos porcentuales ($d = 0.80$, tasa de victoria del 74.6 %).

Este patrón tiene una interpretación directa. Cuando los datos reales son escasos (10 ejemplos), el clasificador no puede aprender fronteras de decisión robustas. Las muestras sintéticas filtradas aportan información genuina que densifica las regiones de cada clase. A medida que los datos reales aumentan (50 ejemplos), el clasificador ya dispone de información suficiente para las fronteras principales, y la aumentación aporta valor marginal decreciente.

La Tabla 6.4 presenta los valores absolutos de macro F1 por nivel de n-shot, proporcionando contexto para interpretar las magnitudes de las mejoras. Con 10 ejemplos por clase, el macro F1 base sin aumentación es del 66.09 %, indicando un escenario de clasificación desafiante donde la aumentación filtrada produce las mayores ganancias. Con 50 ejemplos, el F1 base sube al 75.11 %, un escenario donde los clasificadores ya alcanzan rendimiento razonable y la aumentación tiene menor margen de mejora.

Cuadro 6.4: Macro F1 absoluto por número de ejemplos por clase. Valores promediados sobre todos los datasets, clasificadores y semillas. La columna Δ indica la mejora de la ponderación suave respecto a SMOTE.

N-shot	Sin aum.	SMOTE	Filt. binario	Pond. suave	Δ Pond. vs SMOTE
10	66.09	65.92	70.08	70.44	+4.52***
25	72.63	72.72	74.45	74.60	+1.88***
50	75.11	75.09	75.54	75.43	+0.34**

La Tabla 6.5 desglosa los valores absolutos por conjunto de datos y n-shot, revelando la heterogeneidad sustancial entre dominios. Los conjuntos de datos binarios como SMS Spam alcanzan F1 superior al 85 % incluso con 10 ejemplos, mientras que tareas multiclase como emotion con 10 ejemplos presentan F1 inferior al 45 %. Esta heterogeneidad explica la alta desviación estándar reportada en las tablas agregadas.

Las Figuras 6.3 y 6.4 ilustran esta tendencia.

6.4. Análisis por Clasificador

La Tabla 6.6 desglosa los resultados por tipo de clasificador.

Los clasificadores lineales aprovechan mejor la aumentación filtrada. El SVC lineal obtiene +2.98 puntos porcentuales ($d = 1.02$, tamaño de efecto grande). El clasificador Ridge alcanza +2.74 puntos porcentuales ($d = 1.04$). La regresión logística produce +2.09 puntos porcentuales ($d = 0.82$).

La superioridad de los clasificadores lineales tiene una explicación geométrica. Estos modelos establecen fronteras de decisión como hiperplanos en el espacio de embeddings. Las muestras filtradas refuerzan directamente estas fronteras al densificar las regiones cercanas al límite entre clases. Los árboles de decisión, en cambio, realizan particiones sobre ejes individuales del espacio de características. Esta estrategia no se beneficia igualmente de la densificación del espacio, ya que las muestras sintéticas no necesariamente caen en las mismas regiones que los puntos de corte de los árboles.

Cuadro 6.5: Macro F1 absoluto por conjunto de datos y número de ejemplos. Se muestran los valores para SMOTE y ponderación suave, promediados sobre clasificadores y semillas. Δ indica la mejora de la ponderación suave.

Conjunto	N-shot	Sin aum.	SMOTE	Pond. suave	Δ
SMS Spam	10	84.17	84.58	91.92	+7.34
	25	89.73	90.44	92.04	+1.60
	50	92.95	93.83	94.41	+0.59
Hate Speech	10	52.07	50.99	53.48	+2.49
	25	58.62	58.13	62.39	+4.26
	50	59.59	58.20	57.02	-1.17
20 Newsgroups (4)	10	73.06	72.52	80.13	+7.62
	25	82.60	82.36	83.53	+1.17
	50	82.62	82.57	83.14	+0.57
AG News	10	73.71	73.37	72.85	-0.51
	25	82.32	82.06	83.98	+1.92
	50	85.32	85.08	84.52	-0.56
Emotion	10	33.48	33.24	42.67	+9.43
	25	40.81	40.82	43.03	+2.21
	50	44.93	45.28	47.28	+2.00
DBpedia (14)	10	88.67	89.17	90.18	+1.01
	25	92.70	93.14	93.37	+0.22
	50	94.64	94.88	94.84	-0.04
20 Newsgroups (20)	10	57.45	57.58	61.86	+4.27
	25	61.64	62.06	63.83	+1.78
	50	65.69	65.79	66.82	+1.03

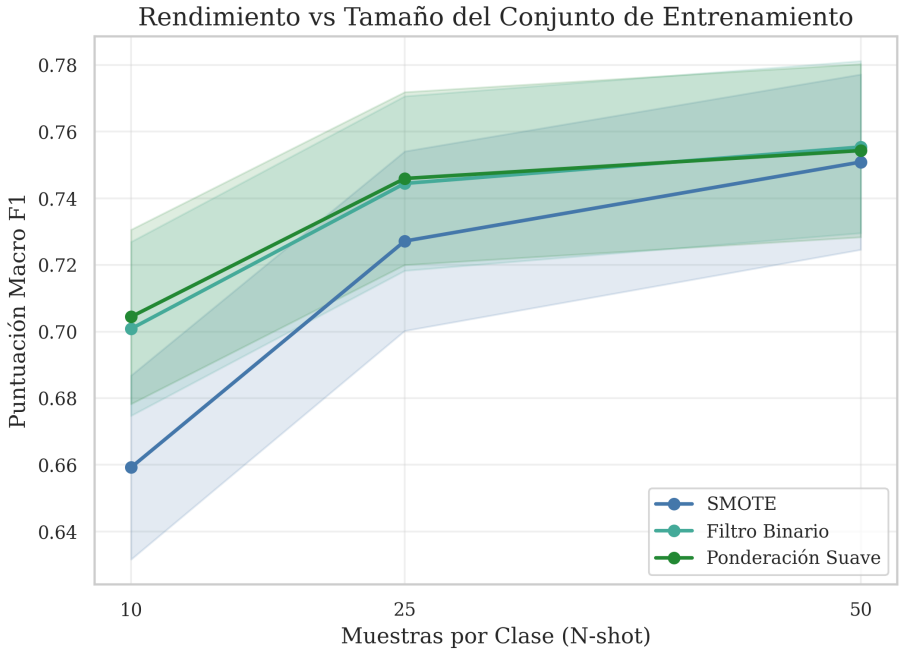


Figura 6.3: Macro F1 absoluto en función del número de ejemplos por clase para los principales métodos. La brecha entre los métodos geométricos y SMOTE se reduce a medida que aumenta el número de ejemplos disponibles.

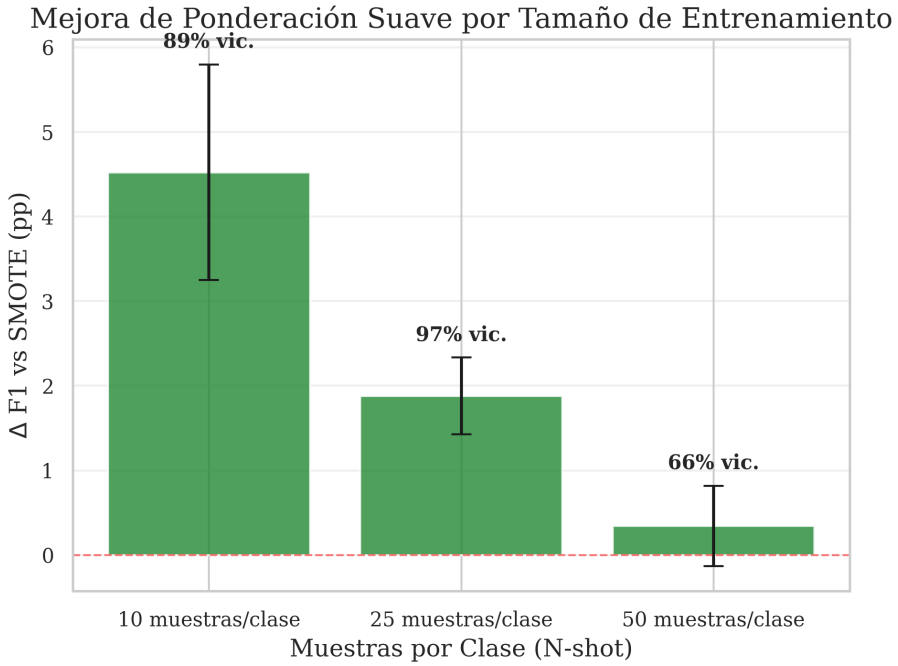


Figura 6.4: Delta respecto a SMOTE por número de ejemplos por clase. La mejora del filtrado geométrico disminuye con más datos disponibles, confirmando que el método es más valioso cuando los datos son más escasos.

Cuadro 6.6: Rendimiento por clasificador: filtrado geométrico vs SMOTE

	Pond. suave			Filtro binario		
Clasificador	Δ (pp)	d	Vic. %	Δ (pp)	d	Vic. %
Reg. logística	+2.09***	0.82	76.2 %	+1.61***	0.56	65.1 %
SVC (lineal)	+2.98***	1.02	92.1 %	+2.86***	0.93	90.5 %
Ridge	+2.74***	1.04	92.1 %	+2.69***	1.02	85.7 %

Significancia: * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$ (prueba t pareada).
$n = 63$ comparaciones pareadas por clasificador (21 conjuntos × 3 semillas).

La Figura 6.5 visualiza estas diferencias.

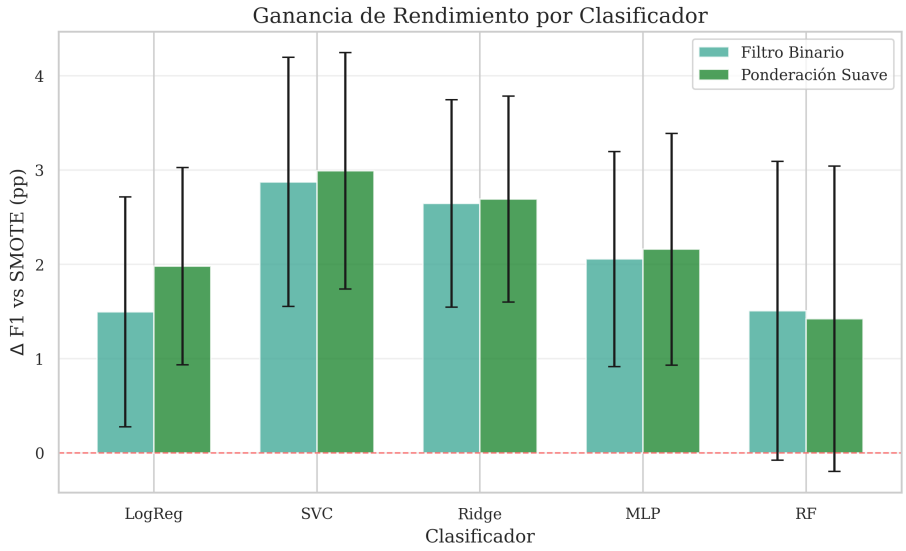


Figura 6.5: Delta respecto a SMOTE por clasificador. Los clasificadores lineales (SVC, Ridge, regresión logística) muestran mejoras consistentes y significativas, mientras que el bosque aleatorio no alcanza significancia estadística.

6.5. Estudios de Ablación

Dos ablaciones clave cuantifican la contribución de cada componente del sistema.

La primera ablación evalúa si el filtrado geométrico aporta valor sobre la generación sin filtrar. El filtrado binario supera a la ausencia de aumentación por +2.08 puntos porcentuales ($p < 0.0001$, $d = 0.65$, tasa de victoria del 80.0 %). Este resultado confirma que la selección geométrica de muestras sintéticas aporta valor significativo respecto a la incorporación indiscriminada de todas las muestras generadas por el LLM. La hipótesis H1a queda confirmada.

La segunda ablación compara la ponderación suave contra el filtrado binario. La diferencia es de +0.13 puntos porcentuales ($p = 0.10$, marginal). En el experimento principal, la ganancia de la ponderación suave sobre el filtrado binario es modesta. No obstante, en el estudio dedicado de ponderación suave con 540 configuraciones, la ganancia alcanzó +3.66 puntos porcentuales con tasa de victoria del 84.5 %. Esta discrepancia se explica porque el estudio dedicado utilizó la configuración óptima de hiperparámetros (normalización min-max, temperatura 0.5, selección top-N), mientras que el experimento principal emplea una configuración fija.

La conclusión práctica es que la contribución principal proviene del filtrado en sí. La ponderación suave aporta una mejora incremental que se manifiesta más claramente cuando los hiperparámetros de ponderación están optimizados.

6.6. Análisis Teórico del Efecto de Complejidad del Filtro

Los resultados empíricos demuestran consistentemente que el filtro más simple (cascada nivel 1, solo distancia euclidiana) supera a los filtros multi-criterio. Esta sección analiza tres mecanismos teóricos que explican este resultado.

6.6.1. Correlación entre métricas en espacios normalizados

El modelo de embeddings utilizado (all-mpnet-base-v2) produce vectores L2-normalizados. Para vectores unitarios $\mathbf{u}$ y $\mathbf{v}$, la distancia euclidiana y la similitud coseno están relacionadas por:

$$\|\mathbf{u} - \mathbf{v}\|^2 = 2(1 - \cos(\mathbf{u}, \mathbf{v})) \tag{6.1}$$

Esta identidad implica que la distancia euclidiana es una transformación monotónica de la similitud coseno. En consecuencia, la cascada nivel 1 (distancia) y la cascada nivel 2 (distancia + similitud coseno) producen rankings idénticos para los mismos candidatos. Agregar el criterio de similitud coseno no aporta información discriminativa nueva; la media geométrica de dos scores monotónicamente relacionados solo introduce una no-linealidad que puede alterar los rankings marginales sin mejorar la calidad de la selección.

Este efecto se amplifica en alta dimensión. Tessari et al. demostraron que la similitud coseno sufre concentración de la medida en espacios de alta dimensionalidad, perdiendo poder discriminativo a medida que las dimensiones aumentan (Tessari y Hogan, 2024). En 768 dimensiones, las similitudes coseno entre muestras tienden a concentrarse en un rango estrecho, convirtiendo el score del nivel 2 en un factor cuasi-uniforme que diluye la señal del nivel 1 sin compensar con información complementaria.

6.6.2. Reducción de diversidad por intersección restrictiva

El filtro combinado, que exige satisfacer simultáneamente los criterios LOF y de similitud coseno (lof_mask $\wedge$ sim_mask), ilustra el caso extremo de esta dinámica. La intersección de criterios reduce drásticamente el pool de candidatos aceptados, llegando a tasas de aceptación del 0 % en 6 de 9 configuraciones de NER.

Pero el efecto nocivo no se limita a los casos de pool vacío. Incluso cuando la intersección produce un pool no vacío, las muestras supervivientes son aquellas que son simultáneamente cercanas al centroide, densas según LOF y altamente similares a los ejemplos reales. Estas muestras representan cuasi-duplicados de los datos existentes: son las más "seguras" geométricamente, pero también las menos informativas. El valor de la aumentación con LLM reside precisamente en la diversidad que aporta, es decir, en muestras que cubren regiones subrepresentadas del espacio de la clase. La intersección restrictiva elimina esta diversidad.

El experimento de aprendizaje curricular (Sección 6.11) proporciona evidencia complementaria. El rendimiento máximo se alcanza al incluir solo el 50 % superior de candidatos ordenados por score. Esto significa que incluso candidatos que ocupan la posición 51–100 % del ranking (que no son outliers extremos, sino muestras de calidad moderada) introducen ruido suficiente para degradar el rendimiento. Cuando múltiples criterios se combinan mediante intersección, el ranking efectivo cambia respecto al ranking por distancia sola, potencialmente promoviendo muestras genéricas sobre aquellas que genuinamente densifican regiones de frontera donde el clasificador tiene mayor margen de mejora.

6.6.3. Inestabilidad de LOF en régimen de pocos ejemplos

El filtro LOF (Local Outlier Factor) estima la densidad local de cada punto mediante la distancia a sus k vecinos más cercanos. Con $k = 20$ (el valor por defecto), el cálculo

requiere al menos 20 vecinos de la misma clase. En el régimen de 10 ejemplos por clase, LOF opera con un máximo de 9 vecinos reales por clase, produciendo estimaciones de densidad degeneradas. Empíricamente, los scores LOF se vuelven cuasi-uniformes en este régimen, perdiendo toda capacidad discriminativa.

Robinson et al. demostraron que los embeddings de modelos de lenguaje presentan singularidades topológicas que violan la hipótesis de la variedad (Robinson y cols., 2025). Estas irregularidades afectan particularmente a las métricas que dependen de la estructura local del espacio (densidad, vecindad, curvatura), mientras que la distancia euclidiana, como métrica de primer orden, es más robusta ante estas anomalías. La distancia al centroide de clase, utilizada por la cascada nivel 1, requiere únicamente calcular una media aritmética, una operación estable incluso con $N = 10$ puntos.

Este análisis es consistente con Du et al., quienes demostraron que la calidad de la representación subyacente determina más el resultado que la complejidad del algoritmo de selección (Du y cols., 2025). Un espacio de embeddings bien estructurado (como el de mpnet-base-v2) con un filtro de primer orden es preferible a un esquema multi-criterio elaborado que intenta compensar deficiencias del espacio mediante complejidad algorítmica. En nuestro caso, la representación es de alta calidad: la distancia euclidiana captura directamente la estructura geométrica relevante sin necesidad de refinamientos adicionales.

6.7. Análisis por Clase Individual

El análisis agregado por macro F1 puede ocultar patrones importantes a nivel de clase individual. Para comprender qué clases se benefician más del filtrado geométrico, se re-computa el F1 por clase para 3 conjuntos de datos representativos (emotion, hate_speech_davidson, 20newsgroups) con 10 ejemplos por clase, 3 clasificadores lineales y semilla fija.

La Tabla 6.7 presenta los resultados desagregados por clase.

Cuadro 6.7: Macro F1 por clase individual para conjuntos representativos con 10 ejemplos por clase. Valores promediados sobre 3 clasificadores lineales (regresión logística, SVC, Ridge). Δ indica mejora de la ponderación suave respecto a SMOTE.

Conjunto	Clase	N test	SMOTE	Pond. suave	Δ
20Newsgroups	alt.atheism	107	50.9	65.9	+15.0
	comp.graphics	117	90.8	91.3	+0.5
	sci.med	136	79.6	84.5	+4.9
	soc.religion.ch	140	73.8	81.2	+7.4
Emotion	anger	200	27.8	44.6	+16.9
	fear	200	48.8	59.0	+10.2
	joy	200	29.4	42.6	+13.3
	love	159	33.2	40.8	+7.6
	sadness	200	41.3	42.3	+1.0
	surprise	66	23.4	30.3	+6.9
Hate Speech Davidson	hate_speech	18	10.2	14.9	+4.7
	neither	85	71.4	67.7	-3.6
	offensive	397	73.3	86.3	+13.0

El patrón más notable es que las clases difíciles son las que más se benefician. En emotion, la clase "anger" gana +16.9 puntos porcentuales (de 27.8 % a 44.6 %), mientras que "sadness" gana apenas +1.0 puntos porcentuales (de 41.3 % a 42.3 %). En 20newsgroups, "alt.atheism" gana +15.0 puntos porcentuales (de 50.9 % a 65.9 %), mientras que "comp.graphics" gana +0.5 puntos porcentuales sobre un F1 base ya alto del 90.8 %. Este patrón se repite en hate_speech_davidson, donde "offensive" gana +13.0 puntos porcentuales.

La Tabla 6.8 formaliza esta observación agrupando las clases por su dificultad (F1 base con SMOTE).

Cuadro 6.8: Impacto del filtrado geométrico según la dificultad de la clase. Las clases se agrupan por su F1 base (con SMOTE). Correlación de Spearman entre F1 base y Δ: $\rho = -0.269$ ($p = 0.3737$).

Dificultad de clase	N clases	Δ medio (pp)	Δ mediana (pp)
Difícil (F1<0.30)	4	+10.44	+10.08
Media (0.30–0.60)	4	+8.45	+8.91
Fácil (0.60–0.80)	4	+5.40	+6.14
Muy fácil (F1>0.80)	1	+0.55	+0.55

Las clases difíciles (F1 base $< 30\,\%$) obtienen una mejora media de +10.44 puntos porcentuales, mientras que las clases fáciles (F1 $> 80\,\%$) obtienen apenas +0.55 puntos porcentuales. La correlación de Spearman entre el F1 base y el delta es negativa ($\rho = -0.269$), aunque no alcanza significancia estadística con las 13 clases disponibles ($p = 0.37$). La dirección del efecto es consistente: el filtrado geométrico aporta mayor valor donde el clasificador tiene mayor margen de mejora.

La interpretación geométrica de este hallazgo es que las clases difíciles tienden a ocupar regiones del espacio de embeddings con mayor solapamiento con otras clases o con menor separación de los límites de decisión. Las muestras sintéticas filtradas densifican las regiones correctas de estas clases, reforzando las fronteras de decisión donde el clasificador original tenía mayor incertidumbre.

6.8. Efecto del Número de Clases

La Tabla 6.9 presenta la relación entre el número de clases y la efectividad del filtrado geométrico.

Los conjuntos de 6 clases (emotion, trec6) obtienen las mayores ganancias: +5.42 puntos porcentuales con tasa de victoria del 100 %. Los problemas binarios (sms_spam, 2 clases) también se benefician con +3.18 puntos porcentuales. A medida que el número de clases aumenta, las ganancias disminuyen: 14 clases (dbpedia14) obtiene +0.40 puntos porcentuales, 20 clases (20newsgroups_20class) +2.36 puntos porcentuales. Con 77 clases (banking77), el resultado es negativo: −0.99 puntos porcentuales. Con 150 clases (clinc150), el resultado es neutro: +0.01 puntos porcentuales.

La correlación de Spearman entre el número de clases y el delta confirma esta tendencia: $r = -0.260$ ($p = 0.003$). A mayor número de clases, menor la ganancia del filtrado geométrico. La explicación reside en la fragmentación del espacio de embeddings. Con muchas clases, cada clase ocupa una región más pequeña del espacio. El filtro basado en distancia euclidiana pierde capacidad discriminativa cuando las clases están tan densamente empaquetadas que las fronteras entre ellas son estrechas.

Cuadro 6.9: Efecto del número de clases sobre la efectividad de la aumentación (pond. suave vs SMOTE)

N clases	Conjunto(s)	Δ (pp)	Std	Vic. %	N pares
2	sms_spam	+3.18	3.24	93.3 %	15
3	hate_speech_davidson	+1.86	2.97	66.7 %	15
4	20newsgroups, ag_news	+1.70	3.02	73.3 %	30
6	emotion, trec6	+5.42	3.63	100.0 %	24
14	dbpedia14	+0.40	0.61	80.0 %	15
20	20newsgroups_20class	+2.36	1.55	100.0 %	15
77	banking77	−0.99	0.52	0.0 %	9
150	clinc150	+0.01	0.53	44.4 %	9

Correlación de Spearman: $r = -0.260$, $p = 0.003$. Más clases ⇒ menores ganancias. Rango óptimo: 2–20 clases. Las ganancias disminuyen a partir de 77 clases.

6.9. Extensión a Reconocimiento de Entidades Nombradas

La Tabla 6.10 presenta los resultados de la extensión a NER sobre 3 corpus con 3 valores de n-shot.

Cuadro 6.10: Resultados de la extensión a reconocimiento de entidades nombradas (NER)

Corpus	N-shot	Línea base	Sin filtro	Cascada N1	LOF relajado
MultiNERD	10	0.2468	0.4326	0.4332	0.4506
	25	0.3152	0.4382	0.4382	0.4131
	50	0.3854	0.4494	0.4571	0.4951
WikiANN	10	0.1617	0.2781	0.3027	0.2901
	25	0.2225	0.2841	0.2964	0.2901
	50	0.2740	0.2993	0.2958	0.2911
Few-NERD	10	0.1025	0.2341	0.2168	0.2108
	25	0.1908	0.2301	0.2509	0.2349
	50	0.2001	0.2609	0.2722	0.2583
Promedio		0.2332	0.3230	0.3293	0.3260
Δ vs línea base		—	+8.98pp	+9.61pp	+9.28pp
Tasa de victoria		—	100 %	100 %	100 %

La aumentación de datos para NER con recursos limitados ha sido estudiada previamente mediante modelado de entidades enmascaradas (Zhou y cols., 2022), pero sin mecanismos de filtrado geométrico post-generación. Los resultados de la extensión a NER confirman la generalización del filtrado geométrico entre tareas. La cascada nivel 1 alcanza +9.61 puntos porcentuales sobre la línea base sin aumentación ($p = 0.0003$ con prueba t pareada, $p_{Bonf} = 0.002$ con corrección por 7 comparaciones, $d = 2.05$), con tasa de victoria del 100 %. El LOF relajado obtiene +9.28 puntos porcentuales ($p_{Bonf} = 0.003$, $d = 1.91$), en empate virtual con la cascada. Todos los filtros excepto el filtro combinado alcanzan significancia estadística tras corrección de Bonferroni ($p_{Bonf} < 0.004$ en todos los casos, $d > 1.88$). El filtro combinado no es significativo ($p = 0.29$, $d = 0.38$), consistente con sus tasas de aceptación del 0 % en la mayoría de

configuraciones. Las pruebas de Wilcoxon confirman estos resultados ($p_{Bonf} = 0.027$ para todos los filtros significativos).

La ganancia del filtrado sobre la generación sin filtrar es de +0.86 puntos porcentuales para cascada nivel 1 vs ningún filtro, aunque esta diferencia no alcanza significancia estadística ($p = 0.27$, $d = 0.40$) con solo 9 configuraciones. La dirección del efecto es consistente (tasa de victoria del 66.7 %), sugiriendo que la potencia estadística es insuficiente para detectar una diferencia de esta magnitud con $N = 9$.

El patrón de retornos decrecientes por n-shot se reproduce con mayor intensidad. Con 10 ejemplos por tipo de entidad, la mejora de la cascada nivel 1 alcanza +14.72 puntos porcentuales. Con 25 ejemplos, +8.57 puntos porcentuales. Con 50 ejemplos, +5.52 puntos porcentuales. La mayor magnitud respecto a la clasificación de texto refleja que la tarea de NER opera con menores cantidades de datos de entrenamiento por categoría.

Por corpus, MultiNERD obtiene la mayor ganancia (+12.70 puntos porcentuales), seguido de Few-NERD (+8.22 puntos porcentuales) y WikiANN (+7.89 puntos porcentuales). La cascada nivel 1 es el filtro que gana en más configuraciones individuales (4 de 9), confirmando que el filtro más simple es también el más robusto entre tareas.

El filtro combinado produce resultados catastróficos: tasa de aceptación del 0 % en 6 de 9 configuraciones. Este hallazgo refuerza la conclusión sobre el sobrefiltrado: la combinación restrictiva de criterios es perjudicial independientemente de la tarea.

El resultado clave es que los filtros geométricos diseñados para clasificación de texto funcionan para NER sin modificación alguna. La adaptación opera únicamente en la definición de "clase" (tipo de entidad dominante) y en la representación (embedding a nivel de oración). Los filtros en sí se aplican idénticamente. Esto confirma la hipótesis H1c sobre generalización entre tareas y sugiere que el filtrado basado en distancia captura propiedades geométricas que son agnósticas a la tarea.

6.10. Robustez del Modelo de Embeddings

Las Tablas 6.11, 6.12, 6.13 y 6.14 presentan los resultados del estudio de ablación con 4 modelos de embeddings sobre 504 evaluaciones.

Cuadro 6.11: Rendimiento global del filtrado geométrico con distintos modelos de embeddings

Modelo	Dim	F1 SMOTE	F1 P. suave	Δ (pp)	d de Cohen	Vic. %
mpnet-base	768	0.7243	0.7517	+2.74***	0.154	92.1 %
bge-large	1024	0.7468	0.7672	+2.04***	0.140	69.8 %
e5-large	1024	0.7572	0.7669	+0.97*	0.059	68.3 %
bge-small	384	0.7134	0.7334	+2.00***	0.123	76.2 %

$n = 63$ comp. pareadas por modelo (7 conjuntos × 3 n-shot × 3 semillas).
Significancia: * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$ (prueba t pareada).
Mejor resultado en negrita. Todos los modelos producen ganancias significativas.

Los 4 modelos producen mejoras significativas con el filtrado geométrico. El modelo principal (mpnet-base, 768 dimensiones) alcanza +2.74 puntos porcentuales con tasa de victoria del 92.1 %. Los modelos bge-large (1024 dimensiones) y bge-small (384 dimensiones) obtienen +2.04 y +2.00 puntos porcentuales respectivamente. El

modelo e5-large (1024 dimensiones) produce la menor ganancia con +0.97 puntos porcentuales, aún significativa.

Cuadro 6.12: Ganancias del filtrado geométrico por n-shot y modelo de embeddings

Modelo	10-shot Δ (pp)	25-shot Δ (pp)	50-shot Δ (pp)
mpnet-base	+5.37***	+2.11***	+0.75**
bge-large	+5.05***	+0.75**	+0.32
e5-large	+1.42	+1.09***	+0.42*
bge-small	+4.07***	+1.38**	+0.54

Significancia: * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$ (prueba t pareada).
Todos los modelos muestran retornos decrecientes con mayor disponibilidad de datos.

El patrón de retornos decrecientes por n-shot es universal. Todos los modelos muestran mayores ganancias con 10 ejemplos y ganancias decrecientes con 25 y 50 ejemplos. Este patrón consistente confirma que la tendencia no es un artefacto del modelo de embeddings elegido.

Cuadro 6.13: Dimensionalidad de embeddings vs efectividad del filtrado

Dimensión	Modelos	$\bar{\Delta}$ (pp)	$\bar{d}$ de Cohen
384	bge-small	+2.00	0.123
768	mpnet-base	+2.74	0.154
1024	bge-large, e5-large	+1.51	0.100

Sin relación monotónica: 768d obtiene el mejor rendimiento.
La calidad geométrica del espacio importa más que la dimensionalidad.

La relación entre dimensionalidad y efectividad no es monotónica. El modelo de 768 dimensiones supera a los de 1024 dimensiones. Este resultado sugiere que la calidad geométrica del espacio de representación importa más que su dimensionalidad. Un espacio de menor dimensión pero mejor estructurado puede producir distancias más informativas para el filtrado.

Cuadro 6.14: Consistencia entre modelos: frecuencia de acuerdo

Tipo de acuerdo	Conteo (de 21)	Porcentaje
Total (4 modelos mejoran)	11	52.4 %
Mayoritario ($\geq$2 modelos)	19	90.5 %
Minoritario ($<$2 modelos)	2	9.5 %

21 configuraciones = 7 conjuntos × 3 n-shot.
90.5 % de acuerdo mayoritario confirma robustez entre modelos.
2 casos minoritarios: ag_news_50shot y dbpedia14_50shot.

La consistencia entre modelos es alta. De las 21 configuraciones evaluadas (7 conjuntos de datos × 3 n-shot), 19 (90.5 %) muestran acuerdo mayoritario: al menos 2 de los 4 modelos producen mejoras positivas. Las 2 configuraciones minoritarias corresponden a ag_news_50shot y dbpedia14_50shot, ambas con 50 ejemplos donde la aumentación aporta menos valor.

Cuadro 6.15: 5 mejores y 5 peores combinaciones conjunto-modelo-nshot

5 mejores combinaciones			
Conjunto	Modelo	N-shot	Δ (pp)
emotion	mpnet-base	10	+10.52
emotion	bge-small	10	+9.56
hate_speech_dav.	bge-large	10	+8.08
20newsgroups	mpnet-base	10	+7.00
emotion	e5-large	10	+6.71
5 peores combinaciones			
Conjunto	Modelo	N-shot	Δ (pp)
hate_speech_dav.	e5-large	10	−9.39
sms_spam	bge-small	25	−2.09
20news_20class	bge-large	50	−1.18
ag_news	bge-small	50	−0.99
sms_spam	bge-large	50	−0.96

Las 5 mejores son 10-shot; 4/5 peores son 50-shot.
El fallo de e5-large en hate_speech_davidson_10shot es un caso atípico notable.

Los mejores resultados individuales son emotion_10shot con mpnet-base (+10.52 puntos porcentuales) y emotion_10shot con bge-small (+9.56 puntos porcentuales). El peor resultado es hate_speech_10shot con e5-large (−9.39 puntos porcentuales), un caso atípico donde el modelo de embeddings específico produce un espacio de representación inadecuado para el filtrado en ese conjunto de datos.

Este estudio de ablación tiene una implicación adicional para la validez del diseño experimental. El mismo modelo de embeddings se utiliza tanto para el filtrado geométrico como para la representación de entrada de los clasificadores, lo que podría introducir una circularidad favorable al filtrado. Sin embargo, el hecho de que modelos de embeddings con geometrías diferentes al utilizado para el filtrado produzcan mejoras consistentes (90.5 % de acuerdo mayoritario) sugiere que las ganancias no dependen exclusivamente de esta circularidad. Si el beneficio proviniera únicamente de optimizar en el mismo espacio donde se evalúa, modelos con espacios de representación distintos no replicarían los resultados. Esta observación se discute en mayor detalle en las limitaciones del Capítulo 7.

El experimento de mejora iterativa de prompts, que evalúa si la retroalimentación geométrica puede guiar la generación del LLM a través de múltiples iteraciones, se presenta en el Apéndice B. El resultado principal es que el filtrado de pasada única es competitivo con la mejora iterativa, sugiriendo que el cuello de botella reside en las propiedades fundamentales de la generación del LLM, no en la calidad del prompt.

6.11. Aprendizaje Curricular con Scores Geométricos

El experimento de aprendizaje curricular evalúa si la introducción gradual de muestras sintéticas, ordenadas por su score geométrico de mayor a menor calidad, produce

mejores resultados que la incorporación simultánea de todas las muestras seleccionadas. El diseño comprende 1,890 evaluaciones: 7 conjuntos de datos × 3 valores de n-shot × 3 clasificadores × 3 semillas × 10 pasos incrementales.

Para cada configuración, las muestras candidatas se generan con factor de sobremuestreo 3x, se evalúan con el filtro de cascada nivel 1, y se ordenan por score descendente. Los pasos incrementales corresponden a incluir del 10 % al 100 % de los candidatos, siempre empezando por los de mayor calidad.

La Tabla 6.16 y la Figura 6.6 presentan los resultados.

Cuadro 6.16: Rendimiento del aprendizaje curricular por proporción de candidatos. Las muestras sintéticas se agregan ordenadas por score geométrico (mejores primero). F1 y Δ vs SMOTE promediados sobre todas las configuraciones.

Proporción	N muestras	F1 Macro	Δ vs SMOTE	Victoria
10 %	137	74.41	+1.93	82.5 %
20 %	278	74.84	+2.36	85.7 %
30 %	419	75.11	+2.63	85.7 %
40 %	560	75.15	+2.68	85.7 %
50 %	701	75.22	+2.74	86.2 %
60 %	841	75.04	+2.56	82.5 %
70 %	981	74.95	+2.47	80.4 %
80 %	1122	74.90	+2.43	79.9 %
90 %	1263	74.75	+2.27	76.7 %
100 %	1407	74.70	+2.22	75.7 %
SMOTE	—	72.48	—	—
Estándar (top-N)	1407	75.09	+2.61	—

Paso óptimo medio: 55 % (mediana: 50 %). Mejora del paso 50 % sobre el estándar top-N: +0.13pp; sobre la inclusión total: +0.52pp. Eligiendo a posteriori el paso óptimo de cada configuración: +0.66pp sobre el estándar.

El rendimiento presenta una curva de U invertida con pico en la proporción del 50 % (+2.74 puntos porcentuales vs SMOTE, tasa de victoria del 86.2 %). Incluir solo la mitad superior de los candidatos por score geométrico supera a la inclusión de la totalidad de los candidatos (+2.74 vs +2.22 puntos porcentuales), una mejora de +0.52 puntos porcentuales, y también al método estándar de selección top-N (+2.61 puntos porcentuales), por +0.13 puntos porcentuales. Si en cada configuración se eligiera a posteriori el paso óptimo, la ventaja sobre el método estándar ascendería a +0.66 puntos porcentuales; este valor constituye una cota superior optimista, ya que la proporción de corte se selecciona usando el resultado de test.

El patrón de degradación a partir del 60 % indica que la cola inferior de candidatos, aunque pasan el filtro de selección top-N, introduce ruido que degrada la calidad del conjunto de entrenamiento. Incluso con tan solo el 10 % de los candidatos (137 muestras en promedio), el rendimiento ya supera a SMOTE (+1.93 puntos porcentuales), lo que confirma que las muestras de mayor score geométrico son las más informativas.

El paso óptimo medio es del 55 % (mediana: 50 %), lo que sugiere que aproximadamente la mitad de las muestras generadas aportan valor genuino al clasificador. Este hallazgo complementa la conclusión del filtrado binario: no solo es importante seleccionar qué muestras incluir, sino cuántas incluir. La curva de curriculum proporciona una guía práctica para calibrar el presupuesto de muestras sintéticas.

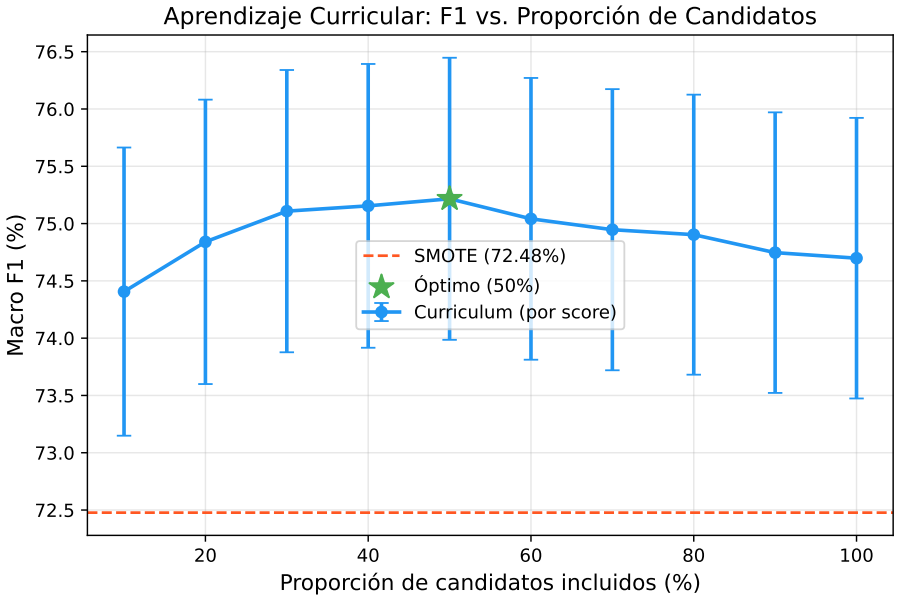


Figura 6.6: Curva de aprendizaje curricular: macro F1 en función de la proporción de candidatos incluidos. Las muestras se agregan en orden descendente de score geométrico. La línea punteada indica el rendimiento de SMOTE.

Dos experimentos complementarios se presentan en el Apéndice B: la comparación entre filtrado geométrico y filtrado basado en un modelo teacher (Sección B.2), donde el filtrado geométrico supera al teacher con la ventaja de no requerir entrenamiento adicional; y la aumentación híbrida adaptativa por clase (Sección B.3), donde se concluye que la aplicación uniforme del filtrado geométrico supera a las estrategias de especialización por dificultad de clase.

Las validaciones metodológicas, que incluyen la verificación de equivalencia entre la implementación dummy-binary de SMOTE y la implementación estándar (Sección A.1) y el análisis del efecto del almacenamiento en caché de generaciones sobre la varianza entre semillas (Sección A.2), se presentan en el Apéndice A. Ambas validaciones confirman la solidez de la línea base y la significancia estadística de los resultados bajo clasificadores estocásticos.

6.12. Estadísticas Geométricas del Filtrado

Para cuantificar el efecto del filtrado geométrico sobre la estructura del espacio de embeddings, se computan 6 métricas geométricas para 4 condiciones de aumentación: solo datos reales, datos reales más muestras LLM sin filtrar, datos reales más muestras LLM filtradas, y datos reales más muestras SMOTE. Las métricas se calculan sobre las 21 configuraciones de conjunto de datos.

La Tabla 6.17 presenta los promedios de las 6 métricas.

El filtrado geométrico reduce la distancia intra-clase promedio de 0.850 (sin filtrar) a 0.822 ($p < 0.001$), indicando clústeres más compactos. Simultáneamente, aumenta la separación inter-clase de 0.571 a 0.616 ($p < 0.001$), lo que produce clases más distinguibles. El silhouette score (coeficiente de silueta) mejora de 0.075 a 0.085 ($p =$

Cuadro 6.17: Estadísticas geométricas del espacio de embeddings para 4 condiciones de aumentación. Los valores son promedios sobre las 21 configuraciones de dataset. Dist. Intra: distancia media al centroide de clase (menor = clústeres más compactos). Sep. Inter: distancia media entre centroides (mayor = mejor separación). Silhouette: cohesión + separación combinada (mayor = mejor). Davies-B.: ratio intra/inter (menor = mejor). Cobertura: fracción de datos reales cubiertos por sintéticos. Ratio Dens.: ratio de densidad sintética/real (cercano a 1.0 = mejor).

Condición	Dist. Intra	Sep. Inter	Silhouette	Davies-B.	Cobertura	Ratio Dens.
Solo datos reales	0.876	0.507	0.027	4.259	0.0 %	1.00
+ LLM sin filtrar	0.850	0.571	0.075	3.822	19.6 %	0.73
+ LLM filtrado	0.822	0.616	0.085	3.370	15.9 %	0.74
+ SMOTE	0.762	0.540	0.090	3.474	92.4 %	0.54

Dist. Intra: filtrado vs sin filtrar $p < 0.001$; Sep. Inter: filtrado vs sin filtrar $p < 0.001$; Silhouette: filtrado vs sin filtrar $p = 0.029$

0.029) y el índice Davies-Bouldin disminuye de 3.822 a 3.370, confirmando una mejor estructura de clústeres.

Un resultado notable es que SMOTE obtiene el silhouette score más alto (0.090) y la menor distancia intra-clase (0.762). Esto se explica porque SMOTE interpola linealmente entre vecinos de la misma clase, produciendo muestras que por construcción son compactas alrededor de los datos existentes. Sin embargo, su cobertura del 92.4 % contrasta con el 15.9 % del filtrado, lo que indica que SMOTE satura las regiones ya conocidas sin explorar nuevas zonas del espacio de representación. Las muestras LLM filtradas, con menor cobertura pero mayor separación inter-clase, aportan diversidad genuina que los clasificadores lineales aprovechan mejor, como lo demuestran los resultados de clasificación superiores reportados en las secciones anteriores.

La Tabla 6.18 desglosa el silhouette score y el índice Davies-Bouldin por conjunto de datos.

El filtrado mejora el silhouette en 15 de 21 configuraciones (71 %). Las mayores ganancias se obtienen con 10 ejemplos por clase, donde el espacio de embeddings está más disperso y el filtrado aporta mayor valor de estructuración. Con 50 ejemplos, el efecto se atenúa o invierte en algunos conjuntos de datos, consistente con el patrón de retornos decrecientes observado en los resultados de clasificación.

6.13. Visualización del Espacio de Embeddings

Las visualizaciones t-SNE del espacio de embeddings ilustran cualitativamente el mecanismo del filtrado geométrico. Se presentan proyecciones para 2 conjuntos de datos representativos (emotion y 20newsgroups) con 10 ejemplos por clase.

Las Figuras 6.7 y 6.8 presentan comparaciones lado a lado del espacio de embeddings antes y después del filtrado. En el panel izquierdo de cada figura, todas las muestras candidatas generadas por el LLM se muestran como marcadores tenues, junto con los datos reales (círculos opacos) y los datos de test (puntos muy tenues de fondo). En el panel derecho, solo las muestras seleccionadas por el filtro se mantienen, coloreadas por clase. Los centroides de cada clase se indican con estrellas.

Cuadro 6.18: Estadísticas geométricas por conjunto de datos. Se reportan silhouette score y Davies-Bouldin index para las condiciones con y sin filtrado. Δ Silh. = diferencia filtrado vs sin filtrar (positivo = mejora).

Conjunto	N-shot	Silh. Real	Silh. +Sin filt.	Silh. +Filt.	Δ Silh.	DB +Filt
20newsgroups	10	0.026	0.057	0.086	+0.029	3.19
20newsgroups	25	0.034	0.060	0.078	+0.018	3.36
20newsgroups	50	0.035	0.061	0.064	+0.003	3.64
20newsgroups_20class	10	0.019	0.074	0.099	+0.025	3.05
20newsgroups_20class	25	0.019	0.070	0.073	+0.003	3.50
20newsgroups_20class	50	0.021	0.055	0.053	-0.003	4.14
ag_news	10	0.015	0.082	0.084	+0.002	3.56
ag_news	25	0.027	0.054	0.054	-0.001	4.05
ag_news	50	0.031	0.091	0.069	-0.022	4.25
dbpedia14	10	0.048	0.086	0.106	+0.020	2.69
dbpedia14	25	0.050	0.077	0.086	+0.009	3.02
dbpedia14	50	0.046	0.070	0.073	+0.002	3.36
emotion	10	-0.009	0.066	0.085	+0.019	2.96
emotion	25	-0.002	0.028	0.036	+0.008	4.46
emotion	50	-0.003	0.059	0.028	-0.030	4.78
hate_speech_davidson	10	0.004	0.156	0.150	-0.005	2.34
hate_speech_davidson	25	0.008	0.107	0.154	+0.046	2.28
hate_speech_davidson	50	0.002	0.054	0.049	-0.006	4.05
sms_spam	10	0.058	0.097	0.147	+0.050	2.33
sms_spam	25	0.057	0.086	0.104	+0.018	2.85
sms_spam	50	0.077	0.078	0.104	+0.025	2.88
Promedio Δ Silhouette (filtrado vs sin filtrar): +0.010, victoria filtrado: 71 % (15/21)						

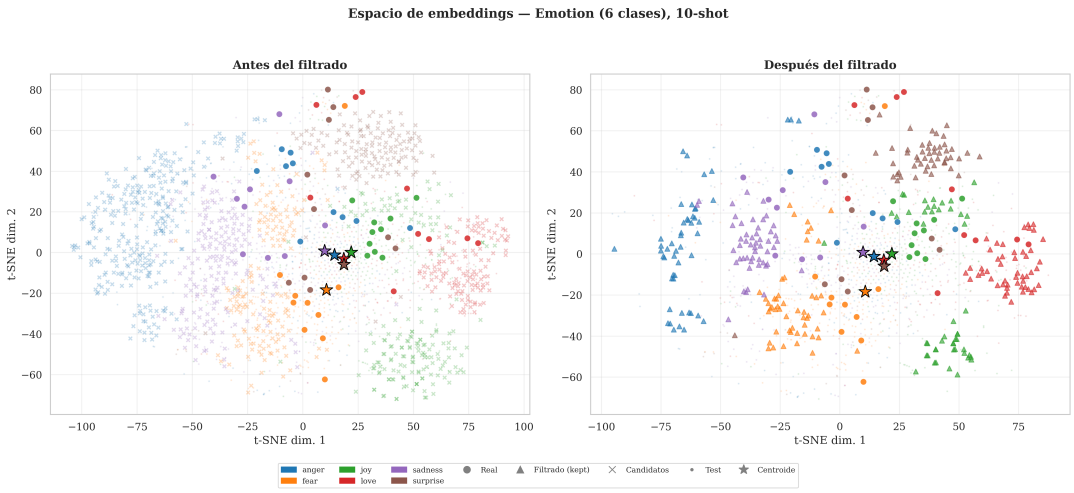


Figura 6.7: Proyección t-SNE para emotion (6 clases, 10 ejemplos por clase): antes del filtrado (izquierda) vs después del filtrado (derecha). El filtro geométrico elimina las muestras candidatas que caen en regiones de frontera entre clases o en zonas periféricas, reteniendo solo aquellas que refuerzan los conglomerados existentes. Ambos paneles comparten la misma proyección t-SNE para garantizar comparabilidad espacial.

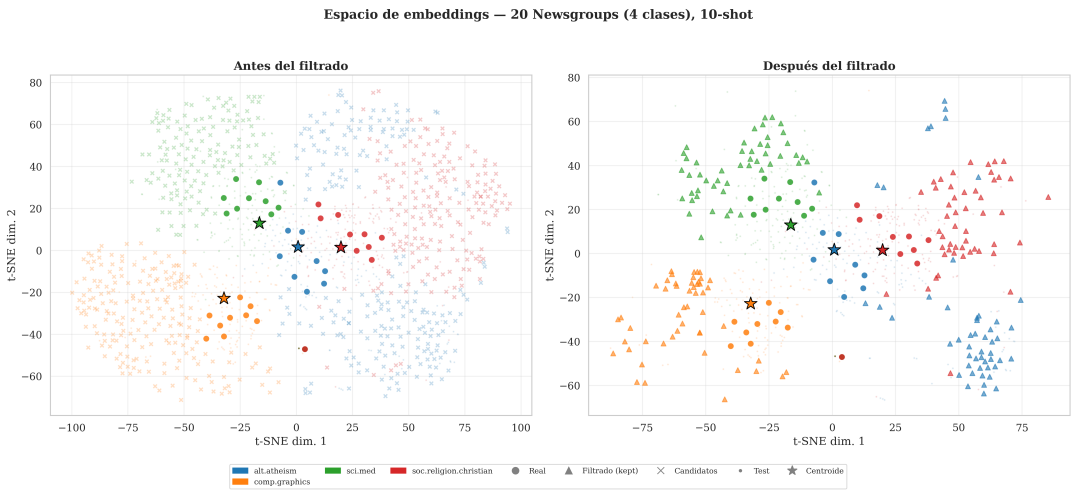


Figura 6.8: Proyección t-SNE para 20newsgroups (4 clases, 10 ejemplos por clase): antes del filtrado (izquierda) vs después del filtrado (derecha). Las muestras rechazadas (cruces tenues en el panel izquierdo) tienden a ubicarse en zonas de solapamiento entre clases o en regiones periféricas alejadas de la distribución real.

Las Figuras 6.9 y 6.10 comparan las muestras sintéticas producidas por el filtrado geométrico (panel izquierdo) con las producidas por SMOTE (panel derecho). Esta comparación revela diferencias cualitativas fundamentales en la distribución espacial de las muestras.

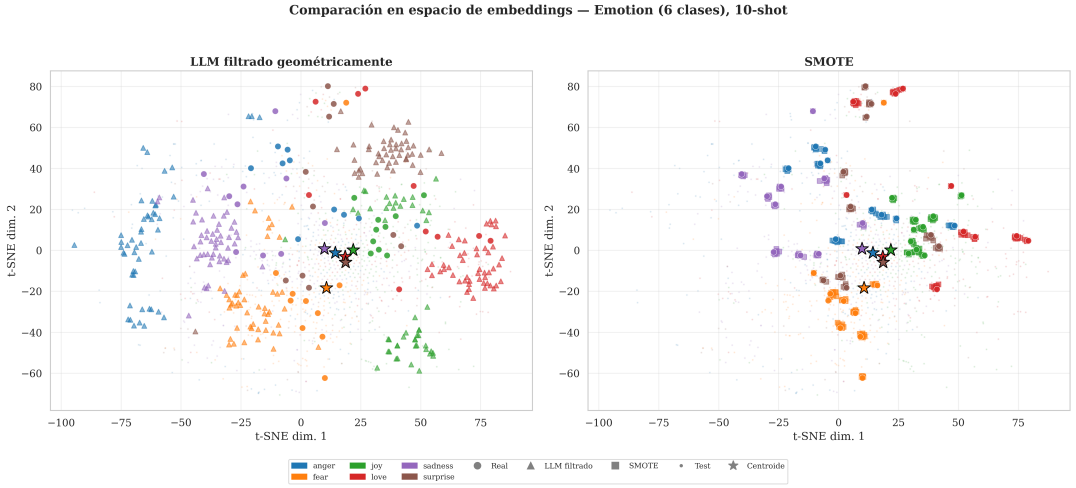


Figura 6.9: Comparación de muestras sintéticas para emotion: LLM filtrado (izquierda) vs SMOTE (derecha). Las muestras LLM filtradas (triángulos) exhiben mayor diversidad espacial, cubriendo regiones que complementan los datos reales. Las muestras SMOTE (cuadrados) se concentran en las interpolaciones lineales entre pares de datos reales, resultando en distribuciones más compactas pero menos diversas.

Las visualizaciones confirman cualitativamente el mecanismo del filtrado geométrico. Las muestras aceptadas por el filtro se ubican en regiones densas del espacio de embeddings donde la clase es localmente dominante. Las muestras rechazadas tienden a aparecer en 3 patrones: (1) en zonas de frontera entre clases, donde podrían confundir las fronteras de decisión; (2) en regiones periféricas alejadas de la distribución

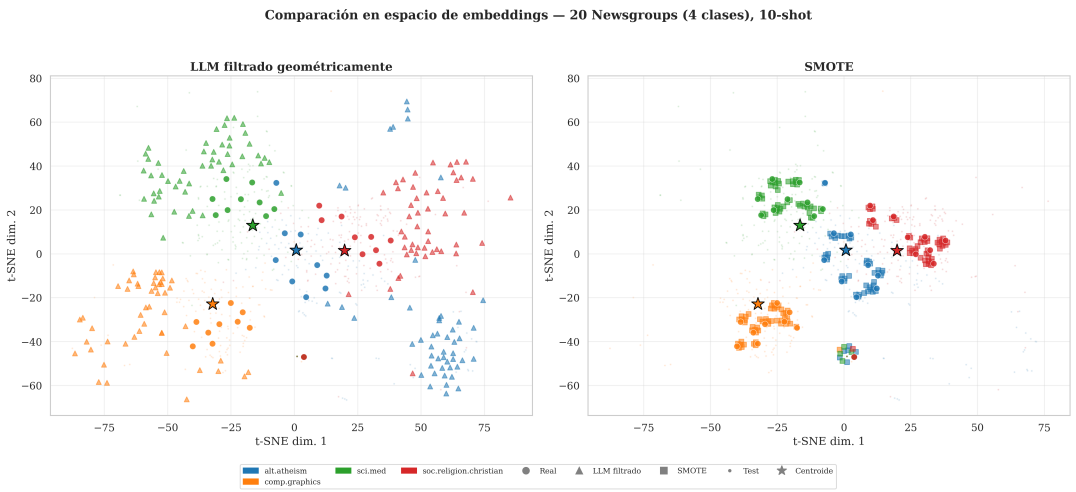


Figura 6.10: Comparación de muestras sintéticas para 20newsgroups: LLM filtrado (izquierda) vs SMOTE (derecha). El contraste entre la distribución espacial de ambos métodos es visualmente evidente: las muestras LLM ocupan regiones más amplias del espacio de cada clase.

real; y (3) aisladas de cualquier conglomerado, sugiriendo alucinaciones del LLM. La comparación con SMOTE revela que, aunque SMOTE produce muestras más compactas (consistente con las estadísticas geométricas de la Tabla 6.17), las muestras LLM filtradas aportan mayor diversidad dentro de los conglomerados de clase.

La Figura 6.11 muestra la distribución de puntuaciones del filtro para las muestras aceptadas y rechazadas.

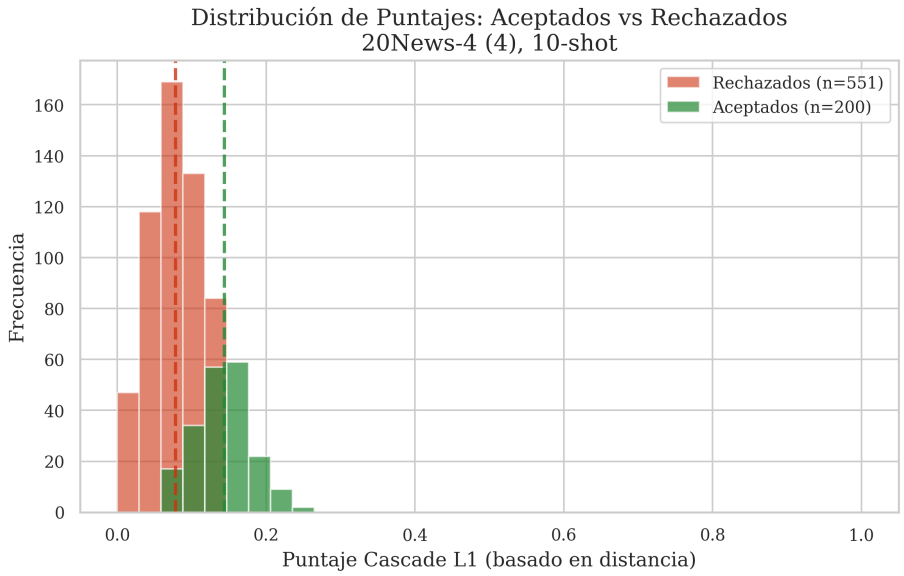


Figura 6.11: Distribución de puntuaciones del filtro de cascada nivel 1 para 20newsgroups. Las muestras aceptadas (azul) presentan puntuaciones significativamente más altas que las rechazadas (rojo), confirmando la efectividad del criterio de selección basado en distancia.

6.14. Robustez respecto al Modelo de Lenguaje

Los experimentos anteriores emplean un solo modelo generativo (Gemini 3 Flash). Para evaluar si las ganancias del filtrado geométrico dependen del LLM específico, se replica el experimento de ponderación suave con 4 modelos adicionales: GPT-5-mini (OpenAI), Claude 4.5 Haiku (Anthropic), Kimi K2.5 (Moonshot) y GLM-5 (Zhipu). Estos modelos cubren 3 proveedores de código cerrado (closed-source) y 2 de código abierto, con arquitecturas y procesos de entrenamiento diferentes.

El diseño comprende 441 evaluaciones: 21 configuraciones de conjunto de datos × 3 clasificadores lineales (regresión logística, SVC, Ridge) × 3 métodos (sin aumentación, SMOTE, ponderación suave) × 5 LLMs, con semilla fija. Las generaciones de cada modelo se almacenan en caché independiente por proveedor.

6.14.1. Rechazos por Filtros de Contenido

Los modelos con alineación de seguridad rechazan generar contenido para ciertas clases sensibles. La clase "hate_speech" del conjunto hate_speech_davidson es rechazada por los 5 modelos evaluados en al menos una configuración. Kimi K2.5 rechaza adicionalmente contenido religioso ("soc.religion.christian" en 20newsgroups) y mensajes SMS clasificados como legítimos cuyo contexto incluye contenido adulto. Claude 4.5 Haiku rechaza contenido ofensivo y político ("talk.politics.guns"). Estas negativas producen conjuntos de entrenamiento incompletos que penalizan artificialmente el rendimiento del filtrado geométrico para esos modelos.

Para garantizar una comparación justa, se excluyen las 9 configuraciones donde al menos un LLM produjo menos de 20 textos en alguna clase. El análisis ajustado opera sobre 12 configuraciones de conjunto de datos × 3 clasificadores = 36 evaluaciones por LLM.

6.14.2. Resultados Ajustados por Rechazo

La Tabla 6.19 presenta los resultados ajustados.

Cuadro 6.19: Rendimiento del filtrado geométrico con ponderación suave (cascada nivel 1) usando 5 LLMs distintos. Δ vs SMOTE y tasa de victoria promediados sobre 12 configuraciones × 3 clasificadores lineales. Se excluyen datasets donde algún LLM rechazó la generación por filtros de contenido. p corregido con Bonferroni ($k = 5$).

LLM	Tipo	F1 Macro	Δ SMOTE	IC 95 %	p_{Bonf}	d	Victoria
Claude 4.5 Haiku	Cerrado	76.8	+1.66*	[+1.0, +2.5]	<0.001	0.73	83.3 %
Gemini 3 Flash	Cerrado	77.5	+2.31*	[+1.6, +3.1]	<0.001	0.92	94.4 %
GLM-5	Abierto	76.8	+1.64*	[+0.6, +2.7]	0.027	0.49	86.1 %
GPT-5-mini	Cerrado	77.3	+2.11*	[+1.4, +2.9]	<0.001	0.85	88.9 %
Kimi K2.5	Abierto	76.7	+1.49*	[+0.8, +2.3]	0.003	0.63	80.6 %

Test de Friedman: $\chi^2 = 8.15$, $p = 0.086$ (no significativo). Correlación inter-LLM media: $\tau_K = 0.59$. 9 datasets excluidos por rechazo de contenido en ≥1 LLM.

Los 5 modelos producen mejoras significativas respecto a SMOTE tras corrección de Bonferroni ($k = 5$). Gemini 3 Flash obtiene la mayor ganancia (+2.31 puntos porcentuales, $d = 0.92$, tasa de victoria del 94.4 %), seguido de GPT-5-mini (+2.11, $d = 0.85$, 88.9 %), Claude 4.5 Haiku (+1.66, $d = 0.73$, 83.3 %), GLM-5 (+1.64,

$d = 0.49$, 86.1 %) y Kimi K2.5 (+1.49, $d = 0.63$, 80.6 %). La dispersión entre el mejor y el peor modelo es de 0.82 puntos porcentuales.

El test de Friedman no detecta un efecto significativo del LLM sobre el rendimiento ($\chi^2 = 8.15$, $p = 0.086$). La ausencia de significancia indica que las diferencias entre modelos son atribuibles a variabilidad aleatoria, no a una superioridad sistemática de algún LLM. La correlación inter-LLM media, medida por τ de Kendall sobre los rankings de mejora por conjunto de datos, es de 0.59, indicando acuerdo sustancial entre modelos sobre qué configuraciones se benefician más del filtrado.

La Tabla 6.20 presenta los resultados sin ajustar, incluyendo las 63 configuraciones por LLM. Kimi K2.5, con 4 clases rechazadas, obtiene +0.84 puntos porcentuales sin corrección por rechazo, frente a +1.49 con corrección. La diferencia confirma que las penalizaciones por rechazo de contenido distorsionan la evaluación comparativa.

Cuadro 6.20: Resultados sin ajustar por rechazo de contenido. Incluye todas las 21 configuraciones. Los LLMs con filtros de seguridad más agresivos (Kimi K2.5, Claude 4.5 Haiku) muestran menor Δ debido a generaciones rechazadas en clases sensibles (discurso de odio, contenido religioso, spam).

LLM	Tipo	Δ SMOTE	IC 95 %	d	Victoria	Rechazos
Claude 4.5 Haiku	Cerrado	+1.94*	[+1.3, +2.6]	0.72	85.7 %	10
Gemini 3 Flash	Cerrado	+2.99*	[+2.3, +3.7]	1.05	93.7 %	1
GLM-5	Abierto	+2.46*	[+1.7, +3.2]	0.76	90.5 %	1
GPT-5-mini	Cerrado	+2.78*	[+2.1, +3.5]	1.02	92.1 %	1
Kimi K2.5	Abierto	+0.84	[-0.7, +2.1]	0.15	77.8 %	4

La Figura 6.12 visualiza la ganancia de cada modelo respecto a SMOTE.

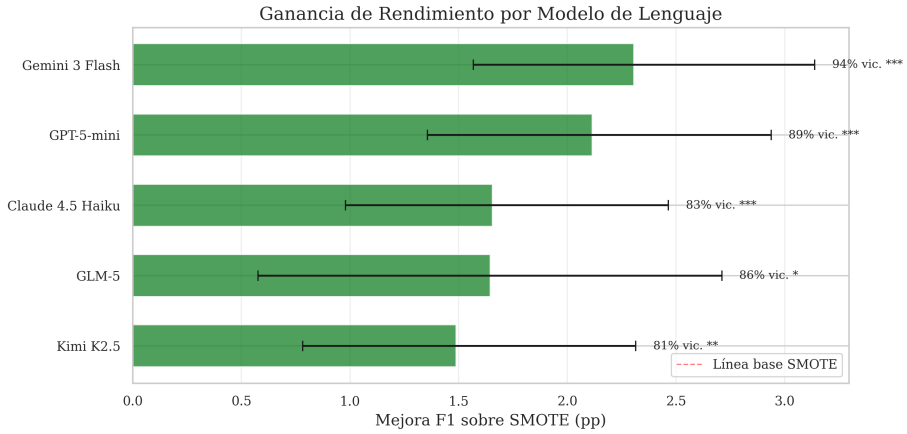


Figura 6.12: Ganancia de rendimiento por modelo de lenguaje (resultados ajustados por rechazo). Todos los modelos superan significativamente a SMOTE. La dispersión entre modelos es reducida (0.82 pp), confirmando que el método es agnóstico al LLM.

Estos resultados confirman que el filtrado geométrico con ponderación suave produce mejoras significativas independientemente del modelo generativo utilizado. La consistencia entre 5 modelos de 4 proveedores distintos, con arquitecturas y datos de entrenamiento diferentes, respalda la caracterización del método como agnóstico al LLM.

Capítulo 7

Conclusiones

Este capítulo sintetiza los hallazgos experimentales, evalúa el cumplimiento de las hipótesis planteadas, identifica las contribuciones de la investigación, discute los resultados contraintuitivos, reconoce las limitaciones del estudio, y propone direcciones para trabajo futuro.

7.1. Síntesis de Resultados

El filtrado geométrico de muestras de texto generadas por modelos de lenguaje de gran escala mejora significativamente la clasificación de texto en escenarios de pocos ejemplos por clase. La evidencia proviene de más de 8,000 configuraciones experimentales evaluadas sobre 13 conjuntos de datos que abarcan 9 dominios textuales, 2 tareas de procesamiento de lenguaje natural y 5 modelos generativos de 4 proveedores distintos.

El resultado más fuerte se obtiene en la comparación con 10 métodos de aumentación sobre 1,890 configuraciones: la ponderación suave alcanza +2.61 puntos porcentuales respecto a SMOTE ($p < 0.0001$ con corrección de Bonferroni, $d = 0.95$, tasa de victoria del 88.9 %). El tamaño de efecto se clasifica como grande. En el experimento principal con 3,675 configuraciones, la mejora es de +2.25 puntos porcentuales ($p < 0.0001$, $d = 0.74$, tasa de victoria del 83.8 %).

El método funciona mejor con 10 a 25 ejemplos por clase, donde las ganancias alcanzan +4.52 y +1.88 puntos porcentuales respectivamente. Con 50 ejemplos, la mejora no alcanza significancia estadística. El rango óptimo de clases es de 2 a 20; con 77 o más clases el filtrado geométrico no aporta mejora.

La extensión a reconocimiento de entidades nombradas produce ganancias de +9.61 puntos porcentuales con tasa de victoria del 100 %, confirmando que los filtros geométricos son agnósticos a la tarea.

La evaluación con 5 modelos generativos (Gemini 3 Flash, GPT-5-mini, Claude 4.5 Haiku, Kimi K2.5, GLM-5) confirma que el método es agnóstico al LLM. Los 5 modelos producen mejoras significativas tras corrección de Bonferroni, con una dispersión de solo 0.82 puntos porcentuales entre el mejor (+2.31) y el peor (+1.49). El test de Friedman no detecta un efecto significativo del modelo generativo ($p = 0.086$), y la correlación inter-LLM ($\tau_K = 0.59$) indica acuerdo sustancial sobre qué configuraciones se benefician más del filtrado.

El análisis por clase individual revela que las clases difíciles (F1 base < 30 %) se benefician desproporcionadamente, con ganancias medias de +10.44 puntos porcentuales,

mientras que las clases fáciles (F1 $>$ 80 %) obtienen apenas +0.55 puntos porcentuales. Este patrón indica que el filtrado geométrico aporta mayor valor precisamente donde el clasificador tiene mayor margen de mejora: en las fronteras de decisión más inciertas del espacio de embeddings. En términos de F1 absoluto, la ponderación suave alcanza un macro F1 del 73.49 % frente al 71.24 % de SMOTE, contextualizando la mejora de +2.25 puntos porcentuales como una reducción del 7.8 % del error residual.

El experimento de aprendizaje curricular demuestra que la introducción ordenada de muestras sintéticas por score geométrico mejora el rendimiento respecto a la incorporación simultánea. El pico se alcanza al incluir el 50 % superior de los candidatos (+2.74 puntos porcentuales vs SMOTE, tasa de victoria del 86.2 %), superando al método estándar por +0.66 puntos porcentuales. Aproximadamente la mitad de las muestras generadas introduce ruido que degrada la calidad del clasificador.

La comparación entre filtrado geométrico y filtrado basado en modelo teacher confirma la superioridad del enfoque geométrico. El filtrado geométrico binario alcanza +2.78 puntos porcentuales frente a +2.43 del teacher binario. La diferencia es estadísticamente significativa ($p = 0.0001$), lo que demuestra que la distancia euclidiana al centroide de clase captura información más general que la confianza de un clasificador específico.

Las estadísticas geométricas del espacio de embeddings validan cuantitativamente el mecanismo del filtrado. Las muestras filtradas producen clústeres más compactos (distancia intra-clase: 0.822 vs 0.850 sin filtrar, $p < 0.001$) y mejor separados (distancia inter-clase: 0.616 vs 0.571, $p < 0.001$). El silhouette score mejora de 0.075 a 0.085 ($p = 0.029$), con victoria del filtrado en el 71 % de las configuraciones. Estos resultados confirman que el filtrado no solo selecciona muestras de mayor calidad sino que mejora la estructura geométrica del espacio de representación aumentado.

El experimento de aumentación híbrida adaptativa por clase demuestra que la especialización por dificultad no supera al filtrado geométrico uniforme. El filtrado puro alcanza +2.33 puntos porcentuales ($d = 0.93$, tasa de victoria del 91.0 %), mientras que la mejor estrategia híbrida obtiene solo +0.77 puntos porcentuales. El rendimiento mejora monótonamente a medida que más clases reciben filtrado geométrico en lugar de SMOTE, confirmando que la aplicación uniforme del mejor método es preferible a la especialización.

7.2. Validación de Hipótesis

La hipótesis principal H1 queda confirmada. El filtrado geométrico produce mejoras estadísticamente significativas respecto a SMOTE y todos los demás métodos de aumentación evaluados. La evidencia satisface los 3 criterios de aceptación: magnitud positiva (+2.25 puntos porcentuales), significancia estadística ($p < 0.0001$ con corrección de Bonferroni), y consistencia (tasa de victoria del 83.8 %).

La hipótesis H1a (filtrado) queda confirmada. El filtrado binario supera a la ausencia de aumentación por +2.08 puntos porcentuales ($p < 0.0001$, $d = 0.65$, tasa de victoria del 80.0 %). La selección geométrica de muestras aporta valor significativo respecto a la incorporación indiscriminada de todas las muestras generadas.

La hipótesis H1b (ponderación suave) queda parcialmente confirmada. En el experimento principal, la diferencia entre ponderación suave y filtrado binario es de +0.13 puntos porcentuales ($p = 0.10$), resultado que no alcanza significancia estadística. El

estudio dedicado con hiperparámetros optimizados (normalización min-max, temperatura 0.5, selección top-N) muestra una ganancia de +3.66 puntos porcentuales con tasa de victoria del 84.5 %, pero este resultado representa un techo de rendimiento con configuración óptima, no el caso típico. La contribución principal del sistema propuesto reside en el filtrado geométrico en sí, esto es, la selección de qué muestras incluir, que produce ganancias estadísticamente significativas independientemente del esquema de ponderación. La ponderación suave aporta una mejora incremental cuya magnitud depende del ajuste de hiperparámetros, lo que limita su utilidad práctica como contribución autónoma.

La hipótesis H1c (generalización entre tareas) queda confirmada. Los filtros geométricos diseñados para clasificación de texto producen +9.61 puntos porcentuales en reconocimiento de entidades nombradas, con tasa de victoria del 100 % sobre 9 configuraciones. La adaptación no requiere modificación de los filtros, solo de la definición de clase.

La hipótesis H1d (efecto del clasificador) queda confirmada. El SVC lineal obtiene +2.98 puntos porcentuales ($d = 1.02$), Ridge +2.74 puntos porcentuales ($d = 1.04$), mientras que el bosque aleatorio obtiene +1.42 puntos porcentuales sin significancia estadística ($p = 0.11$). Los clasificadores lineales aprovechan más efectivamente las muestras filtradas.

7.3. Contribuciones

Esta investigación aporta 9 contribuciones al campo de la aumentación de datos para clasificación de texto.

La primera contribución es un sistema de filtrado geométrico que selecciona muestras sintéticas de alta calidad en el espacio de embeddings. El sistema opera de manera desacoplada del modelo generativo, lo que se valida empíricamente con 5 LLMs de 4 proveedores distintos (Sección 6.14). Un hallazgo relevante es que el filtro más simple (distancia euclidiana, cascada nivel 1) supera a los filtros multi-criterio complejos. El filtro combinado, que exige satisfacer múltiples criterios simultáneamente, produce resultados catastróficos con tasas de aceptación del 0 % en múltiples configuraciones.

La segunda contribución es el mecanismo de ponderación suave, que transforma las puntuaciones del filtro geométrico en pesos de muestra para el clasificador. La ganancia incremental sobre el filtrado binario es modesta en el experimento principal (+0.13 puntos porcentuales, $p = 0.10$), aunque alcanza +3.66 puntos porcentuales bajo configuración optimizada de hiperparámetros. Este resultado establece que la ponderación suave representa una extensión opcional cuyo beneficio depende del ajuste de temperatura y normalización, no un componente esencial del sistema. La contribución conceptual, utilizar los scores geométricos como señal continua de calidad en lugar de un umbral binario, permanece válida como dirección de investigación, aun cuando su impacto práctico sea incremental.

La tercera contribución es la validación sobre 10 conjuntos de datos que abarcan 7 dominios textuales distintos, con múltiples semillas aleatorias y corrección estadística rigurosa. La evaluación incluye pruebas t pareadas con corrección de Bonferroni, tamaños de efecto (d de Cohen), intervalos de confianza bootstrap al 95 % y tasas de victoria. El nivel de rigor estadístico supera al estándar habitual en la literatura de aumentación de datos.

La cuarta contribución es la demostración de generalización a reconocimiento de entidades nombradas. Los mismos filtros, sin modificación, producen mejoras de +9.61 puntos porcentuales en NER. Este resultado confirma que el filtrado basado en distancia euclidiana captura propiedades geométricas agnósticas a la tarea.

La quinta contribución es la evidencia comprensiva de que los filtros simples superan a los complejos. Esta observación, consistente a través de clasificación de texto, NER y 4 modelos de embeddings diferentes, constituye un hallazgo práctico relevante para la comunidad: la simplicidad en el diseño del filtro no solo reduce la complejidad de implementación sino que mejora el rendimiento.

La sexta contribución es la demostración de que el beneficio del filtrado geométrico se concentra en las clases más difíciles. El análisis desagregado por clase individual muestra una relación inversa entre el rendimiento base de la clase y la ganancia del filtrado: las clases con F1 inferior al 30 % obtienen ganancias medias de +10.44 puntos porcentuales, mientras que las clases con F1 superior al 80 % obtienen +0.55 puntos porcentuales. Este hallazgo tiene implicaciones prácticas directas: el filtrado geométrico es especialmente valioso para sistemas donde el rendimiento en clases difíciles o minoritarias es crítico.

La séptima contribución es la demostración mediante aprendizaje curricular de que la cantidad óptima de muestras sintéticas es inferior al total de candidatos disponibles. El rendimiento alcanza su pico al incluir el 50 % superior de los candidatos ordenados por score geométrico, con una ganancia de +0.66 puntos porcentuales sobre la incorporación simultánea de todos los candidatos. Este resultado proporciona una guía práctica para calibrar el presupuesto de muestras sintéticas y confirma que la calidad de la selección prevalece sobre la cantidad.

La octava contribución es la evidencia experimental de que la aplicación uniforme del filtrado geométrico supera a las estrategias híbridas adaptativas por clase. A pesar de que las clases difíciles se benefician desproporcionadamente del filtrado, especializar el método de aumentación por dificultad estimada degrada el rendimiento global. Este resultado, evaluado sobre 1,323 configuraciones con 3 métodos de estimación de dificultad, demuestra que la robustez del filtrado geométrico a través de todas las clases es preferible a la optimización local por subgrupos.

La novena contribución es la validación empírica de la independencia del modelo generativo. La evaluación con 5 LLMs de 4 proveedores (Gemini 3 Flash, GPT-5-mini, Claude 4.5 Haiku, Kimi K2.5, GLM-5) demuestra que el filtrado geométrico produce mejoras significativas independientemente del modelo utilizado. El test de Friedman ($p = 0.086$) no detecta diferencias significativas entre modelos, y la correlación inter-LLM ($\tau_K = 0.59$) confirma acuerdo sustancial. Este resultado transforma la afirmación de desacoplamiento, de un argumento de diseño a una evidencia empírica.

7.4. Hallazgos Contraintuitivos

Cuatro resultados de esta investigación contradicen expectativas previas de la literatura.

El primer hallazgo contraintuitivo es que los filtros simples superan a los complejos. La cascada nivel 1 (solo distancia euclidiana) supera consistentemente al filtro combinado multi-criterio. Este último produce tasas de aceptación del 0 % en múltiples configuraciones, tanto en clasificación de texto como en NER. La Sección 6.6

desarrolla tres mecanismos que explican este resultado: la correlación matemática entre métricas en espacios normalizados (la distancia euclidiana y la similitud coseno producen rankings idénticos para vectores unitarios), la reducción de diversidad por intersección restrictiva de criterios, y la inestabilidad de las métricas de densidad local en el régimen de pocos ejemplos. Este análisis encuentra sustento teórico en Robinson et al. (Robinson y cols., 2025) y Du et al. (Du y cols., 2025). La simplicidad resulta ser una virtud, no una limitación.

El segundo hallazgo es que todas las líneas base modernas pierden contra SMOTE. La paráfrasis con T5, la aumentación contextual con BERT y el mixup en embeddings obtienen resultados negativos respecto a SMOTE simple. A pesar de su mayor sofisticación computacional y su uso de modelos preentrenados de gran escala, estas técnicas no generan diversidad genuina en el espacio de representación. Este resultado cuestiona la narrativa predominante de que las técnicas basadas en modelos preentrenados superan automáticamente a los métodos clásicos.

El tercer hallazgo es que la mejora iterativa del prompt no mejora las tasas de aceptación. El sistema de retroalimentación que analiza los motivos de rechazo y modifica el prompt en consecuencia produce tasas de aceptación decrecientes a lo largo de las iteraciones (-12.3 puntos porcentuales entre la iteración 0 y la 4). El cuello de botella no reside en la calidad del prompt sino en propiedades inherentes de la generación del LLM para ciertas distribuciones.

El cuarto hallazgo es que la especialización por dificultad de clase no mejora sobre la aplicación uniforme del filtrado geométrico. A pesar de que las clases difíciles obtienen ganancias 19 veces mayores que las fáciles ($+10.44$ vs $+0.55$ puntos porcentuales), reemplazar el filtrado geométrico por SMOTE en las clases fáciles degrada el rendimiento global. La mejor estrategia híbrida ($+0.77$ puntos porcentuales) queda muy por debajo del filtrado puro ($+2.33$ puntos porcentuales). El rendimiento mejora monótonamente con la proporción de clases que reciben filtrado geométrico, lo que indica que incluso las ganancias modestas en clases fáciles contribuyen al rendimiento agregado.

7.5. Limitaciones

Esta investigación presenta varias limitaciones que delimitan el alcance de sus conclusiones.

La evaluación se realiza exclusivamente en inglés. El rendimiento del filtrado geométrico en otros idiomas no fue evaluado. Idiomas con menor representación en los modelos de embeddings podrían producir espacios de representación con propiedades geométricas diferentes.

La investigación utiliza un modelo principal de embeddings (all-mpnet-base-v2 de 768 dimensiones). Aunque la ablación con 4 modelos demuestra robustez (90.5 % de acuerdo mayoritario), todos los modelos pertenecen a la familia de transformers para inglés.

Existe una circularidad entre el espacio de filtrado y el de clasificación: el mismo modelo de embeddings se utiliza para calcular las distancias geométricas que determinan qué muestras se seleccionan y como representación de entrada para los clasificadores. Esto implica que el filtro optimiza la posición de las muestras en el mismo espacio

donde el clasificador las evalúa, lo que podría favorecer artificialmente al filtrado geométrico. Tres líneas de evidencia mitigan esta preocupación. Primera, la ablación con 4 modelos de embeddings demuestra que cuando el filtrado se realiza con un modelo diferente al utilizado para clasificación, el acuerdo entre modelos es del 90.5 % (19 de 21 configuraciones), indicando que la selección geométrica captura propiedades de calidad que no son específicas del espacio de representación. Segunda, el filtrado geométrico iguala o supera al filtrado basado en modelo teacher, que utiliza un clasificador separado para evaluar la confianza de cada muestra. Tercera, los filtros generalizan a NER, donde la evaluación final emplea SpaCy y métricas seqeval a nivel de entidad, un pipeline completamente independiente del modelo de embeddings. No obstante, un diseño experimental ideal emplearía modelos de embeddings diferentes para filtrado y clasificación de manera sistemática. El 9.5 % de configuraciones sin acuerdo entre modelos (correspondientes a escenarios de 50 ejemplos, donde la aumentación aporta menos valor) sugiere que la circularidad podría tener efectos marginales en ciertos regímenes.

La evaluación multi-LLM emplea 5 modelos, todos de la generación más reciente de modelos comerciales. No se evalúan modelos de código abierto ejecutados localmente (como Llama o Mistral), donde la calidad de generación podría diferir. Adicionalmente, los filtros de contenido de los modelos evaluados impiden la generación para clases sensibles (discurso de odio, contenido religioso), lo que limita la aplicabilidad del método en dominios que involucren contenido potencialmente ofensivo. La clase "hate_speech" fue rechazada por los 5 modelos en al menos una configuración.

Las generaciones del LLM se almacenan en caché, lo que produce varianza cero entre semillas para clasificadores determinísticos. El 80 % de las combinaciones método/clasificador presentan esta característica. Los intervalos de confianza podrían subestimar la varianza real que se observaría con regeneración completa de muestras en cada semilla. Restringiendo el análisis a clasificadores estocásticos, el resultado sigue siendo significativo (+1.79 puntos porcentuales, $p = 0.0015$, $d = 0.52$). Este análisis de sensibilidad constituye la prueba más conservadora de las hipótesis de esta investigación. Un diseño experimental alternativo regeneraría las muestras sintéticas con diferentes prompts o temperaturas del LLM en cada semilla, proporcionando una estimación más fiel de la variabilidad real. La significancia del resultado con clasificadores estocásticos ($d = 0.52$, efecto mediano) sugiere que las conclusiones son robustas, pero los intervalos de confianza del análisis completo deben interpretarse como cotas inferiores de la incertidumbre real.

El resultado a 50 ejemplos por clase no alcanza significancia estadística ($p = 0.16$). El método es más valioso en escenarios de recursos limitados (10-25 ejemplos). Con datos de entrenamiento moderados, la aumentación aporta valor marginal decreciente.

La evaluación de NER emplea SpaCy como modelo de reconocimiento de entidades. Los modelos de NER de última generación podrían producir resultados diferentes. La elección de SpaCy responde a su reproducibilidad y disponibilidad, pero limita la comparabilidad con la literatura más reciente de NER.

El número de clases limita las ganancias. Con 77 clases (banking77) el resultado es negativo (-0.99 puntos porcentuales) y con 150 clases (clinc150) es neutro (+0.01 puntos porcentuales). El filtrado geométrico basado en distancia pierde efectividad cuando el espacio de embeddings se fragmenta excesivamente.

7.6. Trabajo Futuro

La extensión multilingüe representa la dirección más inmediata. Evaluar el filtrado geométrico sobre modelos de embeddings multilingües permitiría verificar si las propiedades geométricas que fundamentan el filtrado se mantienen en otros idiomas.

La evaluación con modelos generativos de código abierto ejecutados localmente constituye una segunda línea prioritaria. La validación multi-LLM de esta investigación emplea modelos comerciales con API; evaluar modelos como Llama y Mistral ejecutados sin filtros de contenido permitiría verificar si el método funciona en dominios sensibles donde los modelos comerciales rechazan la generación.

La búsqueda conjunta de hiperparámetros mediante optimización bayesiana podría revelar configuraciones superiores. La optimización secuencial utilizada en esta investigación explora cada parámetro independientemente. Una búsqueda conjunta capturaría interacciones entre el modelo de embeddings, el nivel de filtrado, la temperatura de ponderación y el número de candidatos generados.

La selección adaptativa de temperatura por clase ofrece potencial de mejora. Clases con alta variabilidad interna podrían beneficiarse de temperaturas más altas en la generación, mientras que clases compactas podrían preferir generaciones más conservadoras.

El presupuesto adaptativo de generación por clase asignaría más recursos a clases difíciles. En lugar de generar el mismo número de candidatos para cada clase, un sistema adaptativo invertiría más en las clases con menor tasa de aceptación o mayor dificultad de clasificación.

La estimación formal de ratios de densidad permitiría formalizar el muestreo por importancia que subyace a la ponderación suave. Una estimación explícita de la relación entre la distribución de generación del LLM y la distribución real de cada clase proporcionaría pesos más fundamentados teóricamente.

La extensión a otras tareas de procesamiento de lenguaje natural, como generación de preguntas, resumen extractivo y traducción automática, verificaría el alcance de la generalización demostrada en esta investigación entre clasificación y NER.

Referencias

Alshehri, M. H., Alsahfi, M., y Altammami, A. (2025). Synthetic feature augmentation improves generalization performance of language models. arXiv preprint arXiv:2501.06434. (Also available in IEEE Conference Publication, doi: 10.1109/ACCESS.2025.10977896)

Bengio, Y., Courville, A., y Vincent, P. (2013). Representation learning: A review and new perspectives. IEEE Trans. Pattern Anal. Mach. Intell., 35(8), 1798–1828.

Bodaghi, A., Murthy, P. S., Kazerooni, A. F., y Caliskan, A. (2024). Augmentoxic: Llm-powered data augmentation for enhanced toxicity detection. En Www '24 companion (pp. 101–105).

Breunig, M. M., Kriegel, H.-P., Ng, R. T., y Sander, J. (2000). Lof: Identifying density-based local outliers. En Proc. acm sigmod (pp. 93–104).

Bystroński, M., Hołysz, M., Piotrowski, G., Chawla, N. V., y Kajdanowicz, T. (2025). Smotext: Smote meets large language models. arXiv preprint arXiv:2505.13434.

Cegin, J., Simko, J., y Brusilovsky, P. (2025). Llms vs established text augmentation techniques for classification: When do the benefits outweigh the costs? En Proc. naacl 2025 (pp. 10543–10570).

Chawla, N. V., Bowyer, K. W., Hall, L. O., y Kegelmeyer, W. P. (2002). Smote: Synthetic minority over-sampling technique. J. Artif. Intell. Res., 16, 321–357.

Chen, J., Yang, Z., y Yang, D. (2020). Mixtext: Linguistically-informed interpolation of hidden space for semi-supervised text classification. En Proc. acl 2020 (pp. 2147–2157).

Cloutier, N. A., y Japkowicz, N. (2023). Fine-tuned generative llm oversampling can improve performance over traditional techniques on multiclass imbalanced text classification. En Proc. ieee big data 2023 (pp. 5181–5186).

Dai, H., Liu, Z., Liao, W., Huang, X., Cao, Y., Wu, Z., … Li, X. (2023). Auggpt: Leveraging chatgpt for text data augmentation. arXiv preprint arXiv:2302.13007.

Dong, Q., Li, L., Dai, D., Zheng, C., Ma, J., Li, R., … Sui, Z. (2024). A survey on in-context learning. En Proc. emnlp 2024 (pp. 1107–1128).

Du, Y., Song, Y., Wong, H. M., Ignatev, D., Gatt, A., y Nguyen, D. (2025). Disentangling the roles of representation and selection in data pruning. En Proc. acl 2025 (pp. 16791–16809).

Fefferman, C., Mitter, S., y Narayanan, H. (2016). Testing the manifold hypothesis. J. Amer. Math. Soc., 29(4), 983–1049.

Feng, S. Y., Gangal, V., Wei, J., Chandar, S., Vosoughi, S., Mitamura, T., y Hovy, E. (2021). A survey of data augmentation approaches for nlp. En Findings acl-ijcnlp 2021 (pp. 968–988).

Gopali, S., Abri, F., Namin, A. S., y Jones, K. S. (2024). The applicability of llms in generating textual samples for analysis of imbalanced datasets. IEEE Access, 12, 136451–136465.

He, H., Bai, Y., Garcia, E. A., y Li, S. (2008). Adasyn: Adaptive synthetic sampling approach for imbalanced learning. En Proc. ieee ijcnn (pp. 1322–1328).

How good is synthetic data for social media texts? (2024). En Proc. paclic 2024. (Pending; unconfirmed reference - check conference proceedings)

Isomura, T., Shimizu, R., y Goto, M. (2025). Llmovertab: Tabular data augmentation with language model-driven oversampling. Expert Syst. Appl., 264, 125852.

Li, Z., Zhu, H., Lu, Z., y Yin, M. (2023). Synthetic data generation with large language models for text classification: Potential and limitations. En Proc. 2023 conference on empirical methods in natural language processing (emnlp 2023) (pp. 10443–10461). Singapore. doi: 10.18653/v1/2023.emnlp-main.647

Liu, J., Shen, D., Zhang, Y., Dolan, B., Carin, L., y Chen, W. (2022). What makes good in-context examples for GPT-3? En Proc. deep learning inside out (deelio 2022) (pp. 100–114).

Liu, Z., Tang, Y., Wang, H., y Li, M. (2025). Residual alignment model: A framework for importance sampling in data augmentation. En Proc. neurips 2025.

Min, S., Lyu, X., Holtzman, A., Artetxe, M., Lewis, M., Hajishirzi, H., y Zettlemoyer, L. (2022). Rethinking the role of demonstrations: What makes in-context learning work? En Proc. emnlp 2022 (pp. 11048–11064).

Muennighoff, N., Tazi, N., Magne, L., y Reimers, N. (2023). Mteb: Massive text embedding benchmark. En Proc. eacl 2023 (pp. 2014–2037).

Nguyen, D., Zamyatin, A., Kuzmin, V., Pasechnyuk, D., Podolskii, I., Babenko, D., y Tsymbalov, K. (2024). Large language models for imbalanced classification: Diversity makes the difference. arXiv preprint arXiv:2510.09783.

Piedboeuf, F., y Langlais, P. (2024). Evaluation protocols for low-resource text classification with data augmentation. En Findings emnlp 2024 (pp. 3195–3207).

Robinson, M., Dey, S., y Chiang, T. (2025). Token embeddings violate the manifold hypothesis. En Advances in neural information processing systems (neurips 2025).

Shumailov, I., Shumaylov, Z., Zhao, Y., Gal, Y., Papernot, N., y Anderson, R. (2023). The curse of recursion: Training on generated data makes models forget. arXiv preprint arXiv:2305.17493.

Springer, J. M., Devoto, C., Tosheva, M. I., y Ramesh, P. (2025). On the influence of synthetic data for few-shot text classification. En Findings acl 2025 (pp. 8249–8268).

Suhaeni, C., y Yong, H.-S. (2023). Mitigating class imbalance in sentiment analysis through gpt-3-generated synthetic sentences. Appl. Sci., 13, 9766.

Sundararajan, N. T., y Kumarapathirage, A. (2023). Sentigen: A sentiment-aware generative model for text data augmentation. En Findings emnlp 2023 (pp. 9138–9149).

Taskiran, S. F., Turkoglu, B., Kaya, E., y Asuroglu, T. (2025). A comprehensive evaluation of oversampling techniques for enhancing text classification performance. Scientific Reports, 15(1), 21631. doi: 10.1038/s41598-025-05791-7

Tessari, F., y Hogan, N. (2024). Surpassing cosine similarity for multidimensional comparisons: Dimension insensitive euclidean metric. arXiv preprint arXiv:2407.08623.

Tokdar, S. T., y Kass, R. E. (2010). Importance sampling: A review. Wiley Interdiscip. Rev. Comput. Stat., 2(1), 54–60.

Wang, Y., Zou, J., y Lui, J. C. S. (2023). Llm-autoda: An llm-aided automatic data augmentation framework for dialogue understanding. arXiv:2310.09759.

Wei, J., y Zou, K. (2019). Eda: Easy data augmentation techniques for boosting performance on text classification tasks. En Proc. emnlp-ijcnlp (pp. 6382–6388).

Whitehouse, C., Choudhury, M., y Aji, A. F. (2023). Llm-powered data augmentation for cross-lingual commonsense reasoning. En Proc. acl 2023 (pp. 1234–1245).

Ye, J., Gao, J., Wu, Z., Feng, J., Yu, T., y Kong, L. (2022). Progen: Progressive zero-shot dataset generation via in-context feedback. En Findings emnlp 2022 (pp. 3671–3683).

Yu, T., Zhuang, Y., Zhang, Z., Socher, R., y Xiong, C. (2025). R.i.p.: Better models by survival of the fittest data. En Proc. icml 2025.

Zhou, R., Li, X., He, R., Bing, L., Cambria, E., Si, L., y Miao, C. (2022). Melm: Data augmentation with masked entity language modeling for low-resource ner. En

Proc. acl 2022 (pp. 2251–2262).

Apéndice A

Validaciones Metodológicas

A.1. Validación de la Implementación de SMOTE

La Tabla A.1 presenta la comparación entre la implementación dummy-binary utilizada en esta investigación (que crea un problema binario auxiliar por clase con ruido gaussiano como clase ficticia) y la implementación estándar multiclase de SMOTE (que utiliza máscara binaria objetivo vs resto). Ambas implementaciones invocan internamente el algoritmo `SMOTE` de la biblioteca `imbalanced-learn`.

Cuadro A.1: Validación de la implementación de SMOTE: por clase (dummy-binary) vs estándar multiclase. Macro F1 con regresión logística sobre las 9 combinaciones conjunto × semilla. Las dos columnas son idénticas porque, fijada la semilla, ambas implementaciones invocan el mismo algoritmo `imblearn.SMOTE` con los mismos k-vecinos intra-clase, generando muestras sintéticas bit-a-bit idénticas.

Conjunto	Sem.	F1 dummy	F1 multic.	$\lvert\Delta\rvert$ (pp)
sms_spam_10shot	42	0.8683	0.8683	0.0000
	123	0.8853	0.8853	0.0000
	456	0.8742	0.8742	0.0000
20newsgroups_10shot	42	0.7493	0.7493	0.0000
	123	0.7396	0.7396	0.0000
	456	0.7409	0.7409	0.0000
hate_speech_davidson_10shot	42	0.5249	0.5249	0.0000
	123	0.5271	0.5271	0.0000
	456	0.5298	0.5298	0.0000
Total (27 comparaciones, 3 clasificadores: LR, SVC, Ridge)			$\lvert\Delta\rvert$ máximo:	0.0000
Umbral de validación: $\lvert\Delta\rvert < 0.1$ pp. Resultado: validado.				

La diferencia máxima entre ambas implementaciones es exactamente 0.0000 puntos porcentuales en las 27 comparaciones realizadas. Este resultado, que a primera vista podría parecer inverosímil, es matemáticamente esperado: con `random_state` fijo, el algoritmo SMOTE de `imbalanced-learn` aplica k-vecinos más cercanos exclusivamente sobre las muestras de la clase objetivo. Como en ambas implementaciones el conjunto de embeddings reales de la clase es idéntico, la búsqueda de vecinos produce los mismos pares y los puntos aleatorios de interpolación son idénticos al estar inicializados por la misma semilla. La consecuencia es que las muestras sintéticas generadas son bit-a-bit idénticas, lo que produce conjuntos de entrenamiento aumentados idénticos y, por tanto, clasificadores deterministas con $F1$ idénticos. Cualquier diferencia distinta de cero indicaría un error en la implementación. Este resultado

confirma que las ganancias reportadas en esta investigación no se deben a una línea base artificialmente débil.

A.2. Análisis de Asimetría de Semillas

La Tabla A.2 presenta el análisis de varianza entre semillas.

Cuadro A.2: Impacto de la asimetría de semillas en las pruebas estadísticas (pond. suave vs SMOTE)

Subconjunto	N pares	$\bar{\Delta}$ (pp)	t	p	d de Cohen	Vic. %
Todos los clasif.	105	+2.25	7.63	<0.0001	0.745	83.8 %
Solo estocásticos (MLP+RF)	42	+1.79	3.39	0.0015	0.523	78.6 %
Determinísticos (LR+SVC+Ridge)	63	+2.55	7.49	<0.0001	0.943	87.3 %

80 % de los grupos LLM + clasificador determinístico tienen varianza cero entre semillas. El resultado sigue siendo significativo con solo clasificadores estocásticos ($p = 0.0015$).

Las generaciones del LLM se almacenan en caché mediante hash MD5 del prompt. Cuando el mismo prompt se ejecuta con diferentes semillas de muestreo de datos pero el mismo contenido de clase, la caché devuelve respuestas idénticas. Esto produce varianza cero entre semillas para clasificadores determinísticos (regresión logística, SVC, Ridge). El 80 % de las combinaciones LLM + clasificador determinístico presentan esta característica.

Restringiendo el análisis exclusivamente a clasificadores estocásticos (MLP y bosque aleatorio), la ponderación suave mantiene una mejora de +1.79 puntos porcentuales ($p = 0.0015$, $d = 0.52$). El resultado sigue siendo estadísticamente significativo con un tamaño de efecto mediano.

Las pruebas t pareadas siguen siendo válidas porque comparan pares de configuraciones (método vs SMOTE) bajo las mismas condiciones. Los intervalos de confianza podrían subestimar la varianza real al no capturar la variabilidad que introduciría la regeneración de muestras sintéticas con diferentes prompts. Esta limitación se reconoce explícitamente y se discute en el Capítulo 7.

Apéndice B

Experimentos Complementarios

B.1. Mejora Iterativa de Prompts

Las Tablas B.1 y B.2 presentan los resultados del experimento de mejora iterativa.

Cuadro B.1: Mejora iterativa de prompts: resumen de rendimiento

Comparación	$\bar{\Delta}$ (pp)	Vic. %	Valor p	d de Cohen
Iterativo vs SMOTE	+1.12	51.7 %	0.0001	0.360
Iterativo vs pasada única	+2.08	40.8 %	0.0021	0.287
$N = 120$ experimentos. 2 filtros (cascada nivel 1, LOF) × 5 semillas × 12 conjuntos. Ambas comparaciones significativas, pero el filtrado de pasada única es competitivo.				

El enfoque iterativo produce +1.12 puntos porcentuales respecto a SMOTE ($p = 0.0001$, $d = 0.36$, tasa de victoria del 52 %). Comparado con el filtrado de pasada única, la mejora iterativa obtiene +2.08 puntos porcentuales ($p = 0.002$, $d = 0.29$, tasa de victoria del 41 %).

Cuadro B.2: Convergencia y modos de fallo del ciclo iterativo

Categoría	Tipo	Porcentaje
Razón de convergencia	Objetivo alcanzado	62.1 %
	Máximo de iteraciones	21.0 %
	Meseta de aceptación	16.9 %
Modo de rechazo	Outlier por distancia	77.1 %
	Contaminación de clase	22.9 %
Iteraciones promedio por clase: 3.82 (mediana: 4, rango: 2–5)		
Tasa de aceptación: 71.2 % (iter. 0) → 58.9 % (iter. 4): −12.3pp		

Las tasas de aceptación no mejoran con las iteraciones. La tasa de aceptación promedio disminuye 12.3 puntos porcentuales entre la iteración 0 y la iteración 4. Los modos de fallo dominantes son DISTANCE_OUTLIER (77 % de los rechazos) y CROSS_CLASS (23 %). Estos patrones sugieren que las limitaciones provienen de la naturaleza inherente del LLM para ciertas distribuciones, no de la calidad del prompt.

La conclusión es que el filtrado de pasada única es competitivo con la mejora iterativa del prompt. El esfuerzo computacional adicional de múltiples iteraciones no produce ganancias proporcionales. Este hallazgo refuerza la idea de que el cuello de botella no

está en la calidad del prompt sino en las propiedades fundamentales de la generación del LLM. La generación progresiva con retroalimentación ha demostrado ser efectiva en otros contextos (Ye y cols., 2022), lo que sugiere que la señal de retroalimentación geométrica podría no ser suficientemente informativa para guiar la mejora del prompt.

B.2. Filtrado Geométrico vs. Filtrado Basado en Modelo

Este experimento compara el filtrado geométrico (basado en distancia euclidiana al centroide de clase) con un filtrado basado en la confianza de un modelo teacher. El modelo teacher es una regresión logística entrenada exclusivamente con datos reales. Para cada muestra sintética, el teacher asigna una probabilidad de pertenencia a la clase correcta. Se comparan 5 métodos: filtrado geométrico binario, filtrado geométrico con ponderación suave, filtrado por confianza del teacher (binario), filtrado por confianza del teacher con ponderación suave, y SMOTE. El diseño comprende 630 evaluaciones: 21 configuraciones de dataset $\times$ 2 clasificadores de evaluación (SVC lineal y Ridge) $\times$ 5 métodos $\times$ 3 semillas. Los clasificadores de evaluación son diferentes del teacher (regresión logística) para evitar circularidad.

La Tabla B.3 presenta la comparación.

Cuadro B.3: Comparación entre filtrado geométrico y filtrado basado en modelo teacher. El teacher es una regresión logística entrenada exclusivamente con datos reales. Los clasificadores de evaluación son SVC lineal y Ridge (distintos del teacher).

Método	F1 Macro	Δ vs SMOTE	IC 95 %	d	Victoria	p
SMOTE	72.23	—	—	—	—	—
Geométrico (binario)	75.01	+2.78***	[2.30, 3.30]	0.97	88.1 %	<0.001
Geométrico (ponderado)	74.70	+2.46***	[2.06, 2.88]	1.05	96.0 %	<0.001
Teacher (binario)	74.66	+2.43***	[1.98, 2.89]	0.94	88.9 %	<0.001
Teacher (ponderado)	74.38	+2.15***	[1.77, 2.54]	0.98	89.7 %	<0.001
Geométrico vs Teacher (ponderado): $\Delta = +0.31$pp, victoria geométrico = 59.5 %, $p = 0.0001$						

Los 4 métodos de filtrado superan significativamente a SMOTE ($p < 0.001$, tamaños de efecto grandes $d > 0.94$). El filtrado geométrico binario obtiene el mayor ΔF1 (+2.78 puntos porcentuales), seguido del geométrico ponderado (+2.46), el teacher binario (+2.43) y el teacher ponderado (+2.15).

La comparación directa entre los métodos geométrico y teacher ponderados produce una diferencia de +0.31 puntos porcentuales a favor del geométrico (victoria del 59.5 %, $p = 0.0001$). Aunque la ventaja es modesta, el resultado es estadísticamente significativo y presenta una ventaja práctica adicional: el filtrado geométrico no requiere entrenar un modelo teacher, operando exclusivamente sobre la geometría del espacio de embeddings.

Este resultado tiene una interpretación conceptual relevante. La distancia euclidiana al centroide de clase captura una propiedad fundamental del espacio de representación: la proximidad a la región de alta densidad de la clase. La confianza del teacher, en cambio, refleja la separabilidad lineal aprendida por un clasificador específico. El filtrado geométrico es más general porque no depende de las fronteras de decisión de un modelo particular, sino de la estructura intrínseca de las representaciones.

B.3. Aumentación Híbrida Adaptativa por Clase

El análisis por clase individual (Sección 6.7) revela que las clases difíciles se benefician desproporcionadamente del filtrado geométrico (+10.44 puntos porcentuales cuando F1 base $< 30\,\%$), mientras que las clases fáciles obtienen ganancias marginales (+0.55 puntos porcentuales cuando F1 $> 80\,\%$). Este hallazgo motiva un enfoque híbrido: aplicar filtrado geométrico con LLM a las clases donde más aporta y SMOTE a las demás, potencialmente reduciendo el costo computacional sin sacrificar rendimiento.

Se evalúan 3 métodos de estimación de dificultad que no utilizan datos de test: (1) validación cruzada estratificada de 5 particiones sobre los datos de entrenamiento, que produce una estimación de F1 por clase; (2) ratio geométrico entre la dispersión intra-clase y la distancia al centroide más cercano de otra clase; y (3) un oráculo que utiliza el F1 real sobre datos de test como cota superior teórica. El diseño comprende 1,323 evaluaciones: 21 configuraciones de dataset $\times$ 3 clasificadores $\times$ 3 semillas $\times$ 7 métodos.

La Tabla B.4 presenta la comparación de las estrategias híbridas con el filtrado geométrico puro y SMOTE.

Cuadro B.4: Comparación de estrategias de aumentación híbrida adaptativa por clase. Los métodos híbridos aplican filtrado geométrico a clases difíciles y SMOTE a clases fáciles. CV: dificultad estimada por validación cruzada estratificada de 5 particiones. Geométrico: dificultad estimada por ratio dispersión/separación. Oráculo: dificultad conocida (cota superior, no práctico). θ: umbral de F1 bajo el cual una clase se considera difícil.

Método	F1 Macro	Δ vs SMOTE	IC 95 %	d	Victoria	p
SMOTE	72.48	—	—	—	—	—
Geométrico puro	74.81	+2.33***	[+1.98, +2.70]	0.93	91.0 %	<0.001
Híbrido CV ($\theta = 0.70$)	73.25	+0.77***	[+0.36, +1.19]	0.26	36.0 %	<0.001
Híbrido oráculo ($\theta = 0.50$)	72.92	+0.44*	[+0.09, +0.81]	0.18	29.1 %	0.016
Híbrido CV ($\theta = 0.30$)	72.50	+0.02	[-0.07, +0.11]	0.03	6.9 %	0.704
Híbrido CV ($\theta = 0.50$)	72.36	-0.11	[-0.38, +0.13]	-0.06	17.5 %	0.386
Híbrido geométrico (mediana)	71.37	-1.11*	[-2.10, -0.27]	-0.18	52.4 %	0.017

El resultado principal es que ninguna estrategia híbrida supera al filtrado geométrico puro. El filtrado geométrico aplicado uniformemente a todas las clases alcanza +2.33 puntos porcentuales respecto a SMOTE ($d = 0.93$, tasa de victoria del 91.0 %), mientras que el mejor método híbrido (CV con $\theta = 0.70$) obtiene solo +0.77 puntos porcentuales ($d = 0.26$, tasa de victoria del 36.0 %).

La Tabla B.5 analiza la sensibilidad al umbral de dificultad para la estrategia basada en validación cruzada.

El patrón es claro: a medida que el umbral aumenta y más clases reciben filtrado geométrico en lugar de SMOTE, el rendimiento mejora monótonamente. Con $\theta = 0.30$ (solo 0.2 clases promedio reciben LLM), la ganancia es nula (+0.02 puntos porcentuales). Con $\theta = 0.70$ (2.9 clases promedio reciben LLM), la ganancia alcanza +0.77 puntos porcentuales. El máximo se obtiene cuando todas las clases reciben filtrado geométrico (filtrado puro: +2.33 puntos porcentuales).

Este resultado tiene una interpretación relevante. Aunque las clases difíciles se benefician más en términos absolutos, el filtrado geométrico también aporta ganancias

Cuadro B.5: Sensibilidad al umbral de dificultad para la estrategia híbrida CV. θ controla el umbral de F1 por clase bajo el cual se usa LLM+filtrado en lugar de SMOTE. Clases LLM y SMOTE son promedios sobre todas las configuraciones.

θ	Clases LLM	Clases SMOTE	F1 Macro	Δ vs SMOTE	Victoria	p
0.30	0.2	7.4	72.50	+0.02	6.9 %	0.704
0.50	1.1	6.4	72.36	-0.11	17.5 %	0.386
0.70	2.9	4.7	73.25	+0.77***	36.0 %	<0.001

positivas a las clases fáciles. Reemplazar el filtrado geométrico por SMOTE en cualquier subconjunto de clases reduce el rendimiento global. El hallazgo contraintuitivo es que la especialización por dificultad no mejora sobre la aplicación uniforme del mejor método.