Aumentación de Datos con LLMs

Filtrado Geométrico para Clasificación de Texto en Pocos Ejemplos

UAI | FACULTAD DE INGENIERÍA Y CIENCIAS

Benjamín Schindler

1 de junio de 2026

Facultad de Ingeniería y Ciencias
Universidad Adolfo Ibáñez

Profesor guía

Dr. Gonzalo A. Ruz

Grados a optar

Master of Science in Data Science
Ingeniería Civil Informática
Ingeniería Civil Industrial

Comité de defensa

Dr. Luis Aburto
Dr. Rolando De La Cruz
Dr. Pablo Henríquez
Dr. Andrés Peters

Hoja de ruta

1. **Introducción** — desbalance, voces que se callan y por qué las clases raras suelen ser las que más importan.
2. **Problema** — escasez de datos, el marco clásico del re-muestreo y la pregunta central.
3. **Estado del arte** — tres familias de aumentación, tres deficiencias persistentes y una década de evolución.
4. **Hipótesis y objetivos** — qué afirmamos y cómo se va a verificar.
5. **Metodología** — cinco filtros geométricos, ponderación suave y un pipeline desacoplado del LLM.
6. **Resultados** — 8.000+ configuraciones, +2.25 pp sobre SMOTE y un hallazgo contra-intuitivo.
7. **Discusión** — utilidad práctica, limitaciones honestas y trabajo futuro.

1.
Introducción

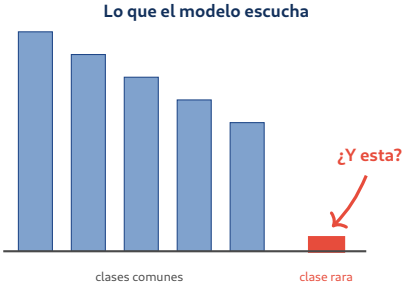
1. Introducción
2. Problema
3. Estado del arte
4. Hipótesis
5. Metodología
6. Resultados
7. Discusión

¿Estamos escuchando todas las voces?

Un clasificador aprende **de lo que ve**. Y la realidad rara vez se reparte por partes iguales:

- **Un** correo de phishing con un esquema nunca antes visto.
- Notas clínicas con síntomas raros: **un puñado** de menciones.
- **Un** mensaje de auxilio entre miles de consultas rutinarias.
- Discurso de odio en lenguas minorizadas: **decenas** de ejemplos.

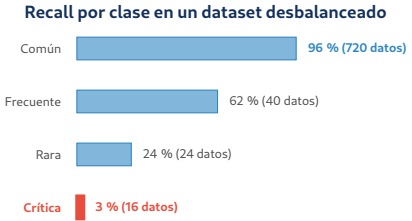
Lo común se escucha. Lo raro se calla.
¿Cómo mejorar esas clases si apenas tenemos datos?



¿Cómo aprende un modelo lo que apenas escucha?

Cuando lo poco escuchado es lo que más importa

Un modelo puede ser **correcto en el 95 % de los casos** y, aun así, **fallar en el 100 % de los que importan**.



Precisión global
95 %

Recall en clase crítica
3 %

El mismo modelo.
Dos verdades.

La voz que el modelo **no escuchó**
suele cargar con el mayor **costo humano**.

¿Cómo le enseñamos a un modelo a reconocer aquello que casi no ha visto?

2.
Problema

1. Introducción
2. Problema
3. Estado del arte
4. Hipótesis
5. Metodología
6. Resultados
7. Discusión

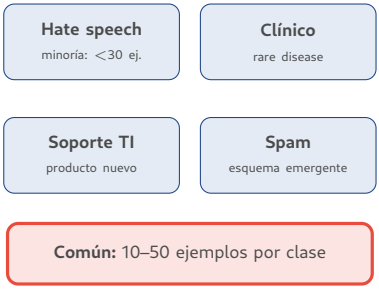
Escasez de datos: un problema cotidiano

Dominios cotidianos en clasificación de texto:
Triaje clínico · tickets de soporte · spam · discurso de odio.

Por qué duele:

- Etiquetado humano = caro, lento y sesgado.
- Las clases raras suelen ser **las que más importan**: urgencias, fraudes, diagnósticos.
- Pocos ejemplos $\Rightarrow$ el modelo **sobreajusta** y no generaliza a casos nuevos.
- Multiclase + desbalance $\Rightarrow$ el rendimiento en clases raras colapsa.

[Gopali 2024; Whitehouse 2023]



Re-muestreo: el paraguas que une a SMOTE y a los LLMs

La estadística clásica enmarca la escasez desde hace décadas como un problema de re-muestreo. Ambas familias caben aquí.

Undersampling

Reduce la clase mayoritaria.

Ejemplos: muestreo aleatorio, NearMiss, Tomek Links.

✓ Más rápido al entrenar.
✗ Pierde información. Inviable en few-shot.

Oversampling

Aumenta la clase minoritaria.

Ejemplos: duplicación, **SMOTE**, ADASYN, EDA, **LLMs**.

✓ Conserva todos los datos.
✗ Riesgo de overfitting, ruido o divergencia.

Dentro de **oversampling** se concentra todo el aumento sintético: desde **SMOTE (2002)** hasta los **LLMs (2023+)**.

¿Qué métodos existen, cómo funcionan y funcionan siempre?

3.
Estado del arte

1. Introducción
2. Problema
3. Estado del arte
4. Hipótesis
5. Metodología
6. Resultados
7. Discusión

Familia 1 — SMOTE y ADASYN: interpolación geométrica

SMOTE [Chawla et al., 2002] y **ADASYN** [He et al., 2008] son los métodos canónicos de oversampling.

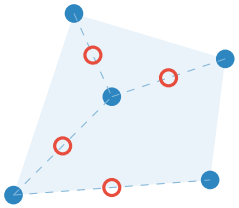
Idea:

- Para cada muestra minoritaria x_i, encontrar sus k vecinos más cercanos de la misma clase.
- Generar muestras nuevas sobre los segmentos:

$$x_{new} = x_i + \lambda\,(x_j - x_i), \quad \lambda \in [0, 1]$$

Diferencia clave:

- ADASYN pesa más las muestras difíciles (rodeadas de otra clase).



• reales ○ sintéticos

Interpolación entre k-NN

✓ Geometría controlada. ✓ Garantías formales.

✗ Genera vectores, no texto. ✗ Solo rellena lo conocido.

Geometría como control: pero la salida es un vector, no una oración.

Familia 2 — Aumentación textual ligera

Entre la interpolación geométrica y la generación libre hay un puente histórico: métodos que producen texto con modelos pequeños y operaciones controladas.

EDA

[Wei & Zou, 2019]

4 ops a nivel **palabra**:
sinónimo, inserción, swap, deleción.

✓ Muy barato.
✗ Ruido en oraciones cortas.

Traducción inversa

[Sennrich 2016; Edunov 2018]

EN → otro idioma → EN.
Paráfrasis a nivel **oración**.

✓ Cambia sintaxis.
✗ Pierde matices.

BERT contextual

[Kobayashi 2018; Wu 2019]

Enmascarar tokens; BERT predice alternativas plausibles.

✓ Contexto semántico.
✗ Solo sustitución 1:1.

Todos producen **texto**, pero con un **techo de creatividad bajo**: paráfrasis cercanas al original. Los LLMs rompen ese techo — y por eso necesitan otro tipo de control.

Familia 3 — LLMs: generación de texto bajo demanda

Pedirle a un LLM (GPT, Gemini, Claude…) que genere ejemplos nuevos para cada clase.

Receta típica [Whitehouse et al., 2023]:

1. Prompt con descripción de clase y ejemplos reales.
2. Pedir N generaciones nuevas.
3. Añadirlas al entrenamiento.



Trabajos representativos:

- Suhaeni & Yong (2024): +12,7 % acc. en minoritarias.
- ImbLLM (2024): control de desbalance vía prompting.
- Cegin et al. (2025): diversidad guiada por LLM.

✓ Texto coherente. ✓ Diversidad lingüística.

✗ Sin garantías geométricas. ✗ Ruido y solapamiento.

Texto sin control: los vectores caen donde quieran.

Familia 3.5 — Fine-tuning para generación sintética

Una rama más reciente: ajustar el LLM sobre la propia tarea antes de generar.

Idea: fine-tunear un LLM preentrenado (GPT-2, LLaMA, T5…) con los pocos ejemplos disponibles, y luego generar muestras específicas del dominio.



Trabajos representativos:

- Cloutier & Japkowicz (2023): fine-tuning generativo supera al re-muestreo tradicional en multiclase desbalanceada.
- ImbLLM (Nguyen et al., 2024): fine-tuning **solo en muestras minoritarias**; F1 $>$ 0.8.
- SentiGEN (Sundararajan, 2023): T5 fine-tuned + validador XLNet.

✓ Distribución alineada con la tarea.

✗ Requiere cómputo extra; riesgo de overfitting con n pequeño.

Más alineamiento, más costo: distinto eje de control al filtrado posterior.

El dilema: SMOTE vs. LLMs lado a lado

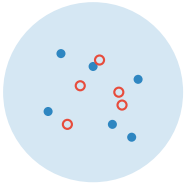
SMOTE / interpolación

✓ Geometría controlada

✓ Garantías formales

✗ Vectores sin texto coherente

✗ Solo rellena lo conocido



Interpolación lineal

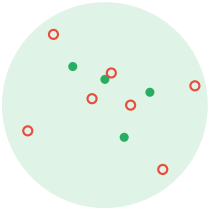
LLM (Gemini, GPT, Claude…)

✓ Texto fluido y coherente

✓ Diversidad lingüística

✗ Geometría descontrolada

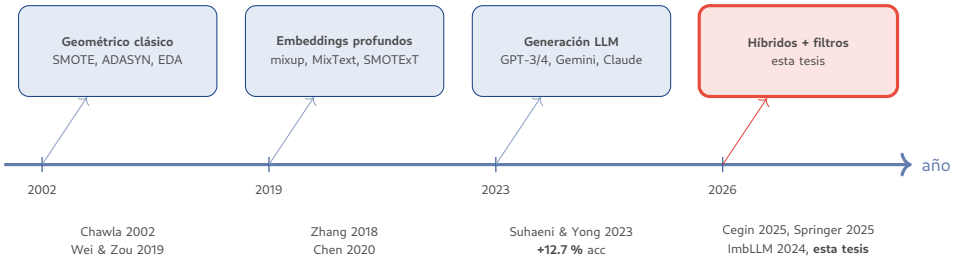
✗ Ruido y solapamiento entre clases



Generación abierta

¿Podemos quedarnos con lo mejor de ambos mundos?

Cuatro paradigmas, una década de evolución



Cada paradigma resuelve un problema y crea otro nuevo.

Tres deficiencias en los métodos actuales

1. Sin validación

Las muestras del LLM se aceptan **todas**, sin verificar si caen en la región correcta del espacio.

Texto gramatical $\neq$ texto en la zona correcta.

2. Peso uniforme

Todas las muestras pesan igual en el clasificador, ignorando la **calidad geométrica** de cada una.

Una en zona densa = una en zona dispersa.

3. Un solo dataset

Casi todos los estudios validan en **un único** corpus o tarea.

¿Generaliza el filtrado entre dominios y tareas?

La señal geométrica está disponible y nadie la está usando.

Una idea simple

¿Y si generamos muchos candidatos con un LLM y dejamos que la **geometría** elija los útiles?



Esta tesis evalúa cuándo esa idea funciona y cuándo no.

El gap metodológico: filtrar la salida del LLM

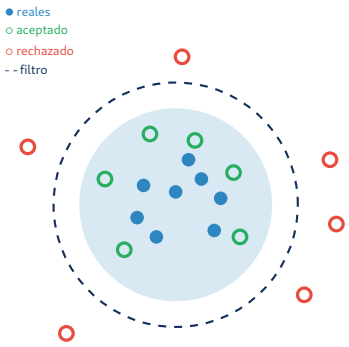
Las deficiencias anteriores apuntan a una intervención conceptualmente simple, no estudiada sistemáticamente.

La idea:

1. Generar N muestras con el LLM (como hoy).
2. Proyectarlas al espacio de embeddings.
3. Medir qué tan cerca caen del **cluster real** de su clase.
4. Rechazar las que se alejan demasiado.

¿Por qué tiene sentido?

- La geometría ya está ahí: usamos embeddings para el clasificador.
- Cero costo extra de generación; el filtro opera a posteriori.
- Agnóstico al LLM concreto.



La señal geométrica ya existe — falta usarla para decidir qué entra al entrenamiento.

Dónde encaja esta propuesta



Contribución: integrar las tres dimensiones por primera vez.

4.
Hipótesis y objetivos

1. Introducción
2. Problema
3. Estado del arte
4. Hipótesis
5. Metodología
6. Resultados
7. Discusión

Hipótesis y objetivos

H1 — Hipótesis principal

El filtrado geométrico de muestras LLM en el espacio de embeddings produce mejoras **estadísticamente significativas** en macro F1 respecto a SMOTE, en clasificación con pocos ejemplos por clase.

Objetivo general

Desarrollar y validar un sistema de filtrado geométrico que opere **exclusivamente en el espacio de embeddings**, **desacoplado del LLM generativo**, y mejore clasificadores de texto en escenarios de pocos ejemplos por clase.

Sub-hipótesis verificables

- **H1a** Filtrado por distancia $>$ sin filtrar.
- **H1b** Ponderación suave $\geq$ filtrado binario.
- **H1c** Generaliza a NER sin modificación.

Objetivos específicos

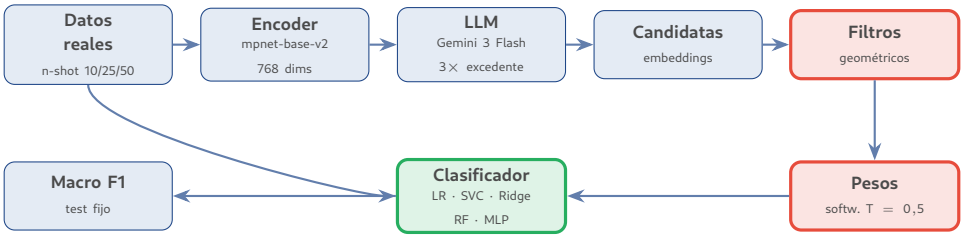
1. Diseñar el sistema de filtros con ponderación suave.
2. Comparar contra **9 métodos** (clásicos + modernos).
3. Demostrar generalización a **NER**.

Criterio de aceptación: $\Delta > 0$, $p_{\text{Bonf}} < 0{,}05$, win-rate $> 50\,\%$.

5.
Metodología

1. Introducción
2. Problema
3. Estado del arte
4. Hipótesis
5. Metodología
6. Resultados
7. Discusión

Pipeline: del texto real al clasificador entrenado



Filtrado y ponderación: dos contribuciones desacopladas del LLM.

Protocolo experimental: 8.000+ configuraciones

Datos y modelos:

- **13 datasets** en 9 dominios.
- n**-shot:** 10 / 25 / 50 ejemplos por clase.
- **5 clasificadores:** LR, SVC, Ridge, RF, MLP.
- **10 métodos** de aumentación.
- **5 LLMs** (Gemini, GPT-5, Claude, Kimi, GLM).
- **4 modelos** de embeddings.
- **5 semillas:** 42, 123, 456, 789, 1011.

Protocolo estadístico:

- Métrica: **macro F1**.
- ΔF1 vs. SMOTE (puntos porcentuales).
- t**-pareada** con corrección de Bonferroni.
- Bootstrap CI 95 % (10 000 remuestreos).
- d de Cohen como tamaño de efecto.
- Win-rate como medida de consistencia.

Volumen

8.000+ configuraciones

Métrica de evaluación: Macro F1

Por qué no accuracy: con clases desbalanceadas, predecir siempre la clase mayoritaria puede dar 95 % de accuracy y 0 % en la clase rara.

Macro F1 promedia el F1 de cada clase con peso igual, sin importar su tamaño:

F1 por clase c:

$$\mathrm{F1}_c = 2 \cdot \frac{\mathrm{P}_c \cdot \mathrm{R}_c}{\mathrm{P}_c + \mathrm{R}_c}$$

Macro F1 sobre C clases:

$$\text{macro-F1} = \frac{1}{C} \sum_{c=1}^{C} \mathrm{F1}_c$$

donde $\mathrm{P}_c = \dfrac{\mathrm{TP}_c}{\mathrm{TP}_c + \mathrm{FP}_c}$ y $\mathrm{R}_c = \dfrac{\mathrm{TP}_c}{\mathrm{TP}_c + \mathrm{FN}_c}$.

Propiedades clave

- Penaliza errores en **clases raras** igual que en clases grandes.
- Rango $[0, 1]$; $1 =$ perfecto.
- Detecta cuando el modelo ignora clases minoritarias.

Reporte de resultados

- $\Delta\mathrm{F1}$: diferencia frente a SMOTE (puntos porcentuales).
- Test fijo, mismo split en todas las configuraciones.

Macro F1: la métrica honesta cuando hay clases raras.

Conjuntos de datos: 13 corpus en 9 dominios

Conjunto	Dominio	Clases	n-shots	Test
Clasificación de texto — experimento principal				
`sms_spam`	Detección de spam	2	10, 25, 50	1.394
`hate_speech_davidson`	Discurso de odio	3	10, 25, 50	4.948
`20newsgroups`	Noticias (4 cat.)	4	10, 25, 50	7.532
`ag_news`	Noticias (4 cat.)	4	10, 25, 50	7.600
`emotion`	Emociones	6	10, 25, 50	2.000
`dbpedia14`	Clasificación de temas	14	10, 25, 50	5.000
`20newsgroups_20class`	Noticias (20 cat.)	20	10, 25, 50	7.532
Adicionales — escalabilidad por número de clases				
`trec6`	Preguntas	6	10, 25, 50	500
`banking77`	Intenciones bancarias	77	10, 25, 50	3.080
`clinc150`	Intenciones de diálogo	150	10, 25, 50	4.500
Reconocimiento de entidades nombradas (NER)				
`MultiNERD`	Entidades generales	5 tipos	10, 25, 50	10.000
`WikiANN`	Entidades Wikipedia	3 tipos	10, 25, 50	10.000
`Few-NERD`	Entidades detalladas	8 tipos	10, 25, 50	10.000

n-shot estricto: 10 / 25 / 50 ejemplos por clase. Rango de complejidad: de binario (*`sms_spam`*) a 150 clases (*`clinc150`*).

¿Por qué estos datasets de clasificación?

Experimento principal — 7 datasets

Buscan **cobertura en tres ejes**:

- **Granularidad:** 2 → 20 clases.
- **Dominio:** spam, odio, noticias, emoción, ontología.
- **Estilo:** corto/largo, formal/informal, social/curado.

- `sms_spam` (2): NLP canónico, frase corta.
- `hate_speech_davidson` (3): dominio sensible.
- `20newsgroups`, `ag_news` (4): noticias.
- `emotion` (6): el ejemplo recurrente.
- `dbpedia14` (14): ontología Wikipedia.
- `20newsgroups_20class` (20): máxima granularidad.

Escalabilidad — 3 datasets adicionales

Responden la pregunta:

¿el filtrado sigue funcionando con muchas clases?

- `trec6` (6): preguntas TREC, mismo régimen de clases que el principal pero distinto dominio. Sirve de **control**.
- `banking77` (77): intenciones bancarias, granularidad fina con clases semánticamente cercanas.
- `clinc150` (150): intenciones de diálogo de asistentes virtuales. **Caso extremo**.

Permiten medir **degradación del filtrado** al aumentar el número de clases.

Diez datasets, dos preguntas: ¿qué tan bueno es el filtrado? ¿hasta dónde escala?

¿Qué es NER y por qué la usamos?

NER (Named Entity Recognition)

Tarea de NLP que **detecta nombres propios dentro del texto y los clasifica por tipo**: personas, lugares, organizaciones, fechas, etc.

Ejemplo: «Llamé a María en Madrid el 2 de marzo .» ↑PER ↑LOC ↑DATE

¿Por qué la usamos como prueba?

- Construimos el filtro para **clasificación**.
- NER es una tarea NLP **distinta**: en vez de etiquetar la oración entera, se etiquetan palabras dentro.
- Si el mismo filtro funciona en NER **sin cambiarlo** ⇒ el filtro no depende de la tarea.

3 corpus, distinta complejidad

- `WikiANN` — 3 tipos (PER, ORG, LOC). **Fácil**.
- `MultiNERD` — 5 tipos (+ DATE, MISC). Medio.
- `Few-NERD` — 8 tipos jerárquicos. **Difícil**.

Es la prueba más fuerte de que el método **generaliza**.

Mismo filtro, otra tarea: si funciona acá, sirve en general.

Cinco estrategias de filtrado evaluadas

Filtro	Criterio	Parámetros
None (control)	Sin filtrado, todas las muestras LLM.	—
LOF	Densidad local; conserva inliers de `decision_function` (sklearn).	k = 20 vecinos[†]; umbral > 0
Cascade L1 ⋆	Distancia euclidiana al centroide. Top-N por ranking.	nivel = 1 (diseño soporta 1–4)[‡]
Combined	LOF **Y** similitud coseno.	$\tau_{\cos} = 0{,}5$
Embedding-Guided	Cobertura 0,6 + calidad 0,4, voraz.	multi-criterio

⋆ Cascade nivel 1 = mejor configuración encontrada.

[†] *`decision_function`* invierte el LOF clásico: > 0 = inlier, < 0 = outlier. Si la clase tiene < 21 muestras (10-shot), k se ajusta a $n - 1$.

[‡] k = 10 aplica solo al nivel 3 (pureza KNN); en L1 no se usa.

Cinco diseños, una pregunta: ¿filtros simples o complejos?

Cascada de filtros: niveles 1–4

Score compuesto (media geométrica):

$$s(x) = \left(\prod_{i=1}^{L} s_i(x) \right)^{1/L}$$

$s(x)$: calidad final $s_i(x)$: score nivel i L: niveles activos

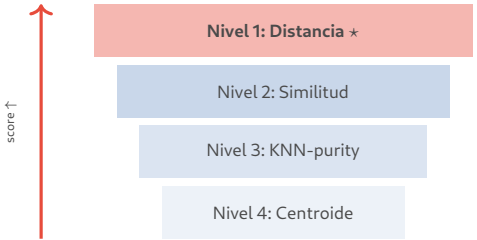
Nivel 1 ⋆ Distancia euclidiana al centroide.

Nivel 2 Similitud coseno.

Nivel 3 Pureza KNN ($k = 10$).

Nivel 4 Distancia al centroide.

Con vectores L2-normalizados, niveles 1 y 2 son redundantes; los niveles 3–4 introducen ruido en pocos ejemplos.



Selecciona top-N por ranking,

sin umbral binario.

Ponderación suave: la 2.ª contribución

En vez de **aceptar / rechazar**, asignamos un peso a cada muestra.

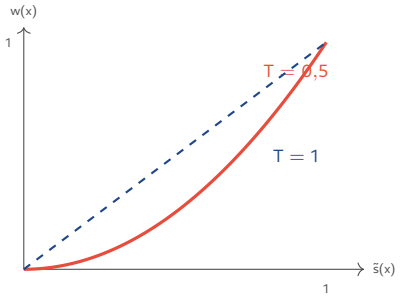
Eq. 1 — Normalización min-max:

$$\tilde{s}(x) = \frac{s(x) - s_{mín}}{s_{máx} - s_{mín}}$$

Eq. 2 — Escalado por temperatura:

$$w(x) = máx\left(w_{mín},\ \tilde{s}(x)^{1/T}\right)$$

$T = 0{,}5$, $w_{mín} = 0$, datos reales $\Rightarrow$ peso 1.



Score normalizado

$T < 1$ amplifica diferencias entre buenas y malas.

Las muestras se entregan al clasificador como `sample_weight`.

6.
Resultados

1. Introducción
2. Problema
3. Estado del arte
4. Hipótesis
5. Metodología
6. Resultados
7. Discusión

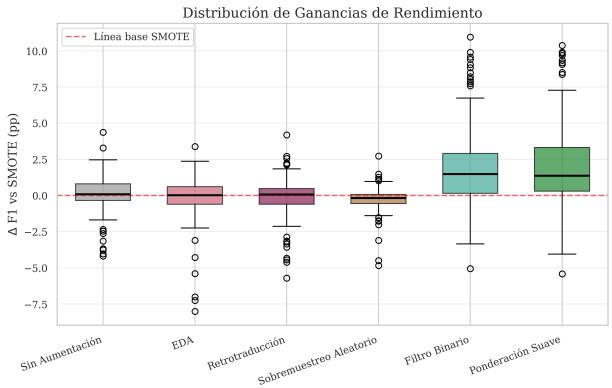
Resultado principal

+2,25 pp

vs. SMOTE

(macro F1)

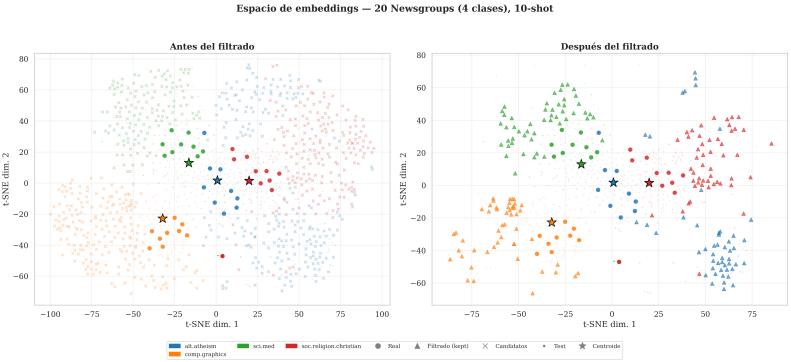
- $p < 0.0001$ [Bonferroni]
- d de Cohen $= 0.74$ [efecto medio-grande]
- Win-rate $= 83.8\,\%$
- $N = 3.675$ configuraciones
- Clasificación absoluta: **73.49 %** vs. 71.24 %



Distribución de ΔF1 por método.

El método propuesto supera todas las líneas base, incluidas las modernas.

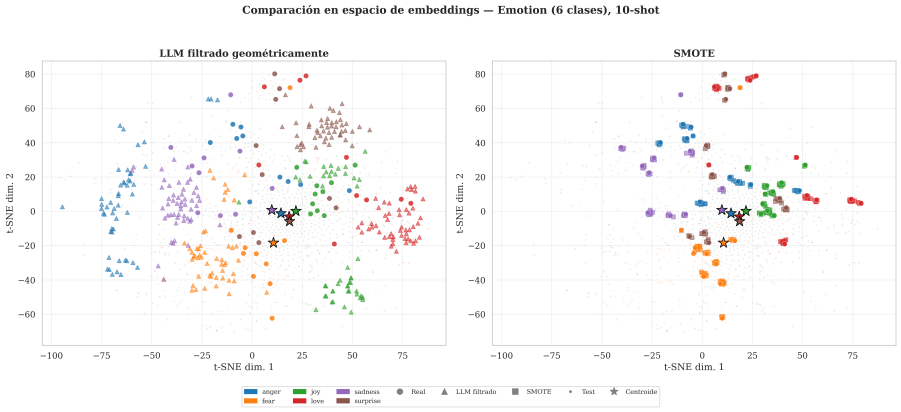
Visualización t-SNE: el filtro en acción — antes vs después



`20newsgroups` (4 clases, 10-shot). **Izq.:** candidatas del LLM (triángulos tenues). **Der.:** sólo las que pasaron el filtro. Círculos = reales, estrellas = centroides.

El filtro descarta candidatas en zonas de cruce o periféricas; conserva las que refuerzan el cluster.

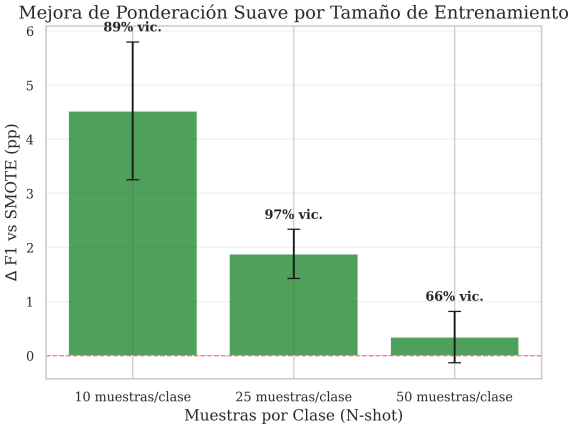
Visualización t-SNE: SMOTE vs filtro



Dataset `emotion` (6 clases, 10-shot): triángulos = LLM filtrado, cuadrados = SMOTE.

El filtro rechaza candidatas en zonas de cruce y aporta diversidad real.

Retornos decrecientes con más datos



ΔF1 por valor de n-shot.

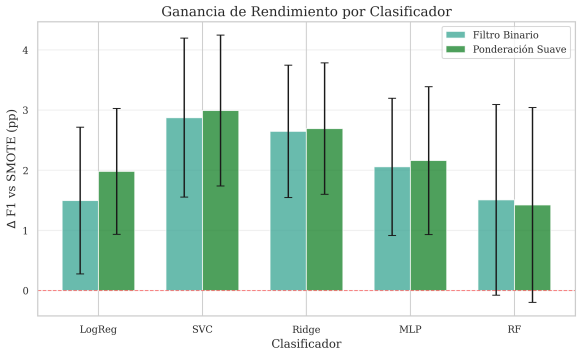
El método brilla donde más se necesita:

n-shot	ΔF1	d
10	+4.89	1.48
25	+2.17	1.57
50	+0.76	0.80

Cuanto menos datos hay, más útil es el filtrado.

Caso de uso ideal: 10 ejemplos por clase.

El clasificador importa: lineales ganan



Clasificador	ΔF1	d	p
SVC (lineal)	+2.99	1.02	< 0,001
Ridge	+2.69	1.04	< 0,001
MLP	+2.16	0.73	< 0,001
Logistic Regression	+1.98	0.82	< 0,001
Random Forest	+1.42	0.31	n.s.

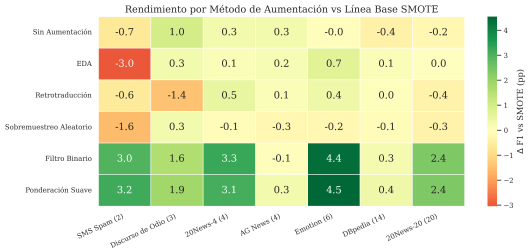
p-valor con t-pareada y Bonferroni.

H1d confirmada: **ensambles de árboles**

no aprovechan los pesos suaves.

Modelos lineales explotan mejor la señal geométrica.

¿Cuándo conviene aplicarlo? Por número de clases



Sweet spot: pocas clases.

# Clases (dataset)	ΔF1
6 (`trec6, emotion`)	+5.42
4 (`20news, ag`)	+2.80
2 (binarios)	+3.18
77 (`banking77`)	−0.99
150 (`clinc150`)	+0.01

Spearman $\rho = -0.260$, p $= 0.003$.

Saturación con $\geq$ 77 clases: el espacio se fragmenta.

Las clases que más ganan: las que partían perdiendo

Dataset	Clase	SMOTE	Ours	Δ
Clases con F1 base bajo				
emotion	**anger**	27.8	44.6	**+16.9**
20news	**alt.atheism**	50.9	65.9	**+15.0**
emotion	joy	29.4	42.6	+13.3
hate_speech	**offensive**	73.3	86.3	+13.0
emotion	fear	48.8	59.0	+10.2
Clases con F1 base alto				
20news	comp.graphics	90.8	91.3	+0.5
emotion	sadness	41.3	42.3	+1.0

10-shot; 3 clasificadores lineales.

Patrón: las clases difíciles inicialmente son las que más ganan con filtrado geométrico.

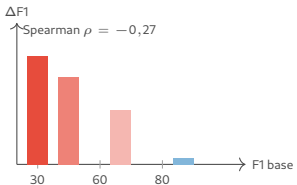
- "anger" arranca en **27.8 %** (poco discriminable).
- Termina en **44.6 %**: +16,9 pp.
- "comp.graphics" parte ya en 90.8 %: poco margen, ganancia +0,5 pp.

Donde el clasificador **ya rinde bien**, el filtrado aporta poco.
Donde **tropieza**, el filtrado densifica la región correcta y refuerza la frontera.

El método actúa justo donde el modelo más lo necesita.

Resumen por dificultad: la mejora escala con el déficit

Dificultad (F1 base)	N clases	Δ medio
Difícil (<30 %)	4	**+10.44**
Media (30–60 %)	4	+8.45
Fácil (60–80 %)	4	+5.40
Muy fácil (>80 %)	1	+0.55



Lectura geométrica:

- Las clases difíciles ocupan regiones de solapamiento o frontera con otras clases.
- Las muestras sintéticas filtradas **densifican la región correcta** de la clase.
- Eso refuerza la frontera de decisión donde el clasificador tenía mayor incertidumbre.

Implicancia práctica

Cuanto peor parte una clase, mayor el espacio donde el filtrado geométrico puede empujar el F1 hacia arriba. El método es **auto-correctivo** en el caso más útil.

Mayor déficit inicial ⇒ mayor ganancia: el filtrado va a buscarlas.

Hallazgo contra-intuitivo: simple > complejo



Cascada	L0	L1	L2	L3	L4
# criterios	0	1	2	3	4
ΔF1 (pp)	−0,52	+1,94	+1,94	+1,95	+1,92

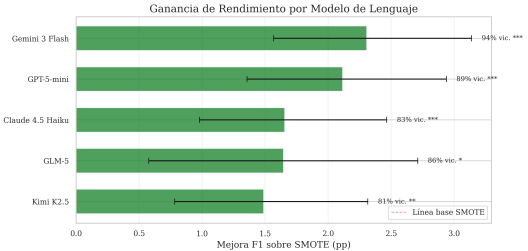
Insight clave

Filtros multi-criterio **degradan** el rendimiento.

- Distancia y similitud son redundantes en L2-norm.
- LOF inestable con $n = 10$.
- Restricciones conjuntivas matan la diversidad.

Más filtrado ≠ mejor filtrado.
Generar muchos, filtrar poco.

Robustez: ¿depende del LLM o del embedding?



5 LLMs probados

Gemini, GPT-5, Claude, Kimi, GLM

ΔF1 entre $+1.49$ y $+2.31$ pp

Friedman $p = 0.086$ [no significativo]

4 modelos de embeddings

Modelo	ΔF1
mpnet-base-v2 (768d)	$+2.74$
bge-large (1024d)	$+2.04$
bge-small (384d)	$+2.00$
e5-large (1024d)	$+0.97$

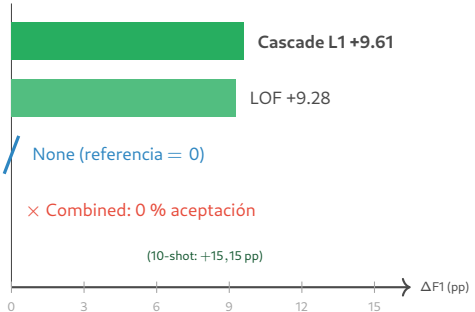
90.5 % acuerdo entre modelos.

El método es agnóstico al LLM y al modelo de embeddings.

Generalización a NER: el filtro funciona en otra tarea

Reconocimiento de entidades nombradas:

- 3 corpus: `MultiNERD`, `WikiANN`, `Few-NERD`
- Adaptación: clase = tipo de entidad dominante por oración.
- **Filtros sin modificación.**



+9.61 pp

Cascade L1

(p = 0,0003, d = 2,05)

La calidad geométrica es agnóstica a la tarea.

7.
Discusión y aplicaciones

1. Introducción
2. Problema
3. Estado del arte
4. Hipótesis
5. Metodología
6. Resultados
7. Discusión

Contribuciones de la tesis

Metodológica

- Sistema de filtros geométricos multi-nivel.
- Ponderación suave por temperatura.
- Desacoplado del LLM.

Empírica

- +2.25 pp vs. SMOTE ($p < 0.0001$).
- Supera a 9 baselines incluidos T5 y BERT.
- Robusto a 5 LLMs y 4 embeddings.

Generalización

- NER: +9.61 pp sin modificar nada.
- Hallazgo: simple $>$ complejo.
- Beneficio en clases difíciles: +10.44 pp.

Insight central: la información geométrica del espacio de embeddings captura calidad de manera agnóstica a la tarea, siempre que el filtro sea simple.

¿Cuándo y cómo usarlo? Utilidad práctica

Receta de aplicación:

1. Tienes 10–25 ejemplos por clase.
2. Tienes 4–10 clases.
3. Generas $3\times$ candidatas con un LLM.
4. Filtras con cascade nivel 1 (distancia).
5. Ponderas suavemente y entrenas un clasificador **lineal**.

Costo real

$\sim$ 10–50 llamadas LLM por clase.
A precios actuales: **centavos por dataset**.

Casos de aplicación inmediata:

- Detectar contenido tóxico nuevo.
- Triaje clínico con notas escasas.
- Categorización de tickets de soporte.
- Monitoreo de marca / tópicos emergentes.
- Clasificación de eventos en logs.

Quién no debería usarlo:

- Más de 50 ejemplos por clase: SMOTE basta.
- $\geq$ 77 clases: el espacio se fragmenta.
- Modelos de árbol como única opción.

Limitaciones, trabajo futuro y cierre

Limitaciones honestas

- Evaluación solo en **inglés**.
- Caching reduce varianza [$+1.79$pp persistente en stochastic clf].
- Pierde efectividad con ≥ 77 clases.
- LLMs comerciales filtran contenido sensible (hate-speech).

Trabajo futuro

- Embeddings y LLMs **multilingües**.
- LLMs locales (Llama, Mistral) sin filtros de contenido.
- Temperatura T **adaptativa por clase**.
- Presupuesto generativo adaptativo.
- Otras tareas: QA, resumen, generación de preguntas.

Gracias.

Preguntas, comentarios, contraejemplos: bienvenidos.

Referencias i

Sobremuestreo geométrico clásico

- Chawla, N. V., Bowyer, K. W., Hall, L. O. & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. J. Artif. Intell. Res., 16, 321–357.
- He, H., Bai, Y., Garcia, E. A. & Li, S. (2008). ADASYN: Adaptive synthetic sampling approach for imbalanced learning. IEEE IJCNN, 1322–1328.

Aumentación textual ligera

- Wei, J. & Zou, K. (2019). EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks. EMNLP-IJCNLP, 6382–6388.
- Sennrich, R., Haddow, B. & Birch, A. (2016). Improving Neural Machine Translation Models with Monolingual Data. ACL.
- Edunov, S., Ott, M., Auli, M. & Grangier, D. (2018). Understanding Back-Translation at Scale. EMNLP, 489–500.
- Kobayashi, S. (2018). Contextual Augmentation: Data Augmentation by Words with Paradigmatic Relations. NAACL-HLT, 452–457.
- Wu, X., Lv, S., Zang, L., Han, J. & Hu, S. (2019). Conditional BERT Contextual Augmentation. ICCS, 84–95.

Aumentación en espacios de embeddings

- Zhang, H., Cisse, M., Dauphin, Y. N. & Lopez-Paz, D. (2018). mixup: Beyond Empirical Risk Minimization. ICLR.
- Chen, J., Yang, Z. & Yang, D. (2020). MixText: Linguistically-Informed Interpolation of Hidden Space for Semi-Supervised Text Classification. ACL, 2147–2157.
- Bayer, M., Kaufhold, M. A. & Reuter, C. (2023). A Survey on Data Augmentation for Text Classification. ACM Computing Surveys, 55(7), 1–39.

Referencias ii

Generación con LLMs

- Brown, T. et al. (2020). Language Models Are Few-Shot Learners. NeurIPS, 33, 1877–1901.
- Whitehouse, C., Choudhury, M. & Aji, A. F. (2023). LLM-powered Data Augmentation for Cross-lingual Commonsense Reasoning. ACL, 1234–1245.
- Suhaeni, C. & Yong, H.-S. (2023). Mitigating Class Imbalance in Sentiment Analysis through GPT-3-Generated Synthetic Sentences. Appl. Sci., 13, 9766. (+12,7 % acc. en minoritarias.)
- Gopali, S., Abri, F., Namin, A. S. & Jones, K. S. (2024). The Applicability of LLMs in Generating Textual Samples for Analysis of Imbalanced Datasets. IEEE Access, 12, 136451–136465.
- Cegin, J., Simko, J. & Brusilovsky, P. (2025). LLMs vs Established Text Augmentation Techniques for Classification: When do the Benefits Outweigh the Costs? NAACL, 10543–10570.
- Springer, J. M., Devoto, C., Tosheva, M. I. & Ramesh, P. (2025). On the Influence of Synthetic Data for Few-Shot Text Classification. Findings ACL, 8249–8268.

Fine-tuning de LLMs para generación sintética

- Cloutier, N. A. & Japkowicz, N. (2023). Fine-tuned generative LLM oversampling can improve performance over traditional techniques on multiclass imbalanced text classification. IEEE Big Data, 5181–5186.
- Nguyen, D. et al. (2024). Large Language Models for Imbalanced Classification: Diversity makes the difference (ImbLLM). arXiv:2510.09783.
- Sundararajan, N. T. & Kumarapathirage, A. (2023). SentiGEN: A Sentiment-Aware Generative Model for Text Data Augmentation. Findings EMNLP, 9138–9149.

Referencias iii

Filtrado, anomalías y selección de datos

- Breunig, M. M., Kriegel, H.-P., Ng, R. T. & Sander, J. (2000). LOF: Identifying Density-Based Local Outliers. ACM SIGMOD, 93–104.
- Robinson, M., Dey, S. & Chiang, T. (2025). Token Embeddings Violate the Manifold Hypothesis. NeurIPS.
- Tessari, F. & Hogan, N. (2024). Surpassing Cosine Similarity for Multidimensional Comparisons: Dimension Insensitive Euclidean Metric. arXiv:2407.08623.
- Du, Y. et al. (2025). Disentangling the Roles of Representation and Selection in Data Pruning. ACL, 16791–16809.
- Yu, T., Zhuang, Y., Zhang, Z., Socher, R. & Xiong, C. (2025). R.I.P.: Better Models by Survival of the Fittest Data. ICML.
- Liu, Z., Tang, Y., Wang, H. & Li, M. (2025). Residual Alignment Model: A Framework for Importance Sampling in Data Augmentation. NeurIPS.
- Tokdar, S. T. & Kass, R. E. (2010). Importance Sampling: A Review. WIREs Comput. Stat., 2(1), 54–60.

NER y extensiones

- Zhou, R. et al. (2022). MELM: Data Augmentation with Masked Entity Language Modeling for Low-Resource NER. ACL, 2251–2262.

Manifold hypothesis y embeddings

- Bengio, Y., Courville, A. & Vincent, P. (2013). Representation Learning: A Review and New Perspectives. IEEE TPAMI, 35(8), 1798–1828.
- Fefferman, C., Mitter, S. & Narayanan, H. (2016). Testing the Manifold Hypothesis. J. Amer. Math. Soc., 29(4), 983–1049.
- Muennighoff, N., Tazi, N., Magne, L. & Reimers, N. (2023). MTEB: Massive Text Embedding Benchmark. EACL, 2014–2037.

Backup B0a: ¿Por qué este protocolo estadístico?

Cada herramienta responde una pregunta **distinta** sobre el efecto:

Herramienta	Pregunta	Justificación
t-pareada	¿La diferencia es real?	Configs emparejadas por dataset $\times$ clasificador $\times$ semilla: elimina varianza entre configs.
Bonferroni	¿Y con muchos tests?	7 métodos vs. SMOTE $\Rightarrow \alpha = 0.05/7$. Conservador, blindado contra falsos positivos.
Bootstrap CI 95 %	¿Qué rango es plausible?	No asume normalidad. 10 000 remuestreos: percentiles 2.5 y 97.5 estables al 3er decimal.
d de Cohen	¿Qué tan grande es?	Separa significancia **estadística** de **práctica**: con n=525, p puede ser bajo aunque Δ sea trivial.
Win-rate	¿Qué tan consistente?	Media $+2.25$pp con 50 % win = volátil. Con 82 % win = robusto.

Los **4 apuntan** en la misma dirección $\Rightarrow$ conclusión difícil de atacar.

Backup B0b: d de Cohen — interpretación

Fórmula (pareada):

$$d = \frac{\overline{\Delta F1}}{SD(\Delta F1)}$$

Convenciones (Cohen 1988):

d	Magnitud	Interpretación
0.2	pequeño	apenas distinguible
0.5	medio	visible a ojo
0.8	grande	claramente diferente
1.0+	muy grande	casi sin solapamiento

Nuestros valores

Configuración	d	Magnitud
Global (soft-weighted)	0.74	medio-grande
SVC (lineal)	1.00	muy grande
Ridge	1.03	muy grande
MLP	0.73	medio-grande
LogReg	0.82	grande
emotion 6-clases	1.24	muy grande
20news 10-shot	0.95	muy grande

Con $d = 0{,}74$ y $p < 0{,}0001$: la diferencia es **real** y **práctica**.

Backup B0c: Filtros geométricos — arquitectura y diseño

1. LOF (Local Outlier Factor)

- Score: densidad local relativa a k vecinos.
- **Decisión binaria**: score $>$ θ_{LOF}.
- `novelty=True`: entrenado en reales, evaluado en sintéticos.

2. Cascade (4 niveles)

- L1: distancia euclidiana al centroide.
- L2: + similitud coseno al centroide.
- L3: + pureza KNN (k=10).
- L4: + confianza (dist. a centroide).
- Score combinado: **media geométrica**.
- Selección: **top-N por ranking** (sin umbral).

3. Combined (LOF $\wedge$ similarity)

- Debe pasar **ambos**: LOF $>$ 0 y sim $>$ 0,5.
- Operador **AND** $\Rightarrow$ muy restrictivo.

4. EmbeddingGuided (coverage)

- Maximiza cobertura: distancia a vecinos.
- Penaliza si está demasiado cerca.
- Coverage 0.6 + Quality 0.4 (centroide).

5. None (control)

- Sin filtrado (selección aleatoria).

Cascade L1 + ponderación suave **top-N** es el ganador: distancia simple + ranking.

Backup B0d: Ablación de niveles — ¿más filtros, mejor?

Cascada con selección top-N (sin ponderación suave, binary mask):

Nivel	ΔF1 vs. SMOTE	Win-rate	Filtros activos
L0 (control)	−0,52	50.0 %	ninguno (random)
L1	+1,94	91.7 %	distancia
L2	+1,94	91.7 %	+ similitud
L3	+1,95	91.7 %	+ KNN purity
L4 (full)	+1,92	91.7 %	+ confianza

Con ponderación suave (top-N, n=168**):**

Nivel	ΔF1 vs. SMOTE	Win-rate
L1	+3,66	84.5 %
L2	+3,60	83.9 %
L4 (full)	+3,60	83.3 %

Por qué L1 gana

- Las 4 métricas están **altamente correlacionadas** (distancia + coseno + KNN + centroide → todas miden "cercanía al cluster").
- La media geométrica de señales redundantes **no aporta** información.
- L1 es **robusto en 10-shot**: KNN/LOF degeneran con $<$ 20 vecinos.

Simple gana a complejo: añadir filtros NO mejora, levemente perjudica.

Backup B0e: Elección de hiperparámetros

LOF: `n_neighbors` y `threshold`

Param	k = 5	k = 10	k = 20
ΔF1 vs. SMOTE	+2,43	+0,16	+0,05
Win-rate	90.0 %	70.0 %	67.5 %

Default sklearn k=20 falla en 10-shot (no hay 20 vecinos por clase). k=5 es el sweet spot.

LOF: `threshold`

Threshold	ΔF1	Win-rate
−0,50	+1,29	80.0 %
−0,30	+0,06	68.3 %
0,00 (default sklearn)	+0,88	75.6 %

θ=0 es la frontera matemática inlier/outlier (*`decision_function`*).

Cascade: `k_neighbors` para KNN purity

- Fijado k=10 (compromiso 10/25/50-shot).
- L1 (sin KNN) no es sensible a este parámetro.

Combined: `sim_threshold`

θ_{sim}	ΔF1	Win-rate
0,3	−0,68	55.0 %
0,5	−5,71	41.7 %
0,7	−1,10	71.7 %

Cualquier $\theta_{\text{sim}} > 0$ combinado con AND ⇒ catastrófico.

Top-N: peso mínimo y temperatura

- Normalización: `minmax` (vs. rank, z-score).
- Temperatura τ=0,5 (peaked, $w \propto s^{1/\tau}$).
- Peso mínimo $w_{\text{mín}}$: **poco impacto** ($\pm$0,05pp).

Hiperparámetros del cascade son **poco sensibles**; los de LOF y combined son **críticos**.

Backup B0f: Comparación completa de filtros geométricos

Filtro	ΔF1	Win	Selección	LLM	Notas
cascade L1 + top-N	+3.66	84.5 %	ranking top-N	3×	**Ganador**
cascade L2 (top-N)	+3.60	83.9 %	ranking top-N	3×	Similar a L1
cascade L4 (top-N)	+3.60	83.3 %	ranking top-N	3×	Redundante
cascade L1 (binary)	+1.94	91.7 %	ranking top-N	3×	Sin pesos suaves
cascade L3 (binary)	+1.95	91.7 %	ranking top-N	3×	+ KNN, no ayuda
LOF (k=5, θ=−0.5)	+2.43	90.0 %	umbral (relajado)	6.2×	Segundo mejor
LOF (k=20, θ=0)	+0.05	67.5 %	umbral (estricto)	8×	Default sklearn falla
none (control)	+0.72	62.9 %	sin filtrar	3×	LLM directo
embedding_guided	−1.29	55.0 %	cobertura greedy	–	Coverage-only falla
combined (LOF ∧ sim)	−3.28	52.5 %	AND, ∼23 % pasa	32×	Demasiado restrictivo

Selección: ranking top-N toma los N mejores del pool 3× generado (filtrado por ranking, no por umbral). Umbral: rechaza candidatos bajo el score; el % indica cuántos pasan. "LLM" = candidatos por muestra requerida.

Tres principios confirmados: (1) Ranking top-N $>$ umbral duro. (2) Distancia simple $\geq$ múltiples criterios. (3) Operador **AND** destruye la señal.

Backup B0g: Hiperparámetros LLM y ponderación suave

LLM (Gemini 3 Flash)

Param	Valor	Justificación
`temperature`	0,8	Diversidad / coherencia
`top_p`, `top_k`	default	SDK Gemini
`max_tokens`	4000	$\sim$ 50 muestras/llamada
back-trans. T	0,3	EN $\leftrightarrow$ ES conservador

Ablation `temperature` (cascade L1):

T	sms_spam	20news
0,5	$-0{,}07$	$+5{,}04$
0,7	$+1{,}44$	$+4{,}16$
0,8	$-1{,}06$	$+6{,}04$
0,9	$-0{,}18$	$+6{,}25$
1,0	$+4{,}95$	$+7{,}44$

No monótono. T=0,8 por convención.

Ponderación suave (top-N)

Param	Valor	Comentario
τ ponder.	0,5	$w \propto s^{1/\tau}$, peaked
normalización	minmax	frente a rank, sigmoid
$w_{mín}$	0,0	sensibilidad $< 0{,}2$pp
candidatos	$3\times$ target	margen top-N

Sweep Phase 2 (468 configs):

Param	ΔF1	Win
$\tau = 0{,}5$	$+4{,}10$	88.3 %
$\tau = 1{,}0$	$+3{,}67$	84.0 %
$\tau = 2{,}0$	$+3{,}41$	83.3 %
norm. minmax	$+3{,}98$	89.6 %
norm. rank	$+3{,}56$	83.3 %

τ=0,5 **peaked** amplifica diferencias entre muestras buenas y mediocres $\Rightarrow$ máxima ganancia.

Backup B0h: Embeddings, clasificadores y protocolo

Clasificadores (sklearn defaults)

Modelo	Hiperparámetros
LogReg	`max_iter=1000`
SVC	`kernel="linear"`
RandomForest	`n_estimators=100`
Ridge	$\alpha = 1{,}0$
MLP (custom)	128 hidden, 300 ep., lr 10^{-3}

Sin tuning por dataset $\Rightarrow$ las diferencias son del **método de aumentación**.

Protocolo

Seeds $\{42, 123, 456, 789, 1011\}$ · N-shot $\{10, 25, 50\}$ · LLM % $\{5, 25, 50, 100\}$ · macro F1 · 50 sintét./clase · cache MD5.

Embedding model (504 runs)

Modelo	Dim	ΔF1	Win
mpnet-base	768	+2,74	92.1 %
bge-large	1024	+2,04	69.8 %
bge-small	384	+2,00	76.2 %
e5-large	1024	+0,97	68.3 %

Más grande $\neq$ mejor: bge-small (384d) supera a e5-large (1024d).

Hiperparámetros del **filtro** son robustos ($\pm 0{,}5$pp). Los del **embedding** y **clasificador** dominan la varianza.

Backup B1: SMOTE — validación de implementación

Crítica anticipada del comité:

> "¿Su SMOTE dummy-binary es equivalente al SMOTE estándar binary-mask?"

Validación:

- 27 comparaciones lado a lado.
- Diferencia máxima: 0.0000 pp.
- F1 idénticos en todos los datasets.

Línea base SMOTE **robusta y reproducible**.

Resumen

Implementación	F1 medio
dummy-binary	0.7124
binary-mask std.	0.7124
Diferencia	**0.0000**

Backup B2: Asimetría de semillas y caching

Observación: 80 % de combinaciones LLM $\times$ clasificador determinista tienen **varianza cero** entre semillas (la generación está cacheada).

Validación rigurosa:

- Filtramos a clasificadores estocásticos (MLP, RandomForest).
- ΔF1 = $+1.79$ pp.
- $p = 0.0015$, $d = 0.52$.
- Significancia se mantiene.

Implicancia

Los CIs subestiman la varianza real, pero las pruebas t pareadas **siguen siendo válidas**.

Backup B3: Closed-loop vs. pasada única

Hipótesis exploratoria: ¿mejora si re-prompteamos al LLM con feedback de los rechazos?

Estrategia	ΔF1 vs. SMOTE	Win-rate
Closed-loop (5 iteraciones)	+1.12	52 %
Pasada única ⋆	+2.08	80 %

¿Por qué falla closed-loop?

- Tasas de aceptación **decrecen** con iteraciones (-12.3 pp).
- Fallo dominante: `DISTANCE_OUTLIER` (77 %).
- Cuello de botella: **el LLM**, no el prompt.

Pasada única + filtro simple > ingeniería iterativa de prompt.

Backup B4: Filtrado geométrico vs. teacher

Comparación con un filtrado supervisado (teacher classifier):

Filtro	ΔF1 vs. SMOTE	p	Costo extra
Geométrico (binary)	$+2.78$	< 0.001	ninguno
Teacher (binary)	$+2.43$	< 0.001	entrenar clf adicional

El filtro geométrico es **más general** (no se especializa en separabilidad lineal) y **más eficiente** (no requiere entrenamiento extra).

Backup B5: Comparación con baselines modernos

1.890 configuraciones, 10 métodos, 3 clasificadores:

Método	ΔF1 vs. SMOTE	p Bonf.	Win-rate
Soft-weighted (ours)	+2.61	< 0.0001	88.9 %
Binary-filter (ours)	+2.39	< 0.0001	79.4 %
No augmentation	+0.64	< 0.05	56.0 %
Embedding mixup	−0.01	n.s.	51.0 %
Contextual BERT	−0.26	n.s.	48.0 %
T5 paraphrase	−0.35	n.s.	47.0 %
Random oversample	−0.32	n.s.	47.0 %
EDA	−0.49	< 0.05	41.0 %
Back-translation	−0.50	< 0.05	40.0 %

Todas las técnicas modernas **pierden** contra SMOTE; solo el filtrado geométrico gana.